

FINANCIAL DATA

MODULE 2: EQUITIES AND CRYPTOCURRENCIES

Bản dịch tiếng Việt

NGUYỄN VĂN TRUNG

MỤC ĐÍCH TÀI LIỆU

Tài liệu này là bản chuyển ngữ cá nhân, được biên soạn phục vụ **mục đích học tập và nghiên cứu cá nhân** của học viên chương trình Master of Science in Financial Engineering tại WorldQuant University, không nhằm mục đích thương mại và không được phân phối công khai.

Nội dung gồm hai phần:

- **Lesson Notes** do WorldQuant University (WQU) biên soạn cho học viên của khóa học (Module 2, các Lesson 1–4).
- **Các bài đọc thêm (Required Readings)** là tài liệu của bên thứ ba. Chỉ phần WQU yêu cầu đọc được dịch sang tiếng Việt, **sát nguyên bản**, không diễn giải lại hay tóm tắt.

Bản dịch là tác phẩm phái sinh: không phải bản chính thức và không được tác giả hay nhà xuất bản của các tài liệu gốc xác nhận. Khi cần trích dẫn hoặc đối chiếu, vui lòng dùng bản gốc tiếng Anh theo các đường dẫn bên dưới.

GIẤY PHÉP CỦA TỪNG TÀI LIỆU

Tài liệu	Giấy phép / bản quyền
Lesson Notes (Lesson 1–4) , WorldQuant University.	Bản quyền © 2024 WorldQuant University. Nội dung chỉ được cấp phép cho mục đích sử dụng cá nhân; nghiêm cấm phân phối lại hoặc xuất bản.
Damodaran, A. <i>Corporate Finance</i> B40.2302 Lecture Notes: Packet 1 (slide 74–76). NYU Stern. https://people.stern.nyu.edu/adamodar/pdfiles/cfovhs/cfpacket1spr19.pdf	Tệp gốc không nêu điều khoản giấy phép. Bản quyền thuộc về tác giả; phần trích dịch chỉ dùng cho mục đích học tập cá nhân.
Downey, A. B. (2014). <i>Think Stats: Exploratory Data Analysis in Python</i> , v2.2.0, mục 5.2–5.4. Green Tea Press. https://greenteapress.com/thinkstats2/thinkstats2.pdf	Bản quyền © 2014 Allen B. Downey. Phát hành theo giấy phép Creative Commons Attribution-NonCommercial-ShareAlike 4.0 International (CC BY-NC-SA 4.0): http://creativecommons.org/licenses/by-nc-sa/4.0/ . Phần dịch trong tài liệu này được giữ cùng giấy phép (phi thương mại, chia sẻ tương tự, ghi nguồn).
Hiranabe, K. (2023). <i>Matrix World</i> , trong <i>Linear Algebra for Everyone</i> (trang 2–4). https://github.com/kenjihiranabe/The-Art-of-Linear-Algebra/blob/main/MatrixWorld.pdf	Tệp gốc không nêu điều khoản giấy phép. Bản quyền thuộc về các tác giả (Kenji Hiranabe; lời tựa của Gilbert Strang); phần trích dịch chỉ dùng cho mục đích học tập cá nhân.

Tài liệu	Giấy phép / bản quyền
Grammatikos, T., Papanikolaou, N. I. (2021). <i>Applying Benford's Law to Detect Accounting Data Manipulation in the Banking Industry</i>. Journal of Financial Services Research, 59, 115–142 (các bảng và hình). https://link.springer.com/article/10.1007/s10693-020-00334-9	Bài báo truy cập mở, phát hành theo giấy phép Creative Commons Attribution 4.0 International (CC BY 4.0): http://creativecommons.org/licenses/by/4.0/. Các bảng, hình đã được dịch và trình bày lại (có thay đổi so với bản gốc).
Chang, K.-C., Gao, Y.-K., Lee, S.-C. (2020). <i>The Effect of Data Theft on a Firm's Short-Term and Long-Term Market Value</i>. Mathematics, 8(5), 808 (mục 3). https://www.mdpi.com/2227-7390/8/5/808/htm	© 2020 các tác giả; Licensee MDPI, Basel, Thụy Sĩ. Bài báo truy cập mở theo giấy phép Creative Commons Attribution (CC BY) 4.0: http://creativecommons.org/licenses/by/4.0/. Phần được dịch có thay đổi so với bản gốc.
Liu, G. (2020). <i>Data Quality Problems Troubling Business and Financial Researchers: A Literature Review and Synthetic Analysis</i>. Journal of Business & Finance Librarianship, DOI 10.1080/08963568.2020.1847555 (trang in 28–36). https://digitalcommons.wcupa.edu/lib_facpub/13/	Bản thảo tác giả (accepted manuscript) đăng truy cập mở tại West Chester University Digital Commons. Tập không nêu giấy phép Creative Commons cụ thể; bản chính thức (Version of Record) thuộc tạp chí. Phần trích dịch chỉ dùng cho mục đích học tập cá nhân.

VIDEO BẮT BUỘC KHÔNG NẪM TRONG BẢN DỊCH

Ba video sau thuộc phần đọc thêm của WQU nhưng **không được dịch** trong tài liệu này; vui lòng xem trực tiếp tại nguồn:

- Bionic Turtle (2009). *FRM: Why We Use Log Returns in Finance*. <https://www.youtube.com/watch?v=PtoUlt3V0CI>
- Khan Academy. *Measures of Spread: Range, Variance & Standard Deviation*. <https://www.khanacademy.org/math/statistics-probability/summarizing-quantitative-data/variance-standard-deviation-population/v/range-variance-and-standard-deviation-as-measures-of-dispersion>
- Bionic Turtle (2018). *Three Approaches to Value at Risk (VaR) and Volatility (FRM T4-1)*. <https://www.youtube.com/watch?v=qzOWm7PurHE>

GHI CHÚ

Hình ảnh và biểu đồ trong các bài đọc thêm được trích trực tiếp từ tài liệu gốc, thuộc cùng phạm vi giấy phép của từng tài liệu; hình trong Lesson Notes là kết quả chạy mã của chính bài học.

MỤC LỤC

1	DỮ LIỆU TÀI SẢN TÀI CHÍNH	1
1.1	Trích xuất Dữ liệu Cổ phiếu cho Amazon và Ford, cùng với Dữ liệu Bitcoin	1
1.1.1	Xem xét Dữ liệu	2
1.1.2	Tìm hiểu Sâu hơn một chút vào Dữ liệu	4
1.1.3	Vẽ Biểu đồ Giá trong năm 2023	5
1.2	Tính toán Lợi suất Đầu tư	6
1.3	So sánh Cổ phiếu và Bitcoin với Trái phiếu	9
1.3.1	Tính toán Lợi suất Log, Loại bỏ các Cột không sử dụng và Xóa Nulls	11
1.3.2	Hiển thị Thống kê Tóm tắt cho Lợi suất	13
1.3.3	Chuyển đổi Lợi suất Hàng ngày sang Hàng năm	14
1.4	Giá trị Tương lai của một Khoản đầu tư	17
1.4.1	Lấy dữ liệu giá hàng ngày trong 5 năm cho S&P 500 và Russell 2000	18
1.4.2	Tính toán Lợi suất Log, Xóa Các Cột Không Sử Dụng và Loại bỏ Null	20
1.4.3	Tính toán Giá trị Tương lai của Mỗi Chỉ số	21
1.5	Các Cơ hội Đầu tư: Sự Biến động	22
1.5.1	Biến động Giá: Cao-Thấp	22
1.5.2	Trung bình trượt (Moving Averages)	24
1.5.3	Các Khoảng cách Trượt	25
1.5.4	Biến động Giá: Các Độ lệch chuẩn	25
1.5.5	Viết một Hàm So sánh Biến động trong Python	26
1.5.6	Chạy Hàm Biến động của Chúng ta	27
1.6	So sánh Các cổ phiếu Tăng trưởng và Giá trị	29
1.7	So sánh Các cổ phiếu Trong nước và Nước ngoài	30
1.8	Kết luận	33
2	ĐỌC THÊM 2: CORPORATE FINANCE B40.2302 – PACKET 1 (DAMODARAN)	34
2.1	Thông tin nguồn	34
2.2	Khung Trung bình - Phương sai (The Mean-Variance Framework)	34
2.3	Disney rủi ro đến mức nào? Một cái nhìn về quá khứ... (How risky is Disney? A look at the past...)	35
2.4	Bạn có sống trong thế giới trung bình - phương sai không? (Do you live in a mean-variance world?)	35
3	PHÂN TÍCH TÀI SẢN TÀI CHÍNH VÀ LỢI SUẤT	36
3.1	Lấy và biến đổi dữ liệu tài chính	36
3.1.1	Nhập dữ liệu	36
3.1.2	Tính lợi suất log, loại bỏ các cột không dùng và xóa giá trị null	38
3.1.3	Hiển thị thống kê tóm tắt cho lợi suất chỉ số	39
3.2	Phương sai và độ lệch chuẩn	40
3.3	Hiệp phương sai và tương quan	42
3.3.1	Sử dụng ma trận hiệp phương sai	43
3.3.2	Sử dụng công thức hệ số tương quan Pearson	44

3.3.3	Tỷ số Sharpe	47
3.4	Bán phương sai	47
3.5	Lợi suất cổ phiếu được phân phối như thế nào?	48
3.5.1	Lợi suất có đối xứng không?	49
3.5.2	Biến động có không đối xứng không?	50
3.6	Lợi suất cổ phiếu có phân phối chuẩn không?	50
3.6.1	Tiến hành kiểm định tính chuẩn	52
3.6.2	Kiểm định độ xiên và độ nhọn	52
3.6.3	Phân phối Gaussian của chúng ta đổ vỡ ở đâu?	53
3.7	Các phân phối phi Gaussian (Non-Gaussian Distributions)	55
3.8	Kết luận	57
4	ĐỌC THÊM 2: THINK STATS – PHÂN TÍCH DỮ LIỆU KHÁM PHÁ BẰNG PYTHON (MỤC 5.2–5.4)	59
4.1	Thông tin nguồn	59
5.2	Phân phối chuẩn	59
5.3	Biểu đồ xác suất chuẩn	61
5.4	Phân phối log-chuẩn	64
5	CÁC MA TRẬN ĐẶC BIỆT CHO PHÂN TÍCH CỔ PHIẾU	66
5.1	1. Ma trận Đối xứng (Symmetric Matrices)	66
5.1.1	Định nghĩa về Ma trận Đối xứng	66
5.1.2	Chéo hóa Ma trận Đối xứng	67
5.1.3	Ma trận Hiệp phương sai (Covariance Matrix)	69
5.1.4	Ma trận Tương quan (Correlation Matrix)	70
5.1.5	Chuyển đổi giữa Ma trận Hiệp phương sai và Ma trận Tương quan	71
5.2	2. Ma trận Tam giác (Triangular Matrix)	71
5.2.1	Ma trận Tam giác dưới	72
5.2.2	Ma trận Tam giác trên	72
5.2.3	Các tính chất của một Ma trận Tam giác	72
5.3	3. Ma trận Đối xứng Xác định Dương (Symmetric Positive Definite - PD) và Ma trận Đối xứng Bán xác định Dương (Symmetric Positive Semi-Definite - SPD)	72
5.3.1	Ma trận Đối xứng Xác định Dương (PD Matrices)	72
5.3.2	Ma trận Đối xứng Bán xác định Dương (SPD Matrices)	73
5.4	4. Phân tích Cholesky (Cholesky Factorization)	74
5.4.1	Định nghĩa về Phân tích Cholesky	74
5.4.2	Sử dụng Phân tích Cholesky cho Mô phỏng Monte Carlo	76
5.5	5. Kết luận	78
6	ĐỌC THÊM: MATRIX WORLD (ĐẠI SỐ TUYẾN TÍNH CHO MỌI NGƯỜI)	79
6.1	Thông tin nguồn	79
6.2	Thế giới Ma trận : Bức tranh về Mọi Ma trận	79
6.3	Dạo bước qua “Thế giới Ma trận”	79
7	THỰC HÀNH ĐẠO ĐỨC VỚI DỮ LIỆU	83
7.1	Cố ý tạo ra dữ liệu gây hiểu lầm (Intentionally Creating Misleading Data)	83
7.2	Lan truyền đánh giá giả (Propagating Fake Reviews)	84
7.3	Không tiết lộ phí hoặc xung đột lợi ích (Failing to Disclose Fees or Conflicts of Interest)	85

7.4	Dùng dữ liệu mô phỏng thay cho dữ liệu thực mà không công khai rõ ràng (Using Simulated Data Instead of Real Data without Explicit Disclosure)	85
7.5	Thêm dữ liệu tốt vào dữ liệu xấu (Adding Good Data to Bad Data)	86
7.6	Che giấu dữ liệu (Hiding Data)	86
7.7	Làm mượt dữ liệu (Smoothing Data)	87
7.8	Ngoại suy dữ liệu (Extrapolating Data)	87
7.9	Đánh cắp dữ liệu (Stealing Data)	88
7.10	Các vấn đề về chất lượng dữ liệu (Data Quality Problems)	88
7.11	Thu thập dữ liệu khi chưa được phép (Collecting Data without Permission)	88
7.12	Tiết lộ dữ liệu khi chưa được phép (Disclosing Data without Permission)	88
7.13	Kết luận (Conclusion)	89
7.14	Tài liệu tham khảo (References)	89
8	ĐỌC THÊM 1: ÁP DỤNG ĐỊNH LUẬT BENFORD ĐỂ PHÁT HIỆN THAO TÚNG DỮ LIỆU KẾ TOÁN	91
8.1	Thông tin nguồn	91
9	ĐỌC THÊM 2: TÁC ĐỘNG CỦA VIỆC ĐÁNH CẤP DỮ LIỆU LÊN GIÁ TRỊ THỊ TRƯỜNG CỦA DOANH NGHIỆP	109
9.1	Thông tin nguồn	109
9.2	Phát triển các Giả thuyết	109
10	ĐỌC THÊM 3: CÁC VẤN ĐỀ CHẤT LƯỢNG DỮ LIỆU ĐỐI VỚI NHÀ NGHIÊN CỨU KINH DOANH VÀ TÀI CHÍNH	111
10.1	Thông tin nguồn	111
10.2	Các Vấn đề Chất lượng Dữ liệu (Data Quality Problems) Phổ biến	111
10.3	Giá trị bị thiếu (Missing Values)	111
10.4	Lỗi Dữ liệu (Data Errors)	112
10.5	Sự chênh lệch (Discrepancies)	113
10.6	Các Thiên lệch (Biases)	114
10.7	Sự Không nhất quán (Inconsistencies)	115
10.8	Dữ liệu Phần đầu Tĩnh (Static Header Data)	116
10.9	Sự Chuẩn hóa (Standardization)	116
10.10	Những Thay đổi trong Dữ liệu Lịch sử (Changes in Historical Data)	117
10.11	Thiếu tính Minh bạch (Lack of Transparency)	117
10.12	Các Vấn đề về Thời gian Báo cáo (Reporting Time Issues)	118
10.13	Sự lạm dụng Dữ liệu (Misuse of Data)	118
10.14	Hàm ý đối với Tham khảo Kinh doanh và Tư vấn Nghiên cứu	119
10.15	Kết luận	120
10.16	Phụ lục I Danh sách các Bài báo được Đánh giá (List of Reviewed Articles)	120

“Những gì cản trở hành động sẽ thúc đẩy hành động, những gì cản đường sẽ trở thành con đường.”

— Marcus Aurelius

“Chúng ta khổ đau nhiều hơn trong tưởng tượng so với thực tế.”

— Seneca

“Đừng chờ cảm hứng, hãy bắt đầu viết rồi cảm hứng sẽ đến.”

— Khuyết danh

1

DỮ LIỆU TÀI SẢN TÀI CHÍNH

LESSON NOTES

MODULE 2 | BÀI 1

Thời gian đọc	60 phút
Kiến thức nền tảng	Python cơ bản, Đại số
Từ khóa	Cổ phiếu, Bitcoin, Giá trái phiếu, ETF, Lợi suất Đơn giản, Phân tích và Vẽ biểu đồ Dữ liệu trong Python

Trong bài học đầu tiên của học phần này, chúng ta sẽ ôn lại một số khái niệm mà bạn đã học trong môn Thị trường Tài chính. Chúng ta sẽ xem xét giá cổ phiếu, trái phiếu và tiền điện tử trong suốt bài học này. Cuối cùng, chúng tôi cũng sẽ chứng minh cách trích xuất dữ liệu giá từ Python và thực hiện một số phân tích giá cơ bản của cổ phiếu, Bitcoin và dữ liệu trái phiếu. Sau đó, chúng ta sẽ mở rộng những gì đã học với một vài số liệu độ biến động tùy chỉnh, cùng với cách lập trình chúng trong Python. Chúng ta cũng sẽ tập trung vào rủi ro, hoặc độ biến động của lợi suất, của các tài sản tài chính.

```
import datetime
import matplotlib.pyplot as plt
import numpy as np
import pandas as pd
import seaborn as sns
import yfinance as yfin

from datetime import date

pd.options.display.float_format = "{:,.6f}".format
```

1.1 TRÍCH XUẤT DỮ LIỆU CỔ PHIẾU CHO AMAZON VÀ FORD, CÙNG VỚI DỮ LIỆU BITCOIN

Đoạn mã sau trích xuất dữ liệu giá cổ phiếu trong 5 năm của Ford và Amazon cùng với giá Bitcoin hàng ngày trong cùng khoảng thời gian. Lý do chúng tôi chọn Ford và Amazon ở đây là để đưa ra các ví dụ từ các lĩnh vực khác nhau. Mặc dù Amazon đã tồn tại được một thời gian, nó vẫn đại diện cho một cổ phiếu công nghệ phổ biến, mới hơn trong khi Ford là một phần rất lớn của đội ngũ cũ, giao dịch công khai từ năm 1956.

Đoạn mã này sử dụng thư viện yfinance để tải xuống dữ liệu cổ phiếu lịch sử cho Amazon (AMZN), Ford (F) và Bitcoin (BTC-USD).

```
# Ngày bắt đầu và kết thúc
start = datetime.date(2019, 8, 1)
end = datetime.date(2024, 8, 1)

# Lấy dữ liệu
# Để chuyển đổi giữa tải xuống dữ liệu trực tiếp và tải dữ liệu cục bộ,
# bỏ ghi chú dòng mong muốn và ghi chú dòng còn lại.
# Lấy dữ liệu Amazon, Ford và Bitcoin
#df = yfin.download(["AMZN", "F", "BTC-USD"], start, end, auto_adjust = False)["Adj Close"]
df = pd.read_csv('FD_M2_L1_stocks_data.csv', index_col='Date', parse_dates=True)\
    .loc[start:end].reindex(columns=["AMZN", "F", "BTC-USD"])

# Chuyển đổi chỉ mục DataFrame sang nhận biết múi giờ (UTC)
df.index = df.index.tz_localize('UTC')
```

1.1.1 Xem xét Dữ liệu

Trừ khi bạn cực kỳ quen thuộc với tập dữ liệu bạn đang làm việc, hầu như luôn luôn là một ý tưởng hay nếu bạn nhìn vào một vài hàng dữ liệu đầu tiên để có ý tưởng về việc nó trông như thế nào. Chúng ta có thể hoàn thành việc này bằng cách sử dụng phương thức `head()`. Bạn có thể truyền một tham số số vào trong hàm này (ví dụ: 10) và nó sẽ trả về 10 hàng đầu tiên của tập dữ liệu. Theo mặc định, nó trả về năm hàng đầu tiên và cuối cùng.

```
df.head(10)
```

```
AMZN
F
BTC-USD
```

```
Date
```

```
2019-08-01 00:00:00+00:00
92.765999
6.833697
10,399.668945
```

```
2019-08-02 00:00:00+00:00
91.162003
6.811677
10,518.174805
```

```
2019-08-03 00:00:00+00:00
NaN
NaN
10,821.726562
```

```

2019-08-04 00:00:00+00:00
NaN
NaN
10,970.184570

```

```

2019-08-05 00:00:00+00:00
88.256500
6.774976
11,805.653320

```

```

2019-08-06 00:00:00+00:00
89.391502
6.958480
11,478.168945

```

```

2019-08-07 00:00:00+00:00
89.669998
6.995181
11,941.968750

```

```

2019-08-08 00:00:00+00:00
91.644501
7.017202
11,966.407227

```

```

2019-08-09 00:00:00+00:00
90.378998
6.936460
11,862.936523

```

```

2019-08-10 00:00:00+00:00
NaN
NaN
11,354.024414

```

Các phương thức khác là `df.tail(n)` với một đối số chỉ ra `n` hàng cuối cùng của tập dữ liệu hoặc chỉ chạy lệnh `df` để nhận 5 hàng đầu tiên và 5 hàng cuối cùng của tập dữ liệu.

Trong ví dụ của chúng ta ở trên, ngay từ đầu, chúng ta có thể thấy rằng đó là một ý tưởng thông minh khi xem xét dữ liệu này trước. Bạn có thể đoán tại sao chúng ta có các giá trị rỗng ở đây không?

Câu trả lời là các cổ phiếu thông thường chỉ giao dịch từ Thứ Hai đến Thứ Sáu, có nghĩa là không có dữ liệu giá có sẵn vào cuối tuần. Bitcoin không có đặc điểm tương tự vì nó giao dịch bảy ngày một tuần, đó là lý do tại sao ngày 2019-08-03 và 2019-08-04 được điền dữ liệu trong trường hợp này.

1.1.2 *Tìm hiểu Sâu hơn một chút vào Dữ liệu*

Chúng ta có thể sử dụng phương thức *describe()* của pandas để hiển thị các số liệu thống kê tóm tắt của dữ liệu của chúng ta. Chúng ta có thể thấy rằng Bitcoin có số lượng quan sát (count) cao hơn nhiều so với hai cổ phiếu của chúng ta, điều này, như vừa thảo luận, là do cổ phiếu không được giao dịch vào cuối tuần. Các số liệu thống kê tóm tắt khác tương đối cơ bản, như giá trị trung bình và độ lệch chuẩn cùng với việc hiển thị mức tối thiểu, tối đa và một vài phân vị. Đây có thể là thứ mà bạn quan tâm, nhưng rất khó để so sánh các khoản đầu tư này chỉ với dữ liệu này vì mỗi tài sản có một mức giá khởi điểm khác nhau năm năm trước. Để so sánh tốt hơn, chúng ta sẽ phải kiểm tra lợi suất sâu hơn trong một bài học sắp tới.

```
df.describe()
```

```
AMZN
F
BTC-USD

count
1,258.000000
1,258.000000
1,827.000000

mean
137.853120
9.445128
30,854.084965

std
31.730629
2.873780
18,350.840533

min
81.820000
3.042593
4,970.788086

25%
107.565500
6.857018
13,602.354004

50%
143.729996
9.971506
28,033.562500
```

```
75%
164.599251
11.059461
43,593.824219
```

```
max
200.000000
19.209183
73,083.500000
```

1.1.3 Vẽ Biểu đồ Giá trong năm 2023

Nếu chúng ta muốn có một biểu đồ nhanh của dữ liệu trong DataFrame, chúng ta có thể sử dụng phương thức được đặt tên rất phù hợp là `plot()`. Như được hiển thị dưới đây, để vẽ biểu đồ lợi suất năm 2023 của ba tài sản này:


```
# Tạo figure.
# Chúng ta muốn một biểu đồ mà ba tài sản có cùng chỉ mục (trục x) nhưng khác thang đo (trục y)
fig = plt.figure(figsize=(13,7))
ax1 = fig.add_subplot(111)
ax2 = ax1.twinx()
ax3 = ax1.twinx()

# Vẽ biểu đồ dữ liệu
df["2023-01-01":"2023-12-31"].plot(ax=ax1, y='AMZN', legend=True)
df["2023-01-01":"2023-12-31"].plot(ax=ax2, y='BTC-USD', legend=True, color='g')
df["2023-01-01":"2023-12-31"].plot(ax=ax3, y='F', legend=True, color='r')

# Chúng ta thiết lập nhãn cho các trục
ax1.set_ylabel('AMZN')
ax2.set_ylabel('BTC-USD')
ax3.set_ylabel('F')
ax3.spines['right'].set_position(('outward', 60))

# Thiết lập vị trí của các chú giải
ax1.legend(['AMZN'], loc='upper left')
ax2.legend(['BTC-USD'], loc='upper left', bbox_to_anchor=(0, 0.95))
ax3.legend(['F'], loc='upper left', bbox_to_anchor=(0, 0.9))

plt.show()
```



Hình 1.1: Giá AMZN, Bitcoin (BTC-USD) và Ford năm 2023 trên ba trục y khác nhau

Mã và biểu đồ trên minh họa cách chúng ta có thể dễ dàng truyền một phạm vi ngày vào phương thức vẽ biểu đồ để vẽ một tập con của dữ liệu. Nếu không có phạm vi ngày nào được cung cấp, theo mặc định, biểu đồ sẽ bao gồm toàn bộ tập dữ liệu. Đoạn mã này tạo ra một figure với ba biểu đồ con chia sẻ cùng một trục x (ngày) nhưng có các trục y khác nhau để vẽ giá của Amazon (AMZN), Bitcoin (BTC-USD) và Ford (F) cho năm 2023. Cách tiếp cận này cho phép chúng ta hình dung xu hướng giá của ba tài sản khác nhau với các thang đo khác nhau trên cùng một biểu đồ. Tuy nhiên, biểu đồ cũng minh họa lý do tại sao chỉ sử dụng giá không phải là lý tưởng để so sánh hai tài sản. Thang đo giá của Bitcoin so với một cổ phiếu giá thấp như Ford khiến việc so sánh hai cổ phiếu này trở nên rất khó khăn khi quyết định đầu tư vào cổ phiếu nào tốt hơn.

1.2 TÍNH TOÁN LỢI SUẤT ĐẦU TƯ

Nếu chúng ta đầu tư **\$1,000** vào mỗi tài sản này năm năm trước, hôm nay chúng ta sẽ có bao nhiêu tiền? Để trả lời câu hỏi này, trước tiên chúng ta cần xác định chúng ta có thể mua bao nhiêu cổ phiếu của mỗi loại với **\$1,000** vào đầu phạm vi ngày của chúng ta. Đối với mục đích của bài tập này, chúng ta sẽ sử dụng **01/08/2019** làm điểm bắt đầu vì i

Từ dữ liệu của chúng ta ở trên, chúng ta có thể thấy giá khởi điểm của AMZN, F và Bitcoin. Chúng ta cũng có thể lưu trữ giá trị của hàng đầu tiên cho mỗi mã trong các biến riêng lẻ, mà sau đó chúng ta có thể sử dụng cho các tính toán hoặc phân tích sâu hơn. Chúng ta sẽ thực hiện việc này trong đoạn mã sau. Chúng ta cũng cần chia **\$1,000** cho mỗi con số này để xem chúng ta sẽ có bao nhiêu cổ phiếu:

```
# Truy cập hàng đầu tiên của DataFrame
first_row = df.iloc[0]

# Gán các giá trị giá cho các biến
amzn_price = first_row["AMZN"]
f_price = first_row["F"]
btc_price = first_row["BTC-USD"]

# In các giá trị giá
```

```

print("Purchase price of AMZN:", np.round(amzn_price, 3))
print("Purchase price of F:", np.round(f_price, 3))
print("Purchase price of BTC-USD:", np.round(btc_price, 3))
print("-----")

# Chia $1,000 cho mỗi giá trị giá để lấy số lượng cổ phiếu
amzn_shares = 1000 / amzn_price
f_shares = 1000 / f_price
btc_shares = 1000 / btc_price

# In số lượng cổ phiếu cho mỗi mã
print("Number of shares of AMZN:", np.round(amzn_shares, 3))
print("Number of shares of F:", np.round(f_shares, 3))
print("Number of shares of BTC-USD:", np.round(btc_shares, 3))

```

```

Purchase price of AMZN: 92.766
Purchase price of F: 6.834
Purchase price of BTC-USD: 10399.669
-----
Number of shares of AMZN: 10.78
Number of shares of F: 146.334
Number of shares of BTC-USD: 0.096

```

Đây là một hiện tượng tương đối gần đây khi các nhà môi giới bán lẻ cung cấp các cổ phiếu lẻ (fractional shares), nhưng điều này có xu hướng trở thành trường hợp ngày nay đối với hầu hết các nhà môi giới thường được sử dụng. Đối với bài tập này, chúng ta sẽ giả định rằng chúng ta có thể có các cổ phiếu lẻ.

Bây giờ, để xác định hôm nay chúng ta sẽ có bao nhiêu tiền, chúng ta xem xét ngày gần nhất trong tập dữ liệu của chúng ta (31/07/2024), lấy giá của từng tài sản và nhân số lượng cổ phiếu của chúng ta với con số này. Chúng ta có thể tìm thấy điều này bằng cách nhìn vào cuối tập dữ liệu của chúng ta trong việc sử dụng phương thức *tail()*. Ngoài ra, chúng ta cũng có thể lập trình các tính toán giá trị tài sản:

```

# Lấy các giá trị ngày cuối cùng từ df
last_row = df.iloc[-1]

# Gán các giá trị giá của ngày kết thúc cho các biến
amzn_price_end = last_row["AMZN"]
f_price_end = last_row["F"]
btc_price_end = last_row["BTC-USD"]

# In giá ngày kết thúc
print("End price of AMZN:", np.round(amzn_price_end, 3))
print("End price of F:", np.round(f_price_end, 3))
print("End price of BTC-USD:", np.round(btc_price_end, 3))
print("-----")

# Tính toán các giá trị ngày kết thúc cho mỗi mã
amzn_value = amzn_price_end * amzn_shares # cần nhân 20 lần do chia tách cổ phiếu
f_value = f_price_end * f_shares
btc_value = btc_price_end * btc_shares

# In các giá trị ngày kết thúc
print("Holding value of AMZN:", np.round(amzn_value, 3))
print("Holding value of F:", np.round(f_value, 3))
print("Holding value of BTC-USD:", np.round(btc_value, 3))

```

```

End price of AMZN: 186.98
End price of F: 9.786
End price of BTC-USD: 64619.25
-----
Holding value of AMZN: 2015.609
Holding value of F: 1432.036
Holding value of BTC-USD: 6213.587

```

Khoản chi tiêu đầu tư là \$1000 cho mỗi mã. Bây giờ, dựa trên các kết quả tính toán ở trên, có vẻ như các khoản đầu tư của chúng ta đã hoạt động khác nhau:

- AMZN: Khoản đầu tư Amazon của chúng ta đã tăng hơn gấp đôi, cho thấy một mức tăng đáng kể.
- F: Khoản đầu tư Ford của chúng ta cũng đã tăng trưởng, cho thấy một mức lợi suất khá tốt.
- BTC-USD: Khoản đầu tư Bitcoin của chúng ta đã tăng hơn sáu lần, cho thấy một khoản lợi nhuận đáng kể.

Tuy nhiên, điều quan trọng cần nhớ là đây chỉ là những giá trị cuối cùng và không kể toàn bộ câu chuyện. Để có bức tranh rõ ràng hơn về hiệu suất đầu tư, chúng ta cần xem xét:

- Khung thời gian: Chúng ta cần biết khung thời gian của khoản đầu tư này để đánh giá lợi suất một cách chính xác. Những biến động ngắn hạn là bình thường, trong khi các xu hướng dài hạn cho thấy hiệu suất tổng thể tốt hơn.
- Các Yếu tố Bên ngoài: Độ biến động của thị trường, điều kiện kinh tế và tin tức cụ thể của công ty có thể tác động đáng kể đến giá cổ phiếu.
- Chiến lược Đầu tư: Các mục tiêu đầu tư cá nhân và khả năng chấp nhận rủi ro nên hướng dẫn các quyết định của bạn.

Các tài sản này tương đối dễ so sánh ở đây vì chúng ta bắt đầu với \$1,000 trong mỗi tài sản. Nếu chúng ta bắt đầu với các giá trị khác nhau, chúng ta sẽ cần tính toán lợi suất để có sự so sánh đồng nhất (apples-to-apples). Trong một bài học tương lai, chúng ta sẽ xem xét các lợi suất đơn giản và log, nhưng để thuận tiện, chúng ta sẽ sử dụng lợi suất đơn giản:

Công thức Lợi suất Đơn giản (Simple Returns Formula)

$$R_{simple} = \frac{p_1 - p_0}{p_0}$$

trong đó p_1 = giá trị cuối, p_0 = giá trị đầu

Điều này sẽ dễ dàng trong trường hợp của chúng ta vì \$1,000 là giá trị ban đầu trong cả ba tình huống.

```

# Tính toán lợi suất đơn giản
amzn_return = (amzn_value - 1000) / 1000
f_return = (f_value - 1000) / 1000
btc_return = (btc_value - 1000) / 1000

```

```
# In các lợi suất
print("Simple return of AMZN:", np.round(amzn_return * 100, 3), "%")
print("Simple return of F:", np.round(f_return * 100, 3), "%")
print("Simple return of BTC-USD:", np.round(btc_return * 100, 3), "%")
```

```
Simple return of AMZN: 101.561 %
Simple return of F: 43.204 %
Simple return of BTC-USD: 521.359 %
```

Lợi suất của Bitcoin ở đây cao vượt trội so với hai tài sản còn lại. Bitcoin là một tài sản tương đối mới — một số người thậm chí còn cho là rủi ro hơn — so với hai tài sản kia. Rủi ro cao hơn đồng nghĩa với tiềm năng phần thưởng cao hơn, và cho đến nay, việc đầu tư vào Bitcoin đã mang lại kết quả hậu hĩnh.

1.3 SO SÁNH CỔ PHIẾU VÀ BITCOIN VỚI TRÁI PHIẾU

Hãy giới thiệu thêm một loại tài sản nữa ở đây: trái phiếu. Như bạn nhớ từ lớp Thị trường Tài chính, trái phiếu không chỉ có hoàn trả tiền gốc, mà chúng còn trả một khoản phiếu giảm giá (coupon), thường là hàng năm hoặc hàng quý. Để đơn giản hóa mọi thứ, chúng ta sẽ sử dụng một quỹ hoán đổi danh mục (ETF), theo dõi các trái phiếu. ETF là quỹ Vanguard Long-Term Bond Index Fund ETF hoặc gọi tắt là BLV. Quỹ này dự định theo dõi hiệu suất của Chỉ số Bloomberg Barclays U.S. Long Government/Credit Float Adjusted Index. Chỉ số này bao gồm trái phiếu doanh nghiệp cấp đầu tư, chính phủ Hoa Kỳ và trái phiếu định danh bằng đô la quốc tế có kỳ hạn lớn hơn 10 năm. Ít nhất 80% tổng tài sản của quỹ sẽ được đầu tư vào các trái phiếu được giữ trong chỉ số được đề cập ở trên (Vanguard).

Đoạn mã sau sẽ trích xuất dữ liệu BLV và kết hợp nó với DataFrame hiện tại của chúng ta, df.

```
# Để chuyển đổi giữa tải xuống dữ liệu trực tiếp và tải dữ liệu cục bộ,
# bỏ ghi chú dòng mong muốn và ghi chú dòng còn lại.
#df = df.join(yfin.download(["BLV"], start, end, auto_adjust = False)["Adj Close"].tz_localize('UTC'))
df = df.join(pd.read_csv('FD_M2_L1_stocks_data.csv', index_col='Date', parse_dates=True)\
    .loc[start:end].reindex(columns=["BLV"]).tz_localize('UTC'))
df
```

```
AMZN
F
BTC-USD
BLV
```

```
Date
```

```
2019-08-01 00:00:00+00:00
92.765999
```

6.833697
10,399.668945
74.656052
2019-08-02 00:00:00+00:00
91.162003
6.811677
10,518.174805
75.178711
2019-08-03 00:00:00+00:00
NaN
NaN
10,821.726562
NaN
2019-08-04 00:00:00+00:00
NaN
NaN
10,970.184570
NaN
2019-08-05 00:00:00+00:00
88.256500
6.774976
11,805.653320
75.822662
...
...
...
...
...
2024-07-27 00:00:00+00:00
NaN
NaN
67,813.335938
NaN
2024-07-28 00:00:00+00:00
NaN
NaN
68,255.867188
NaN
2024-07-29 00:00:00+00:00
183.199997
9.957947
66,819.914062
67.110588

```

2024-07-30 00:00:00+00:00
181.710007
9.804191
66,201.015625
67.251205

```

```

2024-07-31 00:00:00+00:00
186.979996
9.786100
64,619.250000
67.860443

```

1827 rows $\times$ 4 columns

1.3.1 Tính toán Lợi suất Log, Loại bỏ các Cột không sử dụng và Xóa Nulls

Trước khi tính toán lợi suất, chúng ta cần loại bỏ các null cho các ngày cuối tuần.

```

# Để tính toán lợi suất của cổ phiếu, chúng ta cần loại bỏ các hàng NA.
returns_stocks_BLV = df[['AMZN', 'F', 'BLV']].dropna().pct_change()

# Crypto được giao dịch 24/7
returns_BTC = df[['BTC-USD']].pct_change()

# Chúng ta truyền (broadcast) chỉ mục của crypto vào các cổ phiếu để kết hợp các tập dữ liệu
# có NaN cho các ngày cuối tuần trong các cột cổ phiếu và BLV
returns_stocks = returns_stocks_BLV.reindex(returns_BTC.index)
returns = returns_BTC.join(returns_stocks_BLV, how = 'outer')[1:]
returns

```

```

BTC-USD
AMZN
F
BLV

```

Date

```

2019-08-02 00:00:00+00:00
0.011395
-0.017291
-0.003222
0.007001

```

2019-08-03 00:00:00+00:00
0.028860
NaN
NaN
NaN

2019-08-04 00:00:00+00:00
0.013719
NaN
NaN
NaN

2019-08-05 00:00:00+00:00
0.076158
-0.031872
-0.005388
0.008566

2019-08-06 00:00:00+00:00
-0.027740
0.012860
0.027086
0.006694

...
...
...
...
2024-07-27 00:00:00+00:00
-0.001454
NaN
NaN
NaN

2024-07-28 00:00:00+00:00
0.006526
NaN
NaN
NaN

2024-07-29 00:00:00+00:00
-0.021038
0.003836
-0.016086
0.003785

2024-07-30 00:00:00+00:00
-0.009262
-0.008133
-0.015441
0.002095

```

2024-07-31 00:00:00+00:00
-0.023893
0.029002
-0.001845
0.009059

```

1826 rows × 4 columns

1.3.2 *Hiển thị Thống kê Tóm tắt cho Lợi suất*

```
returns.describe()
```

```

BTC-USD
AMZN
F
BLV

```

```

count
1,826.000000
1,257.000000
1,257.000000
1,257.000000

```

```

mean
0.001579
0.000803
0.000671
-0.000034

```

```

std
0.033707
0.022175
0.027760
0.009179

```

```

min
-0.371695
-0.140494
-0.183614
-0.075169

```

```

25%
-0.013480
-0.011068

```

```
-0.013605
-0.005253
```

```
50%
0.000234
0.000643
0.000000
0.000572
```

```
75%
0.015996
0.012222
0.014212
0.005205
```

```
max
0.187465
0.135359
0.234414
0.049139
```

1.3.3 Chuyển đổi Lợi suất Hàng ngày sang Hàng năm

```
(returns.describe()[["BTC-USD", "F"]])
```

```
BTC-USD
F
```

```
count
1,826.000000
1,257.000000
```

```
mean
0.001579
0.000671
```

```
std
0.033707
0.027760
```

```
min
-0.371695
-0.183614
```

```
25%
```

```

-0.013480
-0.013605

50%
0.000234
0.000000

75%
0.015996
0.014212

max
0.187465
0.234414

```

Vì chúng ta đang sử dụng lợi suất đơn giản, để chuẩn hóa chúng theo năm một cách chính xác, chúng ta sẽ sử dụng trung bình nhân (geometric mean):

$$R_{\text{Geom_Mean}} = \left(\prod_{i=1}^N (1 + r_i) \right)^{\frac{1}{N}} - 1$$

Sau đó, lợi suất hàng năm sẽ được tính bằng:

$$R_{\text{Annualized_Returns}} = (R_{\text{Geom_Mean}} + 1)^{252 \text{ or } 365} - 1$$

```

# Chuẩn hóa BTC-USD theo năm với 365 ngày giao dịch
(np.prod(returns_BTC + 1, axis=0) ** (1/len(returns_BTC))) ** (365) - 1

```

```

BTC-USD 0.440439
dtype: float64

```

```

# Chuẩn hóa cổ phiếu theo năm với 252 ngày giao dịch
(np.prod(returns_stocks_BLV + 1, axis=0) ** (1/len(returns_stocks_BLV))) ** (252) - 1

```

```

AMZN 0.150742
F 0.074584
BLV -0.018936
dtype: float64

```

Chúng ta có thể chạy phân tích tương tự trên BLV giống như chúng ta đã làm trên các cổ phiếu ở trên để lấy tổng lợi suất đơn giản trong khoảng thời gian năm năm bằng cách sử dụng một phương pháp hơi khác. Lần này, chúng ta sẽ tính lợi suất đơn giản và sau đó chỉ nhân khoản đầu tư ban đầu 1,000 đô la với $1 + \text{returnRate}$.

```

# Lấy giá ban đầu và giá cuối từ df
blv_price = df.iloc[0]["BLV"]
blv_price_end = df.iloc[-1]["BLV"]

```

```
# Tính lợi suất đơn giản
blv_return_rate = (blv_price_end - blv_price) / blv_price
print("Simple return rate of BLV:", np.round(blv_return_rate * 100, 3), "%")

# Tính tổng lợi suất đơn giản
total_simple_return = 1000 * (1 + blv_return_rate)
print("Total simple return of BLV: $", np.round(total_simple_return, 3))
```

```
Simple return rate of BLV: -9.103 %
Total simple return of BLV: $ 908.974
```

Đầu ra này chỉ ra rằng khoản đầu tư vào BLV đã trải qua mức lợi suất đơn giản âm là -9.103%. Điều này có nghĩa là chúng ta đã mất khoảng 9.1% khoản đầu tư ban đầu của mình vào BLV.

Nếu chúng ta bắt đầu với 1.000 USD, sau năm năm, chúng ta sẽ thu về $(1 - 9.103) * 1000 = 908.97$ USD.

Đây là mức lợi suất thấp hơn nhiều so với những gì chúng ta sẽ nhận được với Ford, Amazon hoặc Bitcoin. Điều này được dự đoán phần lớn vì trái phiếu trả coupon (lãi suất) hàng quý/hàng năm cùng với việc hoàn trả tiền gốc. Vì lý do này, trái phiếu (đặc biệt là trái phiếu chính phủ) được coi là tài sản an toàn hơn cổ phiếu hoặc tiền điện tử. Một điều chính cần xem xét là nếu một công ty phá sản, bạn có thể không nhận lại được tiền gốc trong một trái phiếu. Điều đó nói lên rằng, điều tương tự cũng áp dụng cho cổ phiếu. Người nắm giữ trái phiếu cũng có rủi ro tín dụng thấp hơn so với người nắm giữ cổ phiếu: nếu bạn sở hữu một trái phiếu của Ford và bạn của bạn sở hữu cổ phiếu Ford, nhưng Ford tuyên bố phá sản vào ngày mai, người nắm giữ trái phiếu sẽ được thanh toán trước trong các thủ tục phá sản và chủ sở hữu vốn cổ phần sẽ chỉ nhận được những gì còn sót lại, làm cho trái phiếu trở thành một khoản đầu tư an toàn hơn.

Nhược điểm của điều này là rất khó để đạt được mức tổng lợi suất mà một cổ phiếu hoặc tiền điện tử có thể đạt được với một trái phiếu. Có một sự đánh đổi giữa rủi ro và phần thưởng (risk-reward tradeoff). Hãy nghĩ lại về bài đọc trong bài học này một chút. Những gì chúng ta vừa thảo luận ở đây được đề cập trong bài đọc so sánh một khoản đầu tư có phương sai cao (high-variance) với một khoản đầu tư có phương sai thấp (low-variance). Bạn chọn gì hoàn toàn phụ thuộc vào sở thích rủi ro của bạn. Luôn xem xét sự đánh đổi giữa rủi ro và phần thưởng.

Dưới đây là một số điểm cần xem xét:

- **Thời gian Đầu tư (Time Horizon):** Lợi suất đơn giản không tính đến khung thời gian đầu tư. Những khoản lỗ ngắn hạn không phải là bất thường, và điều quan trọng là phải đánh giá các khoản đầu tư trong một thời gian dài hơn để có được bức tranh chính xác hơn về hiệu suất của chúng.
- **Đo lường chuẩn (Benchmarking):** So sánh lợi suất của BLV với một điểm chuẩn (benchmark) có liên quan, chẳng hạn như chỉ số thị trường rộng lớn như S&P 500, để đánh giá hiệu suất tương đối của nó.
- **Chiến lược Đầu tư:** Xem xét các mục tiêu đầu tư tổng thể và khả năng chịu rủi ro của bạn khi đánh giá hiệu suất của BLV.

Hãy nhớ rằng lợi suất đơn giản chỉ là một cách để đo lường hiệu suất đầu tư. Để phân tích toàn diện hơn, hãy xem xét các yếu tố như cổ tức, thuế, tính thanh khoản, quy định, rủi ro tín dụng, biến động và giá trị thời gian của tiền.

1.4 GIÁ TRỊ TƯƠNG LAI CỦA MỘT KHOẢN ĐẦU TƯ

S&P 500 bao gồm 500 công ty vốn hóa lớn. Chỉ số này tính toán trọng số theo vốn hóa thị trường. Trọng số này khác với trọng số trong Chỉ số Trung bình Công nghiệp Dow Jones, được tính trọng số theo giá. Các công ty tạo nên chỉ số này được lựa chọn bởi một ủy ban, nhưng các công ty phải đáp ứng các tiêu chí cụ thể trước khi được đưa vào (Standard & Poor's):

- Vốn hóa thị trường phải lớn hơn hoặc bằng 18 tỷ USD.
- Giá trị đô la hàng năm được giao dịch trên vốn hóa thị trường được điều chỉnh theo khối lượng tự do chuyển nhượng lớn hơn 1.0.
- Khối lượng giao dịch tối thiểu hàng tháng là 250.000 cổ phiếu trong mỗi sáu tháng tính đến ngày đánh giá.
- Công ty phải được niêm yết công khai trên Sở Giao dịch Chứng khoán New York (NYSE), bao gồm NYSE Arca hoặc NYSE American, hoặc NASDAQ (NASDAQ Global Select Market, NASDAQ Select Market hoặc NASDAQ Capital Market).
- Công ty phải từ Hoa Kỳ.
- Các chứng khoán không đủ điều kiện để đưa vào chỉ số là các công ty hợp danh hữu hạn, công ty hợp danh hữu hạn chính và các đơn vị ủy thác đầu tư của họ, các vấn đề của OTC Bulletin Board, quỹ đóng, quỹ hoán đổi danh mục, trái phiếu hoán đổi danh mục, ủy thác tiền bản quyền, cổ phiếu theo dõi, cổ phiếu ưu đãi, ủy thác đơn vị, chứng quyền cổ phần, trái phiếu chuyển đổi, ủy thác đầu tư, biên lai lưu ký Mỹ và cổ phiếu lưu ký Mỹ.
- Kể từ năm 2017, các công ty có cấu trúc cổ phiếu hai loại, như Standard & Poor's, không được thêm vào chỉ số.

Điều này sẽ được sử dụng như là đại diện (proxy) của chúng ta cho các cổ phiếu vốn hóa lớn.

Russell 2000 là một chỉ số chứa 2.000 công ty vốn hóa nhỏ và thường xuyên được sử dụng như một điểm chuẩn bởi các quỹ tương hỗ vốn hóa nhỏ cho mục đích so sánh. Russell 2000 được cấu trúc để cung cấp một thước đo cho các cổ phiếu vốn hóa nhỏ. Nó được tái cấu trúc hàng năm để đảm bảo các công ty từ năm trước không trở nên quá lớn và làm biến dạng các đặc điểm của vốn hóa nhỏ (Maginn 118).

Chỉ số Russell 2000 sẽ được sử dụng như là đại diện của chúng ta cho các công ty vốn hóa nhỏ.

Một cách để so sánh hai cơ hội đầu tư là xác định giá trị tương lai của một khoản đầu tư. Luôn có những rủi ro và nhiều giả định cần được đưa ra khi xác định giá trị tương lai, đặc biệt là đối với một khoản đầu tư rủi ro như một cổ phiếu. Chúng ta sẽ bắt đầu bằng cách sử dụng lợi suất trung bình hàng ngày của mỗi chỉ số để xác định lợi suất kỳ vọng. Đây là một cách suy nghĩ đơn giản vì không thể nói rằng 10 năm tới sẽ giống hệt như 10 năm qua, nhưng nó là một điểm khởi đầu khi so sánh các khoản đầu tư. Chúng ta sẽ đi sâu hơn vào các số liệu so sánh nâng cao hơn khi khóa học tiếp diễn.

Công thức tính lãi kép là:

$$FV = PV(1 + i)^n$$

trong đó

FV = Giá trị tương lai PV = Giá trị hiện tại i = Lãi suất định kỳ n = Số kỳ

1.4.1 Lấy dữ liệu giá hàng ngày trong 5 năm cho S&P 500 và Russell 2000

Chúng ta sẽ đi sâu hơn vào các loại tài sản cổ phiếu cụ thể và so sánh chúng như những khoản đầu tư tiềm năng. Chúng ta sẽ bắt đầu bằng cách so sánh cổ phiếu vốn hóa lớn với cổ phiếu vốn hóa nhỏ bằng cách sử dụng S&P 500 và Chỉ số Russell 2000.

Xuyên suốt bài học này, chúng ta sẽ xây dựng hướng tới một hàm ở đây nhận vào một phạm vi ngày và so sánh hai chuỗi lợi suất.

```
# Ngày tháng
start = datetime.date(2019, 8, 1)
end = datetime.date(2024, 8, 1)

# Để chuyển đổi giữa việc tải dữ liệu trực tiếp và tải dữ liệu cục bộ,
# bỏ ghi chú dòng mong muốn và ghi chú dòng còn lại.
#prices = yfin.download(["^GSPC", "^RUT"], start, end, auto_adjust = False)["Adj Close"]
prices = pd.read_csv('FD_M2_L1_stocks_data.csv', index_col='Date', parse_dates=True)\
    .loc[start:end].reindex(columns=["^GSPC", "^RUT"])

# Đổi tên cột để làm cho tên trực quan hơn
prices = prices.rename(columns={"^GSPC": "SP500", "^RUT": "Russell2000"})

# Lấy thống kê của tập dữ liệu
prices.describe()
```

```
SP500
Russell2000

count
1,258.000000
1,258.000000

mean
4,028.833253
1,865.957234

std
685.682781
284.232353

min
2,237.399902
```

991.159973

25%
3,502.235046
1,674.337524

50%
4,110.745117
1,873.654968

75%
4,468.547485
2,067.780090

max
5,667.200195
2,442.739990

Hiển thị 5 hàng đầu tiên
prices.head()

SP500
Russell2000

Date

2019-08-01
2,953.560059
1,550.760010

2019-08-02
2,932.050049
1,533.660034

2019-08-03
NaN
NaN

2019-08-04
NaN
NaN

2019-08-05

```
2,844.739990
1,487.410034
```

Một lần nữa, chúng ta có thể thấy các tập dữ liệu này có các điểm bắt đầu khác nhau, vì vậy cách duy nhất chúng ta có thể thực hiện so sánh công bằng là so sánh lợi suất.

1.4.2 Tính toán Lợi suất Log, Xóa Các Cột Không Sử Dụng và Loại bỏ Null

Ở đây chúng ta có các giá trị null cho các ngày cuối tuần vì S&P 500 và Chỉ số Russell 2000 đều là các chỉ số chứng khoán. Đoạn mã sau loại bỏ các giá trị null bằng phương thức `.df.dropna()` và tính toán lợi suất log của các tài sản tài chính này:

```
# Tính toán lợi suất log
prices = prices.dropna()
df = np.log(prices) - np.log(prices.shift(1))
df = df.iloc[1:, 0:]
df.head()
```

```
SP500
Russell2000
```

```
Date
```

```
2019-08-02
-0.007309
-0.011088
```

```
2019-08-05
-0.030230
-0.030621
```

```
2019-08-06
0.012933
0.009821
```

```
2019-08-07
0.000767
-0.000932
```

```
2019-08-08
0.018588
0.020734
```

Lợi suất log thường được ưa thích hơn lợi suất đơn giản trong phân tích tài chính vì một số lý do:

- Tính cộng dồn theo thời gian: Lợi suất log có thể dễ dàng được cộng lại qua thời gian để tính toán lợi suất tích lũy trong các khoảng thời gian dài hơn.
- Tính chuẩn: Lợi suất log có xu hướng phân phối chuẩn hơn so với lợi suất đơn giản, đây là một đặc tính mong muốn cho việc lập mô hình thống kê.
- Tính đối xứng: Lợi suất log cung cấp tính đối xứng tốt hơn lợi suất đơn giản, đặc biệt đối với những thay đổi nhỏ hơn, điều này làm cho chúng phù hợp hơn với một số loại phân tích tài chính.

Bằng cách tính toán lợi suất log, bạn có thể thực hiện phân tích và lập mô hình tài chính tinh vi hơn.

1.4.3 Tính toán Giá trị Tương lai của Mỗi Chỉ số

Trong đoạn mã sau, chúng ta tính toán lợi suất trung bình hàng năm cho mỗi chỉ số bằng cách sử dụng giá trị trung bình của lợi suất hàng ngày nhân với 252 (số ngày giao dịch mỗi năm). Sau đó, chúng ta sử dụng các lợi suất trung bình này để tính toán giá trị tương lai.

```
# Tính toán lợi suất trung bình hàng năm trong 5 năm qua
avg_returns = df.mean() * 252

# Tính toán giá trị tương lai cho mỗi chỉ số
future_value_sp500 = 1000 * np.exp(avg_returns["SP500"] * 5)
future_value_russell2000 = 1000 * np.exp(avg_returns["Russell2000"] * 5)

print("Future Value of SP500:", future_value_sp500)
print("Future Value of Russell2000:", future_value_russell2000)
```

```
Future Value of SP500: 1872.5041981875975
Future Value of Russell2000: 1455.0892174400194
```

Hãy nhớ rằng hiệu suất trong quá khứ không phải là chỉ báo cho kết quả trong tương lai. Sử dụng lợi suất trung bình của 5 năm qua chỉ là một cách tiếp cận, và bạn nên xem xét các yếu tố khác và rủi ro tiềm ẩn khi đưa ra quyết định đầu tư.

Trong trường hợp cụ thể của chúng ta ở trên, vì chúng ta đang tính toán giá trị tương lai trong khoảng thời gian 5 năm, việc sử dụng lợi suất trung bình hàng năm có khả năng phù hợp và hiệu quả hơn. Tuy nhiên, nếu chúng ta đang phân tích những biến động ngắn hạn hoặc rủi ro của các chỉ số, lợi suất hàng ngày sẽ cung cấp nhiều thông tin hơn.

Việc tốt hơn nên tính toán lợi suất trung bình hàng ngày hay lợi suất trung bình hàng năm phụ thuộc vào bối cảnh và cách chúng ta dự định sử dụng kết quả. Dưới đây là sự phân tích chi tiết về các cân nhắc:

- Khả năng so sánh: Nếu chúng ta muốn so sánh lợi suất của các tài sản hoặc khoản đầu tư khác nhau với các khung thời gian khác nhau, lợi suất hàng năm thường hữu ích hơn. Lợi suất hàng ngày có thể gây hiểu nhầm nếu các kỳ đầu tư không giống nhau.
- Tính toán Giá trị Tương lai: Nếu chúng ta đang đặc biệt tính toán các giá trị tương lai, việc sử dụng trực tiếp lợi suất trung bình hàng năm trong công thức sẽ đơn giản hơn và tránh được các bước bổ sung.

- Phân tích Biến động: Nếu chúng ta quan tâm đến việc phân tích sự biến động hoặc rủi ro của một khoản đầu tư, lợi suất hàng ngày có thể phù hợp hơn vì chúng cung cấp dữ liệu chi tiết hơn.

Viết lại đoạn mã trước bằng cách sử dụng lợi suất hàng ngày như sau:

```
# Tính toán lợi suất trung bình hàng ngày trong 5 năm qua
avg_daily_returns = df.mean()

# Tính toán giá trị tương lai cho mỗi chỉ số (sử dụng lợi suất hàng ngày và 5 năm)
num_days = 252 * 5 # Số ngày giao dịch trong 5 năm
future_value_sp500 = 1000 * np.exp(avg_daily_returns["SP500"] * num_days)
future_value_russell2000 = 1000 * np.exp(avg_daily_returns["Russell2000"] * num_days)

print("Future Value of SP500:", future_value_sp500)
print("Future Value of Russell2000:", future_value_russell2000)
```

```
Future Value of SP500: 1872.5041981875975
Future Value of Russell2000: 1455.0892174400194
```

Cách tiếp cận này sử dụng lợi suất hàng ngày thay vì lợi suất hàng năm để tính toán giá trị tương lai. Hãy nhớ rằng điều này giả định việc tính lãi kép liên tục, có thể không hoàn toàn chính xác đối với các khoản đầu tư trong thế giới thực.

Đầu ra cho thấy giá trị tương lai của một khoản đầu tư ban đầu 1,000 đô la vào cả hai chỉ số S&P 500 và Russell 2000 sau 5 năm, dựa trên lợi suất trung bình hàng ngày của chúng.

- S&P500: Giá trị tương lai xấp xỉ 1.872.50 đô la.
- Russell2000: Giá trị tương lai xấp xỉ 1.455.09 đô la.

Mặc dù giá trị tương lai rất quan trọng khi so sánh các khoản đầu tư, chúng ta cũng cần phải quan tâm đến mức độ biến động của các cơ hội đầu tư này. Trong phần tiếp theo, chúng ta sẽ thảo luận về ba số liệu biến động khác nhau cùng với cách lập trình chúng trong Python.

1.5 CÁC CƠ HỘI ĐẦU TƯ: SỰ BIẾN ĐỘNG

1.5.1 Biến động Giá: Cao-Thấp

Chúng ta sẽ sử dụng lại DataFrame prices để chỉ ra một số cách đơn giản nhằm so sánh sự biến động của một số khoản đầu tư nhất định. Phương pháp đầu tiên là so sánh mức cao và mức thấp của chỉ số. Đối với điều này, chúng ta sử dụng các phương thức max() và min() để lấy mức cao và mức thấp trong khoảng thời gian của DataFrame theo cột. Từ đây, chúng ta có thể trừ chúng cho nhau để có ý tưởng về sự biến động tiềm năng của mỗi khoản đầu tư.

```
prices.max()
```

```
SP500      5,667.200195
Russell2000 2,442.739990
dtype: float64
```

```
prices.min()
```

```
SP500      2,237.399902
Russell2000 991.159973
dtype: float64
```

```
prices.max() - prices.min()
```

```
SP500      3,429.800293
Russell2000 1,451.580017
dtype: float64
```

Mặc dù một số người có thể thấy điều này hữu ích, nhưng chúng ta chắc chắn cần cải thiện số liệu này để làm cho nó hữu ích hơn khi so sánh các khoản đầu tư khác nhau. Bạn nghĩ chúng ta có thể làm điều này như thế nào? Hãy thử hai ý tưởng.

Ý tưởng đầu tiên là thay đổi một chút khung thời gian. Ở trên, chúng ta đang xem xét dữ liệu 5 năm qua. Có lẽ sẽ hữu ích hơn khi phân tích dữ liệu gần đây hơn. Đối với điều này, chúng ta sẽ xem xét cùng một số liệu trong năm qua:

```
# Cắt ra năm ngoái từ dữ liệu giá
end = pd.Timestamp(end).tz_localize(None) # Xóa thông tin múi giờ

currYear = prices.loc[
    pd.Timestamp(end - datetime.timedelta(365)) : end
]

# Tính sự khác biệt giữa các giá trị tối đa và tối thiểu trong currYear
currYear.max() - currYear.min()
```

```
SP500      1,549.830078
Russell2000 626.729980
dtype: float64
```

Ngay cả khi so sánh dữ liệu trong 365 ngày qua, có vẻ khó để thực hiện một sự so sánh hai tập dữ liệu này vì chúng có các điểm bắt đầu khác nhau. Một sự điều chỉnh cuối cùng cho số liệu biến động này có thể là chuẩn hóa nó bằng cách chia cho mức giá hiện tại của chỉ số:

```
(currYear.max() - currYear.min()) / prices.iloc[-1]
```

```
SP500      0.280649
Russell2000 0.277993
dtype: float64
```

Sự biến động là một thước đo của sự phân tán hoặc dao động của các mức lợi suất. Sự biến động cao hơn chỉ ra những sự thay đổi giá lớn hơn và rủi ro có khả năng cao hơn. Bây giờ chúng ta đã có dữ liệu được chuẩn hóa bằng mức giá hiện tại, số liệu cao/thấp này thực sự cho thấy rằng chúng ta có các mức biến động hàng ngày tương tự ở cả hai chỉ số, với S&P 500 biến động hơn một chút so với Russell 2000.

Lưu ý Quan trọng:

- Những giá trị này được dựa trên dữ liệu lịch sử và có thể không phản ánh sự biến động trong tương lai.

- Sự biến động có thể được tính toán bằng cách sử dụng các phương pháp và các khung thời gian khác nhau. Hãy đảm bảo bạn hiểu tính toán cụ thể được sử dụng để diễn giải các kết quả một cách chính xác.
- Việc hiểu sự biến động là rất quan trọng để đánh giá rủi ro đầu tư và đưa ra các quyết định sáng suốt.


1.5.2 Trung bình trượt (Moving Averages)

Chúng ta sẽ tạo một số liệu biến động so sánh giá của mỗi ngày với trung bình trượt. Các mức trung bình 50 ngày và 200 ngày thường được sử dụng khi so sánh các khoản đầu tư. Đối với số liệu của chúng ta, chúng ta sẽ sử dụng mức trung bình 50 ngày. Đây là một ví dụ về cách chúng ta có thể vẽ biểu đồ của S&P 500 cùng với trung bình trượt 50 ngày của nó:

```
# Tính trung bình trượt 50 ngày của cột "SP500"
prices["SP500 50 day_rolling_avg"] = prices.SP500.rolling(50).mean()

# thiết lập kích thước hình vẽ và vẽ một biểu đồ chuỗi thời gian đơn giản bằng cách sử dụng seaborn.
lineplot()
plt.figure(figsize=(13, 7))
sns.lineplot(x="Date", y="SP500", data=prices, label="Daily S&P 500 Prices")

# vẽ trung bình trượt
sns.lineplot(x="Date", y="SP500 50 day_rolling_avg", data=prices, label="Rollingavg", linewidth=2)
plt.show()
```



Hình 1.2: Giá S&P 500 kèm đường trung bình trượt 50 ngày

Trực quan hóa này giúp làm phẳng các dao động ngắn hạn trong giá hàng ngày và làm nổi bật xu hướng dài hạn hơn của S&P 500. Trung bình trượt cung cấp một bức tranh rõ ràng hơn về hướng đi tổng thể của thị trường.

1.5.3 Các Khoảng cách Trượt

Chúng ta có thể tạo một số liệu biến động ở đây bằng cách sử dụng trung bình trượt này. Hãy tưởng tượng chúng ta đang lấy khoảng cách giữa đường trung bình trượt và mỗi điểm dữ liệu từ biểu đồ S&P 500. Chúng ta có thể sử dụng điều này như một đại diện (proxy) cho sự biến động. Chúng ta cũng sẽ muốn xử lý các sự khác biệt âm giống như các sự khác biệt dương; nếu không, chúng có thể triệt tiêu lẫn nhau. Do đó, chúng ta sẽ sử dụng giá trị tuyệt đối của mỗi điểm. Chúng ta sẽ chia các sự khác biệt này cho các mức giá để chuẩn hóa các giá trị này, và cuối cùng, chúng ta sẽ lấy trung bình của các giá trị đó. Điều này có thể được lập trình bằng Python với dòng mã đơn giản này:

```
((abs(prices - prices.rolling(50).mean())) / prices).mean()
```

```
SP500          0.037068
Russell2000     0.048725
SP500 50 day_rolling_avg  0.028209
dtype: float64
```

Kết quả của tính toán này cung cấp một thước đo về việc trung bình các mức giá hàng ngày lệch bao nhiêu so với trung bình trượt 50 ngày của chúng, được thể hiện dưới dạng một phần trăm. Điều này có thể là một chỉ báo hữu ích về sự biến động hoặc sự ổn định của tài sản. Các giá trị cao hơn đề xuất các dao động lớn hơn xung quanh trung bình trượt, trong khi các giá trị thấp hơn chỉ ra các mức giá ổn định hơn.

Đây là một số liệu khác biệt so với số liệu cao/thấp mà chúng ta đã tính toán trước đó, và nó cho thấy độ lệch trung bình cho Russell 2000 là biến động hơn khi so sánh với S&P 500. Và bản thân trung bình trượt (SP500 50 day_rolling_avg) có một độ lệch trung bình là 2,82%. Điều này là như được mong đợi vì trung bình trượt thì mượt hơn các mức giá hàng ngày.

Các giá trị này có thể hữu ích để hiểu sự biến động tương đối của các tài sản khác nhau và mức độ mà các giá hàng ngày có xu hướng đi lệch khỏi các xu hướng dài hạn hơn của chúng.

1.5.4 Biến động Giá: Các Độ lệch chuẩn

Độ lệch chuẩn có khả năng là số liệu biến động phổ biến nhất được sử dụng khi xem xét một cơ hội đầu tư. Nó đơn giản như việc gọi phương thức `std()` trên một DataFrame.

```
prices.std()
```

```
SP500          685.682781
Russell2000     284.232353
SP500 50 day_rolling_avg  635.644388
dtype: float64
```

Như đã đề cập trước đó, việc gọi phương thức này trên các mức giá không trực quan như việc gọi phương thức này trên các mức lợi suất vì các mức giá bắt đầu ở các điểm khác nhau. Để có một so sánh tốt hơn, chúng ta sẽ gọi phương thức `std()` này trên các mức lợi suất hàng ngày của 5 năm qua:

```
df.std()
```

```
SP500      0.013458
Russell2000 0.017503
dtype: float64
```

Ở đây một lần nữa, Russell 2000 có một độ lệch chuẩn cao hơn một chút so với S&P 500, đề xuất rằng nó đã biến động hơn trong 5 năm qua.

1.5.5 Viết một Hàm So sánh Biến động trong Python

Để kết nối tất cả lại với nhau, chúng ta sẽ lấy ba số liệu biến động mà chúng ta đã sử dụng cho đến thời điểm này, cùng với lợi suất hàng ngày trung bình, và viết một hàm, trong đó lấy:

- startTime - định dạng dateTime
- endTime - định dạng dateTime
- tickers - một từ điển của các giá trị trong đó khóa là mã yahoo và giá trị là tên hiển thị tức là {"^GSPC": "SP500", "^RUT": "Russell2000"}

Bằng cách viết một hàm như thế này, nó cho phép nghiên cứu của chúng ta có thể được tái tạo và áp dụng cho nhiều tham số khác nhau. Trong trường hợp của chúng ta, nó sẽ là một phạm vi ngày và từ điển của các mã. Nếu bạn đang viết một ứng dụng nghiêm túc, bạn sẽ cần phải có nhiều xử lý lỗi trong hàm này, chẳng hạn như đảm bảo rằng các tham số được truyền vào thuộc đúng kiểu dữ liệu. Trong trường hợp của chúng ta, chúng ta sẽ giả định các kiểu dữ liệu của các tham số là chính xác và phạm vi ngày thì dài hơn 365 ngày.

```
def investCompare(startTime, endTime, tickers):
    # lấy dữ liệu giá từ yahoo -- (list(tickers.keys())) = ['^GSPC', '^RUT']
    startTime = pd.Timestamp(startTime).tz_localize('UTC')
    endTime = pd.Timestamp(endTime).tz_localize('UTC')

    # Bỏ bình luận/bình luận dòng phù hợp để Tải xuống dữ liệu trực tiếp HOẶC tải dữ liệu từ file cục bộ
    # prices = yfin.download(list(tickers.keys()), startTime, endTime, auto_adjust = False)["Adj Close"]
    prices = pd.read_csv('FD_M2_L1_stocks_data.csv', index_col='Date', parse_dates=True)\
        .tz_localize('UTC').loc[startTime:endTime].reindex(columns=list(tickers.keys()))
    prices = prices.rename(columns=tickers)

    # Tính toán lợi suất
    returns = np.log(prices) - np.log(prices.shift(1))
    returns = returns.iloc[1:, 0:]

    # kéo dữ liệu vào DataFrame riêng để chỉ xem xét 365 ngày cuối cùng của
    # dữ liệu cho việc tính toán số liệu cao/thấp của chúng ta
    currYear = prices.loc[(endTime - datetime.timedelta(365))\
        .tz_convert(prices.index.tz) : endTime.tz_convert(prices.index.tz)]

    # Cao-Thấp
    highLow = (currYear.max() - currYear.min()) / prices.iloc[-1]
    highLow = pd.DataFrame(highLow, columns=["HighMinusLow"])

    # Sự biến động trung bình trượt
    MA = pd.DataFrame(
        ((abs(prices - prices.rolling(50).mean())) / prices).mean(),
        columns=["MovingAverageVolatility"],
    )
```

```

investments = pd.merge(highLow, MA, left_index=True, right_index=True)

# Độ lệch chuẩn
investments = pd.merge(
    investments,
    pd.DataFrame(returns.std(), columns=["StandardDeviation"]),
    left_index=True,
    right_index=True,
)

# Lợi suất hàng ngày
investments = pd.merge(
    investments,
    pd.DataFrame(returns.mean(), columns=["Daily Return Percentage"]),
    left_index=True,
    right_index=True,
)

# Định dạng các cột:
# Cột Cao-Thấp được làm tròn đến 5 chữ số thập phân
investments["HighMinusLow"] = investments["HighMinusLow"].round(4).astype(str)

# Các cột MA, std và lợi suất dưới dạng phần trăm
columns = ["MovingAverageVolatility", "StandardDeviation", "Daily Return Percentage"]
for col in columns:
    investments[col] = (investments[col] * 100).round(3).astype(str) + '%'

return investments

```

Ở đây chúng ta cũng định dạng các giá trị: Các giá trị Cao-Thấp được làm tròn đến 4 chữ số thập phân và các giá trị trong các cột 'MovingAverageVolatility', 'StandardDeviation', và 'Daily Return Percentage' được định dạng dưới dạng các phần trăm với việc làm tròn 3 chữ số thập phân, đây là một thực hành tốt để tạo điều kiện thuận lợi cho sự so sánh.

1.5.6 Chạy Hàm Biến động của Chúng ta

Chúng ta sẽ bắt đầu bằng cách gọi hàm của chúng ta với hai chỉ số mà chúng ta đã và đang kiểm tra cho đến nay: S&P 500 cùng với Chỉ số Russell 2000. Như chúng ta đã thấy, ba số liệu biến động cho thấy Russell 2000 là khoản đầu tư biến động hơn. Lợi suất hàng ngày trung bình cũng cao hơn đối với S&P 500. Do đó, trong 5 năm qua, không chỉ S&P 500 đã sinh lời tốt hơn so với Russell 2000, mà nó còn ít biến động hơn. Hãy ghi nhớ rằng các số liệu biến động khác nhau này đều tính toán theo một cách nào đó về sự biến động của cổ phiếu trong quá khứ. Bài tập này được dự định để chứng minh các cách khác nhau để tính toán sự biến động và cách bạn có thể sáng tạo một chút với nó. Điều này không có nghĩa là sự biến động là không đổi hoặc dễ dự đoán, hành xử theo cùng một cách trong tương lai; bài tập này chỉ phản ánh quá khứ.

```

investCompare(
    datetime.date(2019, 8, 1),
    datetime.date(2024, 8, 1),
    {"^GSPC": "SP500", "^RUT": "Russell2000"},
)

```

HighMinusLow

MovingAverageVolatility
StandardDeviation
Daily Return Percentage

SP500
0.2806
nan%
1.314%
0.058%

Russell2000
0.278
nan%
1.711%
0.036%

Hàm này cung cấp cho chúng ta một không gian gọn gàng để so sánh các khoản đầu tư trong một dòng.
Chúng ta cũng muốn cho thấy rằng chúng ta đã làm cho hàm trở nên linh hoạt để thêm các ký hiệu trong tương lai. Trong ví dụ bên dưới, chúng ta đã thêm Apple vào DataFrame để so sánh nó với hai chỉ số kia.

```
investCompare(  
    datetime.date(2019, 8, 1),  
    datetime.date(2024, 8, 1),  
    {"^GSPC": "SP500", "^RUT": "Russell2000", "AAPL": "Apple"},  
)
```

HighMinusLow
MovingAverageVolatility
StandardDeviation
Daily Return Percentage

SP500
0.2806
nan%
1.314%
0.058%

Russell2000
0.278
nan%
1.711%
0.036%

Apple
0.3154
nan%

```
1.957%
0.104%
```

Các số liệu này cho thấy Apple là một khoản đầu tư tốt hơn về mặt lợi suất hàng ngày, nhưng chúng cũng cho thấy rằng Apple thì biến động đáng kể hơn so với hai chỉ số. Điều này là như được mong đợi, vì các chỉ số đại diện cho các rổ cổ phiếu rộng lớn. Với nhiều cổ phiếu di chuyển theo các hướng khác nhau, bạn sẽ mong đợi các chỉ số ít biến động hơn so với một cổ phiếu riêng lẻ, ngay cả một cổ phiếu blue-chip như Apple.

1.6 SO SÁNH CÁC CỔ PHIẾU TĂNG TRƯỞNG VÀ GIÁ TRỊ

Chúng ta có thể tiếp tục sử dụng hàm mà chúng ta vừa viết để kiểm tra và so sánh các loại khoản đầu tư khác nhau, bắt đầu từ đây với các cổ phiếu tăng trưởng so với giá trị. Là đại diện cho các cổ phiếu tăng trưởng, chúng ta sẽ sử dụng ETF Vanguard Growth (VUG). VUG là một trong những quỹ ETF tăng trưởng lớn nhất với khoảng 87 tỷ đô la tài sản được quản lý.

Đối với các cổ phiếu giá trị, chúng ta sẽ sử dụng ETF Vanguard Value (VTV). VTV là quỹ ETF giá trị nổi bật nhất với 88 tỷ đô la tài sản được quản lý. Như bạn có thể tưởng tượng cho đến thời điểm hiện tại, Vanguard là một nhà cung cấp các quỹ ETF phổ biến và có một số tỷ lệ chi phí thấp nhất trong ngành.

```
# Đặt ngày bắt đầu và ngày kết thúc
start = datetime.date(2022, 8, 1)
end = datetime.date(2024, 8, 1)

# Tính toán các thống kê đầu tư sử dụng hàm investCompare()
investCompare(start, end, {"VUG": "Growth", "VTV": "Value"})
```

```
HighMinusLow
MovingAverageVolatility
StandardDeviation
Daily Return Percentage
```

```
Growth
0.3582
nan%
1.352%
0.064%
```

```
Value
0.2306
nan%
0.857%
0.039%
```

Việc chạy `investCompare` trong vòng hai năm qua cho các quỹ ETF này cho thấy rằng các cổ phiếu tăng trưởng đã rõ ràng vượt trội so với các cổ phiếu giá trị về mặt lợi suất — nhưng không phải là không có sự biến động tăng lên.

Chúng ta cần lưu ý rằng các khung thời gian có ảnh hưởng lớn đến các kết quả của chúng ta ở đây. Hãy xem xét dữ liệu kể từ năm 2010:

```
# Đặt ngày bắt đầu và ngày kết thúc
start = datetime.date(2010, 8, 1)
end = datetime.date(2024, 8, 1)

# Tính toán các thống kê đầu tư sử dụng hàm investCompare()
investCompare(start, end, {"VUG": "Growth", "VTV": "Value"})
```

```
HighMinusLow
MovingAverageVolatility
StandardDeviation
Daily Return Percentage
```

```
Growth
0.3582
2.847%
1.194%
0.065%
```

```
Value
0.2306
2.825%
1.018%
0.051%
```

Thú vị thay, so với phân tích trước đó qua một khung thời gian ngắn hơn, các sự khác biệt về sự biến động và các lợi suất giữa Tăng trưởng (Growth) và Giá trị (Value) dường như đã bị thu hẹp một chút qua giai đoạn dài hơn này. Điều này có thể là do thực tế rằng, trong dài hạn, các hồ sơ rủi ro-lợi suất của các phong cách đầu tư này thì cân bằng hơn.

1.7 SO SÁNH CÁC CỔ PHIẾU TRONG NƯỚC VÀ NƯỚC NGOÀI

Chúng ta sẽ sử dụng S&P 500 một lần nữa cho các cổ phiếu của Hoa Kỳ trong khi tìm kiếm một ETF cho các cổ phiếu nước ngoài. Có rất nhiều tùy chọn để lựa chọn trong không gian này.

Câu hỏi đầu tiên bạn cần tự hỏi bản thân là bạn muốn đầu tư vào đâu? Nó có thể là các thị trường mới nổi, Châu Âu, Trung Quốc, v.v. Để làm cho mọi thứ đơn giản, chúng ta sẽ sử dụng một ví dụ dành riêng cho Châu Âu, ETF: SPDR Portfolio Europe ETF (SPEU), và một ví dụ dành riêng cho Trung Quốc, ETF: SPDR S&P China ETF (GXC).

```
# So sánh Các cổ phiếu Trong nước và Nước ngoài
start = datetime.date(2022, 8, 1)
end = datetime.date(2024, 8, 1)
investCompare(start, end, {"^GSPC": "SP500", "SPEU": "Europe ETF", "GXC": "China ETF"})
```

```
HighMinusLow
MovingAverageVolatility
StandardDeviation
Daily Return Percentage
```

SP500
0.2806
nan%
1.033%
0.045%

Europe ETF
0.2324
nan%
1.095%
0.051%

China ETF
0.2629
nan%
1.626%
-0.001%

Những Điểm chính:

- Quỹ China ETF dường như là khoản đầu tư biến động nhất và rủi ro nhất trong số ba quỹ, với một lợi suất hàng ngày trung bình âm trong giai đoạn này.
- Quỹ Europe ETF và các cổ phiếu của Hoa Kỳ cho thấy các mức độ biến động tương tự và các lợi suất dương, với các cổ phiếu của Hoa Kỳ có một mức lợi suất cao hơn một chút.

Bây giờ, hãy thu nhỏ lại và nhìn vào dữ liệu kể từ năm 2010, và chúng ta sẽ thấy như sau:

```
# So sánh Các cổ phiếu Trong nước và Nước ngoài
start = datetime.date(2010, 8, 1)
end = datetime.date(2024, 8, 1)
investCompare(start, end, {"^GSPC": "SP500", "SPEU": "Europe ETF", "GXC": "China ETF"})
```

HighMinusLow
MovingAverageVolatility
StandardDeviation
Daily Return Percentage

SP500
0.2806
2.655%
1.06%
0.051%

Europe ETF
0.2324

3.191%
1.229%
0.037%

China ETF
0.2629
3.928%
1.526%
0.026%

Những Điểm chính:

- Qua giai đoạn dài hơn này, các cổ phiếu của Hoa Kỳ dường như đã cung cấp các mức lợi suất cao nhất, tiếp theo là quỹ Europe ETF và sau đó là quỹ China ETF.
- Quỹ China ETF, mặc dù vẫn cho thấy sự biến động cao hơn, nhưng có một lợi suất hàng ngày trung bình dương qua dài hạn, không giống như lợi suất âm được quan sát trong phân tích khung thời gian ngắn hơn.

Mặc dù việc xem xét các khung thời gian dài hơn thường được khuyến nghị cho việc đánh giá đầu tư, nó không phải là một quy tắc phổ quát và có những lập luận hợp lệ phản đối việc chỉ dựa vào hiệu suất dài hạn.

Đây là một số điểm chúng ta có thể lập luận:

- Sự thay đổi Động lực Thị trường: Dữ liệu lịch sử dài hạn có thể không phản ánh chính xác các điều kiện thị trường hiện tại hoặc trong tương lai. Các sự dịch chuyển kinh tế, các sự gián đoạn công nghệ, sự gia tăng quy định, và các sự kiện địa chính trị có thể tác động đáng kể đến hiệu suất đầu tư, làm cho các xu hướng trong quá khứ trở nên ít liên quan hơn.
- Các Mục tiêu Đầu tư và Chân trời Thời gian: Một nhà đầu tư có một chân trời thời gian ngắn hơn (ví dụ, tiết kiệm cho một khoản trả trước) có thể ưu tiên hiệu suất ngắn hạn hơn các xu hướng dài hạn. Chiến lược đầu tư và khả năng chịu đựng rủi ro của họ sẽ khác biệt so với một người có một mục tiêu dài hạn hơn (ví dụ, nghỉ hưu).
- Các Cơ hội bị Bỏ lỡ: Việc chỉ tập trung vào các xu hướng dài hạn có thể dẫn đến các cơ hội bị bỏ lỡ trong ngắn hạn. Các nhà đầu tư tích cực hoặc các nhà giao dịch có thể tận dụng các biến động thị trường ngắn hạn để tạo ra các lợi suất, ngay cả khi triển vọng dài hạn là không chắc chắn.
- Thiên kiến Sống sót (Survivorship Bias): Dữ liệu dài hạn thường mắc phải thiên kiến sống sót, nghĩa là nó chỉ bao gồm các công ty hoặc các khoản đầu tư đã tồn tại theo thời gian. Điều này có thể tạo ra một cái nhìn bị bóp méo về hiệu suất lịch sử, vì các khoản đầu tư thất bại không được bao gồm trong phân tích.

Việc xem xét cả các yếu tố ngắn hạn và dài hạn khi đánh giá hiệu suất đầu tư là quan trọng. Một cách tiếp cận cân bằng có sự kết hợp các mục tiêu cá nhân của bạn, khả năng chịu đựng rủi ro, và môi trường thị trường hiện tại là rất quan trọng để đưa ra các quyết định đầu tư sáng suốt.

1.8 KẾT LUẬN

Bài học này là một điểm khởi đầu để kéo vào và phân tích dữ liệu giá trong Python. Chúng ta đã đi vào một số chi tiết cụ thể về các loại cổ phiếu khác nhau và so sánh chúng bằng cách sử dụng các phương pháp tương tự. Chúng ta cũng đã so sánh các lợi suất của các cơ hội đầu tư khác nhau, và chúng ta đã sử dụng Python để minh họa các cách khác nhau để tính toán sự biến động của các khoản đầu tư. Hãy ghi nhớ những bài học này khi chúng ta đào sâu hơn vào sự kết nối giữa sự biến động và lợi suất trong bài học tiếp theo. Tiếp theo, chúng ta sẽ mở rộng phân tích này bằng cách cũng tính đến các lợi suất của các khoản đầu tư khác nhau.

Tài liệu tham khảo

- Maginn, John L. *Managing Investment Portfolios Workbook: A Dynamic Process*. John Wiley & Sons, Inc., 2007.
- Standard & Poor's. *S & P U.S. Indices Methodology*. Nov. 2021, <https://www.spglobal.com/spdji/en/documents/methodologies/methodology-sp-us-indices.pdf>.
- Vanguard. "BLV Long-Term Bond ETF." <https://institutional.vanguard.com/investments/product-details/fund/0927>.

Bản quyền 2024 WorldQuant University. Nội dung này chỉ được cấp phép cho việc sử dụng cá nhân. Việc phân phối lại hoặc xuất bản tài liệu này bị nghiêm cấm.


ĐỌC THÊM 2: CORPORATE FINANCE B40.2302 – PACKET 1 (DAMODARAN)

2.1 THÔNG TIN NGUỒN

- **Nguồn:** Damodaran, Aswath. "Corporate Finance B40.2302 Lecture Notes: Packet 1." New York University. <https://people.stern.nyu.edu/adamodar/pdfiles/cfovhd/cfpacket1spr19.pdf>
- **Phần cần đọc:** Slide 74–76 (10 phút)

2.2 KHUNG TRUNG BÌNH - PHƯƠNG SAI (THE MEAN-VARIANCE FRAMEWORK)

Phương sai (variance) trên bất kỳ khoản đầu tư nào cũng đo lường sự chênh lệch (disparity) giữa lợi suất (returns) thực tế và kỳ vọng.



1. Khung Trung bình - Phương sai (Biểu đồ)


Khoản đầu tư có Phương sai Thấp (Low Variance Investment)
 Khoản đầu tư có Phương sai Cao (High Variance Investment)

2.3 DISNEY RỦI RO ĐẾN MỨC NÀO? MỘT CÁI NHÌN VỀ QUÁ KHỨ... (HOW RISKY IS DISNEY? A LOOK

Lợi suất Kỳ vọng (Expected Return)

Aswath Damodaran 74

2.3 DISNEY RỦI RO ĐẾN MỨC NÀO? MỘT CÁI NHÌN VỀ QUÁ KHỨ... (HOW RISKY IS DISNEY? A LOOK AT THE PAST...)



Disney rủi ro đến mức nào? Một cái nhìn về quá khứ... (Biểu đồ)

Lợi suất của Disney - 2008-2013

Lợi suất trung bình hàng tháng = 1.65% Độ lệch chuẩn (standard deviation) trung bình hàng tháng = 7.64% Lợi suất trung bình hàng năm = 21.70% Độ lệch chuẩn trung bình hàng năm = 26.47%

Aswath Damodaran 75

2.4 BẠN CÓ SỐNG TRONG THẾ GIỚI TRUNG BÌNH - PHƯƠNG SAI KHÔNG? (DO YOU LIVE IN A MEAN-VARIANCE WORLD?)

- Giả sử bạn phải chọn giữa hai khoản đầu tư. Chúng có cùng mức lợi suất kỳ vọng là 15% và cùng độ lệch chuẩn là 25%; tuy nhiên, khoản đầu tư A mang lại một khả năng rất nhỏ để bạn có thể nhân bốn (quadruple) số tiền của mình, trong khi mức chi trả (payoff) cao nhất có thể có của khoản đầu tư B là lợi suất 60%. Bạn sẽ: a. bàng quan (indifferent) giữa hai khoản đầu tư, vì chúng có cùng mức lợi suất kỳ vọng và độ lệch chuẩn? b. ưa thích (prefer) khoản đầu tư A hơn, vì khả năng có mức chi trả cao? c. ưa thích (prefer) khoản đầu tư B hơn, vì nó an toàn hơn?
- Câu trả lời của bạn có thay đổi không nếu bạn không được cho biết rằng có một khả năng nhỏ là bạn có thể mất 100% số tiền của mình vào khoản đầu tư A nhưng kịch bản tồi tệ nhất (worst case scenario) của bạn với khoản đầu tư B là -50%?

Aswath Damodaran 76

3

PHÂN TÍCH TÀI SẢN TÀI CHÍNH VÀ LỢI SUẤT

LESSON NOTES

Thời gian đọc	60 phút
Kiến thức tiên quyết	Python cơ bản
Từ khóa	Lợi suất log và lợi suất đơn, Phương sai, Độ lệch chuẩn, Tương quan, Hiệp phương sai, Tỷ số Sharpe, Bán phương sai

Bài học này sẽ xây dựng dựa trên trọng tâm về giá của các bài học trước để cuối cùng mở rộng cuộc thảo luận sang lợi suất. Chúng ta đi sâu hơn nhiều vào cách tính toán lợi suất và cách so sánh hai khoản đầu tư bằng cách sử dụng các thước đo rủi ro khác nhau. Sau đó, chúng ta tiến thêm một bước bằng cách sử dụng các phân phối để lập mô hình chính xác về rủi ro và lợi suất.

```
import datetime
import numpy as np
import pandas as pd
import seaborn as sns
import yfinance as yfin

from matplotlib import pyplot as plt
from scipy import stats
```

3.1 LẤY VÀ BIẾN ĐỔI DỮ LIỆU TÀI CHÍNH

3.1.1 Nhập dữ liệu

Vì khóa học này có trọng tâm thực tế hơn, chúng ta sẽ bắt đầu bằng cách lấy dữ liệu giá vào Python và chỉ ra cách làm sạch và biến đổi dữ liệu một cách đơn giản để nó ở định dạng dễ làm việc hơn.

```
# Ngày bắt đầu và ngày kết thúc
start = datetime.date(2019, 8, 1)
end = datetime.date(2024, 8, 1)

# Lấy dữ liệu
# Để chuyển đổi giữa tải dữ liệu trực tiếp và tải dữ liệu cục bộ,
# bỏ ghi chú dòng mong muốn và ghi chú dòng còn lại.
# Lấy dữ liệu Amazon, Ford và Bitcoin
#df = yfin.download(["^GSPC", "^IXIC", "BTC-USD"], start, end, auto_adjust = False)['Adj Close']
df = pd.read_csv('FD_M2_L2_stocks_data.csv', index_col='Date', parse_dates=True)\
```

```
.loc[start:end].reindex(columns=["^GSPC", "^IXIC", "BTC-USD"])

# Hiển thị năm hàng đầu tiên
df.head()
```

```
^GSPC
^IXIC
BTC-USD
```

```
Date
```

```
2019-08-01
2953.560059
8111.120117
10399.668945
```

```
2019-08-02
2932.050049
8004.069824
10518.174805
```

```
2019-08-03
NaN
NaN
10821.726562
```

```
2019-08-04
NaN
NaN
10970.184570
```

```
2019-08-05
2844.739990
7726.040039
11805.653320
```

Chúng ta đã lấy dữ liệu từ hai chỉ số phổ biến nhất của Hoa Kỳ là NASDAQ và S&P 500, cùng với giá Bitcoin hàng ngày trong 5 năm qua. Trong bài học này, một số bước làm sạch dữ liệu cơ bản sẽ được thực hiện bằng cách loại bỏ các giá trị null (dữ liệu cuối tuần). Sau đó, chúng ta sẽ có một DataFrame chứa ngày tháng và giá của ba tài sản khác nhau. Ở đây, chúng ta cần so sánh lợi suất thay vì giá vì một số lý do:

1. Lợi suất là một bản tóm tắt không phụ thuộc vào quy mô (scale-free) của một cơ hội đầu tư.

2. Lợi suất có các thuộc tính thống kê dễ làm việc hơn. (Điều này sẽ được thảo luận nhiều hơn trong bài học này.)

Câu hỏi tiếp theo là liệu nên sử dụng lợi suất đơn (simple returns) hay lợi suất log (log returns). Sử dụng các biến số sau, chúng ta có thể định nghĩa các loại lợi suất khác nhau: p_1 = giá trị cuối cùng, p_0 = giá trị ban đầu.

Công thức Lợi suất Đơn

$$R_{simple} = \frac{p_1 - p_0}{p_0}$$

Ví dụ: nếu chúng ta đang tính lợi suất hàng năm và vào ngày 1, danh mục đầu tư có giá trị là \$100 và vào cuối năm nó có giá trị là \$125, lợi suất đơn sẽ là $(125-100)/100 = 0.25$ = mức tăng 25%.

Công thức Lợi suất Log

$$R_{log} = \ln\left(\frac{p_1}{p_0}\right)$$

Ví dụ: nếu danh mục đầu tư của chúng ta có giá trị là \$100 vào đầu năm và \$80 vào cuối năm, lợi suất log sẽ là $\ln(80/100) = -0.223$ = mức lỗ -22.3%.

Lợi suất log được sử dụng trong trường hợp này vì một giả định phổ biến trong nhiều mô hình tài chính là lợi suất có phân phối chuẩn, và lợi suất log có các thuộc tính toán học tốt, giúp chúng dễ làm việc hơn khi xem xét giả định này.

3.1.2 Tính lợi suất log, loại bỏ các cột không dùng và xóa giá trị null

Chúng ta cần loại bỏ các giá trị null đối với các ngày cuối tuần. Đoạn code sau đây tính toán lợi suất log cho S&P 500, NASDAQ, và Bitcoin, đồng thời loại bỏ các cột giá gốc.

```
# Xóa các hàng có giá trị bị thiếu
df.dropna(inplace = True)

# Tính lợi suất log
df["SP500"] = np.log(df["^GSPC"]) - np.log(df["^GSPC"].shift(1))
df["NASDAQ"] = np.log(df["^IXIC"]) - np.log(df["^IXIC"].shift(1))
df["Bitcoin"] = np.log(df["BTC-USD"]) - np.log(df["BTC-USD"].shift(1))

# Xóa các cột giá gốc
df.drop(["^GSPC", "^IXIC", "BTC-USD"], axis = 'columns', inplace = True)

# Xóa các hàng có giá trị bị thiếu (lần nữa)
df.dropna(inplace = True)

# Hiển thị năm hàng đầu tiên
df.head()
```

```
SP500
NASDAQ
Bitcoin
```

Date

2019-08-02
-0.007309
-0.013286
0.011331

2019-08-05
-0.030230
-0.035354
0.115474

2019-08-06
0.012933
0.013784
-0.028132

2019-08-07
0.000767
0.003767
0.039612

2019-08-08
0.018588
0.022178
0.002044

3.1.3 *Hiển thị thống kê tóm tắt cho lợi suất chỉ số*

Đoạn code này sẽ tạo ra các thống kê mô tả (descriptive statistics) cho dataframe của bạn:

```
df.describe()
```

SP500
NASDAQ
Bitcoin

count
1257.000000
1257.000000
1257.000000

```

mean
0.000498
0.000616
0.001453

std
0.013458
0.015952
0.041542

min
-0.127652
-0.131492
-0.464730

25%
-0.005256
-0.006802
-0.016203

50%
0.000866
0.001270
0.000365

75%
0.007240
0.009293
0.020095

max
0.089683
0.089347
0.191527

```

3.2 PHƯƠNG SAI VÀ ĐỘ LỆCH CHUẨN

Các nhà đầu tư cũng phải luôn ghi nhớ về sự biến động (volatility) khi lựa chọn một khoản đầu tư. Ví dụ: một quỹ hưu trí có thể cần phải cẩn thận hơn với tiền của họ và sẽ muốn đảm bảo rằng họ không tham gia vào bất kỳ khoản đầu tư nào cực kỳ biến động. Ngoài ra còn có các quỹ phòng hộ (hedge funds), chuyên bán khống cổ phiếu và thậm chí giao dịch sự biến động bằng các hợp đồng quyền chọn (options). Như bạn có thể thấy, dù bạn là người thích rủi ro (risk-seeking) hay e ngại rủi ro (risk-averse), sự biến động (rủi ro) của một khoản đầu tư là điều bạn nên quan tâm.

Một thước đo biến động đơn giản là phương sai (variance). Phương sai được sử dụng để xem mỗi điểm dữ liệu trong một tập hợp nằm cách xa mức trung bình (mean) bao nhiêu. Phương sai được tính toán bằng các bước sau:

- Lấy chênh lệch giữa mỗi điểm dữ liệu và mức trung bình

- Bình phương mỗi mức chênh lệch đó để chúng đều là giá trị dương
- Tính tổng các kết quả đã bình phương
- Chia kết quả này cho số lượng điểm dữ liệu trừ đi một

$$\sigma^2 = \frac{\sum (x_i - \bar{x})^2}{n - 1}$$

trong đó

σ^2 = phương sai mẫu (sample variance) x_i = giá trị của một quan sát $\bar{x}$ = trung bình của tất cả các quan sát n = số lượng quan sát

Phương sai càng lớn thì nó càng phân tán xa khỏi mức trung bình. Phương sai xử lý tất cả các sai lệch so với mức trung bình theo cùng một cách, bất kể chúng nhỏ hơn hay lớn hơn mức trung bình. Phương sai bằng 0 sẽ chỉ ra rằng mỗi điểm dữ liệu là như nhau.

Độ lệch chuẩn (standard deviation) rất dễ tính toán khi bạn đã có phương sai. Tất cả những gì bạn phải làm là lấy căn bậc hai của phương sai:

$$\sigma = \sqrt{\sigma^2}$$

trong đó σ = độ lệch chuẩn

Độ lệch chuẩn là một thước đo thống kê thường được sử dụng khác để định lượng biến động của thị trường. Bạn có thể kỳ vọng các cổ phiếu tăng trưởng mới hơn sẽ có độ lệch chuẩn cao hơn và các cổ phiếu blue-chip đã được thiết lập lâu đời sẽ có độ lệch chuẩn của lợi suất thấp hơn. Chúng ta sẽ minh họa điều này bằng cách so sánh lợi suất hàng ngày trong 5 năm qua của S&P 500 và NASDAQ, cũng như giá Bitcoin. Mặc dù Bitcoin không nhất thiết là một cổ phiếu tăng trưởng, nhưng nó vẫn rất mới so với S&P 500 và NASDAQ, vì vậy bạn có thể kỳ vọng sẽ thấy những biến động giá lớn hơn khi so sánh với hai chỉ số cổ phiếu đó.

Điều này được minh họa dưới đây bằng cách lấy độ lệch chuẩn của lợi suất trong 5 năm qua. Các kết quả này đúng như kỳ vọng: cả S&P 500 và NASDAQ đều có độ lệch chuẩn hàng ngày rất giống nhau. Mặt khác, Bitcoin có độ lệch chuẩn gấp gần năm lần so với hai chỉ số cổ phiếu.


```
df.std()
```

```
SP500    0.013458
NASDAQ   0.015952
Bitcoin   0.041542
dtype: float64
```


Chúng ta cũng có thể trực quan hóa điều này bằng cách vẽ biểu đồ lợi suất trong Python sử dụng phương thức plot trong pandas kết hợp với các giới hạn trục y được chuẩn hóa để chúng ta có thể đảm bảo rằng mình đang so sánh lợi suất trên cùng một thang đo:

```
# Vẽ hai biểu đồ
ax1 = df.plot(figsize=(15, 3), y="SP500", title="Hình 1: Lợi suất Hàng ngày S&P 500")
ax2 = df.plot(figsize=(15, 3), y="Bitcoin", title="Hình 2: Lợi suất Hàng ngày Bitcoin")

# Đặt giới hạn trục y cho cả hai biểu đồ
ax1.set_ylim(-0.5, 0.4)
ax2.set_ylim(-0.5, 0.4);
```



Hình 1: Lợi suất hàng ngày S&P 500



Hình 2: Lợi suất hàng ngày Bitcoin

Các biểu đồ trên cho thấy rõ ràng Bitcoin biến động (volatile) nhiều hơn bao nhiêu so với S&P 500 và do đó tại sao phương sai/độ lệch chuẩn của lợi suất lại cao hơn nhiều.

Độ lệch chuẩn được ưu tiên hơn phương sai trong hầu hết các trường hợp vì phương sai là kết quả bình phương của các đơn vị lợi suất. Bằng cách lấy căn bậc hai của giá trị này và do đó thu được độ lệch chuẩn, kết quả sẽ ở cùng đơn vị với dữ liệu cơ sở, mà trong trường hợp này là lợi suất. Về mặt trực giác, điều này giúp nó dễ hiểu hơn nhiều.

Hãy ghi nhớ rằng độ lệch chuẩn thấp hơn không nhất thiết là được ưu tiên hơn khi xem xét các khoản đầu tư. Tất cả phụ thuộc vào sở thích rủi ro của nhà đầu tư. Rủi ro cao hơn có nghĩa là tiềm năng phần thưởng cao hơn. Hiểu được góc nhìn của nhà đầu tư là chìa khóa để xác định mức độ rủi ro nào mà một nhà đầu tư cảm thấy thoải mái.

3.3 HIỆP PHƯƠNG SAI VÀ TƯƠNG QUAN

Chúng ta có thể so sánh hiệu suất của các cổ phiếu có các mức giá khác nhau bằng cách sử dụng lợi suất và độ lệch chuẩn. Làm thế nào chúng ta có thể xem xét hiệu suất chung của hai cổ phiếu? Đối với điều này, chúng ta chuyển sang hiệp phương sai (covariance) và tương quan (correlation). Chúng ta sẽ bắt đầu với hiệp phương sai:

$$\frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{N - 1}$$

trong đó

x_i = giá trị của một quan sát của x y_i = giá trị của một quan sát của y $\bar{x}$ = trung bình của x $\bar{y}$ = trung bình của y N = số lượng quan sát

Hiệp phương sai cung cấp cho chúng ta một số hiểu biết về cách hai biến số di chuyển cùng nhau. Hiệp phương sai dương giữa lợi suất các cổ phiếu sẽ chỉ ra rằng khi một cổ phiếu tăng giá, cổ phiếu kia cũng vậy và ngược lại. Hiệp phương sai âm sẽ có nghĩa là hai cổ phiếu di chuyển nghịch chiều nhau, tức là khi cổ phiếu này tăng, cổ phiếu kia giảm.

Nhìn vào ma trận hiệp phương sai dưới đây cho ba tài sản của chúng ta, chúng ta có thể thấy rằng các tài sản này có mối quan hệ tích cực (dương) với nhau. Rất khó để hiểu được nhiều hơn thế với những con số này, do các đơn vị không được chuẩn hóa.

3.3.1 Sử dụng ma trận hiệp phương sai

Mặc dù hiệp phương sai hữu ích để xác định hướng của hai biến số cùng nhau, chúng ta có thể chuyển sang tương quan để có một phiên bản chuẩn hóa hơn của thước đo này. Hiện tại, khi thảo luận về tương quan, chúng ta sẽ sử dụng hệ số tương quan Pearson. Các loại tương quan khác sẽ được thảo luận trong một bài học tương lai.

```
df.cov()
```

```
SP500
NASDAQ
Bitcoin
```

```
SP500
0.000181
0.000203
0.000200
```

```
NASDAQ
0.000203
0.000254
0.000253
```

```
Bitcoin
0.000200
0.000253
0.001726
```

Dưới đây là cách diễn giải nó:

- Các giá trị trên đường chéo: Những giá trị này đại diện cho phương sai của mỗi tài sản. Ví dụ: 0.000181 là phương sai của lợi suất log hàng ngày của S&P 500.
- Các giá trị ngoài đường chéo: Những giá trị này đại diện cho hiệp phương sai giữa hai tài sản khác nhau. Ví dụ: 0.000203 là hiệp phương sai giữa lợi suất log hàng ngày của S&P 500 và NASDAQ.

Tất cả các giá trị đều dương, chỉ ra một mối quan hệ tích cực (cùng chiều) giữa lợi suất của các tài sản này. Điều này có nghĩa là khi lợi suất của một tài sản là số dương, lợi suất của các tài sản khác cũng có xu hướng dương.

3.3.2 Sử dụng công thức hệ số tương quan Pearson

Hệ số tương quan Pearson là một thước đo sức mạnh của mối quan hệ tuyến tính giữa hai biến số. Công thức như sau:

$$\rho_{X,Y} = \frac{\text{cov}(X,Y)}{\sigma_X \sigma_Y}$$

trong đó

cov = Hiệp phương sai σ_X = Độ lệch chuẩn của X σ_Y = Độ lệch chuẩn của Y

Tương quan được sử dụng trong thống kê để định lượng mức độ mà hai biến số di chuyển trong một mối quan hệ tuyến tính với nhau. Tương quan có thể dao động từ -1 đến 1 (bao gồm cả hai đầu mút). Tương quan bằng 1 có nghĩa là tương quan hoàn hảo; các biến số di chuyển chính xác song hành cùng nhau. Sự song hành hoàn hảo đối với tương quan dương có nghĩa là nếu chúng ta biết biến X tăng, thì biến Y cũng tăng. Tương quan bằng -1 chỉ ra tương quan nghịch hoàn hảo. Đây cũng là sự song hành hoàn hảo, nhưng theo hướng ngược lại. Ở đây, nếu chúng ta biết biến X tăng, thì biến Y giảm. Tương quan bằng 0 chỉ ra rằng không có mối quan hệ tuyến tính nào có thể phân biệt được giữa hai biến số; do đó, sẽ không thể đưa ra dự đoán về một biến nếu biết biến kia. Trong trường hợp này, nếu chúng ta biết biến X tăng, thì biến Y có khả năng tăng hoặc giảm như nhau.

Một lợi ích của tương quan so với hiệp phương sai là tương quan được giới hạn từ -1 đến 1 trong khi hiệp phương sai có thể từ -vô cực đến +vô cực. Điều này làm cho hiệp phương sai trở thành một thống kê khó hiểu hơn về mặt trực giác. Tương quan cũng có tính tỷ lệ, điều này sẽ được hiển thị trong video bên dưới.

Hãy ghi nhớ rằng rất nhiều mô hình và khái niệm tài chính giả định một mức tương quan không đổi, nhưng điều này hiếm khi xảy ra. Tương quan thay đổi theo thời gian và thậm chí có khả năng thay đổi nếu bạn điều chỉnh khoảng thời gian mà từ đó bạn đang đo lường sự tương quan.

Khi so sánh các mức tương quan của các tài sản mà chúng ta đã và đang sử dụng cho đến nay, bạn có thể thấy nó vẽ ra một bức tranh rõ ràng hơn so với hiệp phương sai.

```
round(df.corr(), 3)
```

```
SP500
NASDAQ
Bitcoin
```

```
SP500
1.000
0.947
0.358
```

```
NASDAQ
0.947
1.000
0.381
```


Bitcoin
0.358
0.381
1.000

Tất cả các biến số đều có mối quan hệ tích cực (dương), điều mà chúng ta đã thấy với ma trận hiệp phương sai trước đó. Ở đây, chúng ta cũng có thể thấy sức mạnh của các mối quan hệ: S&P 500 có tương quan mạnh với NASDAQ vì chúng ta đã thu được hệ số tương quan Pearson là 0.947. Mối quan hệ giữa NASDAQ và Bitcoin vẫn là tích cực (dương) nhưng yếu hơn nhiều với hệ số tương quan Pearson là 0.381.

Khi chúng ta vẽ biểu đồ lợi suất giữa các biến số này, chúng ta có thể thấy bằng chứng về các mức tương quan ở trên, một cách trực quan:

```
# Tạo biểu đồ phân tán kèm đường hồi quy
chart = sns.regplot(x="SP500", y="NASDAQ", data=df).set(
    title="Hình 3: Lợi suất Hàng ngày S&P 500 so với Lợi suất NASDAQ"
)

# Thêm đường thẳng đứng tại x=0 và đường nằm ngang tại y=0
plt.axvline(0, 0, 1, dash_capstyle="butt", linestyle="--", color="grey")
plt.plot([min(df.SP500), max(df.SP500)], [0, 0], linestyle="--", color="grey");
```




Hình 3: Lợi suất hàng ngày S&P 500 so với lợi suất NASDAQ

Biểu đồ này hiển thị một cách trực quan mối quan hệ giữa lợi suất log hàng ngày của S&P 500 và NASDAQ, bao gồm một đường hồi quy (regression line) đại diện cho mối quan hệ tuyến tính phù hợp nhất giữa hai biến số. Các đường đứt nét tại $x=0$ và $y=0$ giúp hình dung các mức lợi suất dương và âm cho mỗi tài sản. Mối quan hệ này cho thấy tương quan gần như hoàn hảo.

Bây giờ chúng ta hãy trực quan hóa mối quan hệ giữa lợi suất hàng ngày của S&P 500 và Bitcoin.

```
# Tạo biểu đồ phân tán kèm đường hồi quy
sns.regplot(x="SP500", y="Bitcoin", data=df).set(
    title="Hình 4: Lợi suất Hàng ngày S&P 500 so với Lợi suất Bitcoin"
)

# Thêm đường thẳng đứng tại x=0 và đường nằm ngang tại y=0
plt.axvline(0, 0, 1, dash_capstyle="butt", linestyle="--", color="grey")
plt.plot([min(df.SP500), max(df.SP500)], [0, 0], linestyle="--", color="grey");
```



Hình 4: Lợi suất hàng ngày S&P 500 so với lợi suất Bitcoin

Mối quan hệ ở đây phân tán hơn nhiều mặc dù mối quan hệ vẫn hơi tích cực (dương). Chúng được vẽ bằng phương thức `regplot()` của seaborn, phương thức này cũng hiển thị các khoảng tin cậy (confidence intervals) xung quanh đường hồi quy, như được thấy ở trên.

3.3.3 Tỷ số Sharpe

Có bất kỳ thống kê nào chúng ta có thể sử dụng để định lượng không chỉ lợi suất mà còn cả rủi ro không? Đối với điều này, chúng ta chuyển sang tỷ số Sharpe.

Tỷ số Sharpe (Sharpe ratio) cho phép nhà đầu tư hiểu được mối quan hệ giữa lợi suất của một khoản đầu tư và sự biến động của nó. Công thức như sau:

$$\text{Sharpe Ratio} = \frac{R_p - R_f}{\sigma_p}$$

trong đó

R_p = Lợi suất của danh mục đầu tư R_f = Lãi suất phi rủi ro σ_p = Độ lệch chuẩn của danh mục đầu tư

Trong nhiều trường hợp khi lãi suất quá thấp, các nhà đầu tư sẽ giả định lãi suất phi rủi ro bằng 0, làm cho tỷ số trở thành:

$$\text{Sharpe Ratio} = \frac{R_p}{\sigma_p}$$

Bạn có nhận thấy điều gì về mẫu số không? Vâng, đúng vậy: chúng ta sử dụng độ lệch chuẩn ở đây để đại diện cho rủi ro.

Thước đo này được sử dụng như một cách chia tỷ lệ lợi suất của một khoản đầu tư tùy thuộc vào mức độ rủi ro được thực hiện. Nói cách khác, độ lệch chuẩn càng cao, lợi suất được điều chỉnh theo rủi ro (risk-weighted return) càng giảm. Hãy sử dụng cùng một ví dụ như trên với lợi suất hàng ngày của S&P 500 và Bitcoin trong 5 năm qua.

```
# Tính tỷ số Sharpe cho cả S&P 500 và Bitcoin
Sharpe_Ratio_SP500 = df["SP500"].mean() / df["SP500"].std()
Sharpe_Ratio_Bitcoin = df["Bitcoin"].mean() / df["Bitcoin"].std()

# In kết quả
print("Sharpe Ratio of S&P 500: ", round(Sharpe_Ratio_SP500, 5))
print("Sharpe Ratio of Bitcoin: ", round(Sharpe_Ratio_Bitcoin, 5))
```

```
Sharpe Ratio of S&P 500: 0.03699
Sharpe Ratio of Bitcoin: 0.03498
```

Dựa trên những kết quả này, S&P 500 có Tỷ số Sharpe cao hơn một chút (0.03699) so với Bitcoin (0.03498). Điều này gợi ý rằng S&P 500 đã mang lại mức lợi suất được điều chỉnh theo rủi ro tốt hơn một chút trong khoảng thời gian được phân tích.

Một sai sót lớn của tỷ số Sharpe là nó sử dụng độ lệch chuẩn của lợi suất ở mẫu số, điều này giả định rằng lợi suất có phân phối chuẩn. Điều này có thể không phải lúc nào cũng đúng - và thực tế hiếm khi xảy ra. Điều này sẽ được khám phá thêm trong một bài học tương lai.

3.4 BÁN PHƯƠNG SAI

Làm thế nào chúng ta có thể tinh chỉnh tỷ số Sharpe để đưa ra một thước đo thậm chí còn tốt hơn cho lợi suất điều chỉnh theo rủi ro? Bán phương sai (Semivariance) là câu trả lời. Bán phương sai, còn được gọi là rủi ro giảm giá (downside risk), là một phiên bản tinh tế hơn của

độ lệch chuẩn. Độ lệch chuẩn xem xét cả rủi ro tăng giá (upside risk) và giảm giá của một khoản đầu tư. Hầu hết các nhà đầu tư, trừ khi bạn đang giao dịch bán khống (short), quan tâm nhiều hơn đến rủi ro giảm giá so với rủi ro tăng giá. Nói cách khác, nếu bạn đã mua một cổ phiếu và đang xem xét tỷ số Sharpe, bạn sẽ không muốn con số này bị phạt (penalize) vì cổ phiếu đó tăng giá mạnh đến mức nào. Hầu hết thời gian, một nhà đầu tư sẽ quan tâm nhiều hơn đến rủi ro giảm giá của một cổ phiếu.

$$\text{Semivariance} = \frac{1}{n} \sum_{r_i < \bar{r}} (r_i - \bar{r})^2$$

trong đó

r_i = giá trị của một quan sát $\bar{r}$ = trung bình của tất cả các quan sát n = số lượng quan sát

Có thể coi bán phương sai là một công cụ ước tính phương sai của các mức lợi suất thấp hơn mức trung bình của chúng. Điều này có thể được sử dụng để ước lượng mức lỗ trung bình mà một danh mục đầu tư có thể gánh chịu, giả định phân phối của lợi suất là phân phối chuẩn.

Ngược lại, nếu chúng ta bán khống (short) một chứng khoán, chúng ta vẫn có thể sử dụng bán phương sai, nhưng lần này, nó sẽ tập trung vào các mức lợi suất dương. Nếu chúng ta bán khống, sự sụt giảm về giá sẽ tạo ra phần tăng (upside), do đó chúng ta sẽ không muốn phạt sự biến động này trong tỷ số Sharpe của mình. Tuy nhiên, nếu có những độ lệch lớn theo hướng đi lên, thì điều này sẽ đóng góp vào bán phương sai. Tóm lại, bán phương sai sử dụng lợi suất dương hoặc lợi suất âm.

Bây giờ chúng ta hãy tính toán bán phương sai cho cả S&P 500 và Bitcoin:

```
# Tính lợi suất trung bình của từng tài sản
sp500mean = df["SP500"].mean()
BTCmean = df["Bitcoin"].mean()

# Tính bán phương sai của từng tài sản
sp500_semivariance = ((df[df["SP500"] < sp500mean]["SP500"] - sp500mean) ** 2).mean()
BTC_semivariance = ((df[df["Bitcoin"] < BTCmean]["Bitcoin"] - BTCmean) ** 2).mean()

# In kết quả bán phương sai
print("Semivariance of S&P 500: ", round(sp500_semivariance, 5))
print("Semivariance of Bitcoin: ", round(BTC_semivariance, 5))
```

```
Semivariance of S&P 500: 0.00021
Semivariance of Bitcoin: 0.00181
```

Đầu ra này cho thấy Bitcoin có bán phương sai cao hơn nhiều (0.00181) so với S&P 500 (0.00021). Điều này chỉ ra rằng Bitcoin đã trải qua các sai lệch âm lớn hơn đáng kể so với mức lợi suất trung bình của nó, cho thấy rủi ro giảm giá cao hơn.

3.5 LỢI SUẤT CỔ PHIẾU ĐƯỢC PHÂN PHỐI NHƯ THỂ NÀO?

Nhiều mô hình và lý thuyết xoay quanh cổ phiếu giả định một phân phối chuẩn (normal distribution). Chúng ta sẽ cố gắng xác định điều đó ở đây bằng một phân tích dựa trên dữ liệu. Các đặc tính của một phân phối Gaussian như sau:

- Trung bình (mean), trung vị (median) và yếu vị (mode) đều như nhau.

- Dữ liệu đối xứng, có nghĩa là có số lượng quan sát bằng nhau ở cả hai phía của mức trung bình.
- Trong dữ liệu có phân phối chuẩn, 68.25% tất cả các trường hợp rơi vào phạm vi +/- một độ lệch chuẩn từ mức trung bình, 95% tất cả các trường hợp rơi vào phạm vi +/- hai độ lệch chuẩn từ mức trung bình và 99.7% tất cả các trường hợp rơi vào phạm vi +/- ba độ lệch chuẩn từ mức trung bình.

Hãy bắt đầu bằng cách lấy 20 năm dữ liệu giá hàng ngày cho S&P 500. Chúng ta sẽ sử dụng các phương pháp tương tự như chúng ta đã sử dụng trong một vài bài học trước để lấy dữ liệu này và sẽ tính toán lợi suất log ở đây.

Một cách nhanh chóng để làm điều này là xác định xem chúng ta có bao nhiêu điểm dữ liệu ở hai bên của mức trung bình ở đây. Chúng ta có hơn 5,000 điểm dữ liệu một chút. Đoạn code dưới đây lấy số lượng điểm dữ liệu lớn hơn mức trung bình và chia nó cho tổng số điểm dữ liệu. Điều này sẽ cho chúng ta tỷ lệ phần trăm các điểm dữ liệu lớn hơn mức trung bình.

```
# Ngày bắt đầu và ngày kết thúc
start = datetime.date(2004, 8, 1)
end = datetime.date(2024, 8, 1)

# Lấy dữ liệu
# Để chuyển đổi giữa tải dữ liệu trực tiếp và tải dữ liệu cục bộ,
# bỏ ghi chú dòng mong muốn và ghi chú dòng còn lại.
# Lấy dữ liệu Amazon, Ford và Bitcoin
#prices = pd.DataFrame(yfin.download(["^GSPC"], start, end, auto_adjust = False)["Adj Close"])
prices = pd.read_csv('FD_M2_L2_stocks_data.csv', index_col='Date', parse_dates=True)\
    .loc[start:end].reindex(columns=["^GSPC"])

# Loại bỏ giá trị null của các ngày cuối tuần và đổi tên cột để tên gọi trực quan hơn
prices.dropna(inplace = True)
prices = prices.rename(columns={"^GSPC": "SP500"})
df = np.log(prices) - np.log(prices.shift(1))
df = df.iloc[1:, 0]
```

3.5.1 Lợi suất có đối xứng không?

Một cách nhanh chóng để làm điều này là xác định xem chúng ta có bao nhiêu điểm dữ liệu ở hai bên của mức trung bình ở đây. Chúng ta có hơn 5,000 điểm dữ liệu ở đây một chút. Đoạn code dưới đây lấy số lượng điểm dữ liệu lớn hơn mức trung bình và chia nó cho tổng số điểm dữ liệu. Điều này sẽ cho chúng ta tỷ lệ phần trăm các điểm dữ liệu lớn hơn mức trung bình.

```
(len(df[df.SP500 > df.SP500.mean()])) / (len(df))
```

```
0.5235446056030201
```

Đầu ra sẽ là một con số nằm giữa 0 và 1, đại diện cho tỷ lệ lợi suất hàng ngày của S&P 500 lớn hơn lợi suất trung bình. Điều này có thể cho bạn một ý tưởng về độ xiên (skewness) của phân phối lợi suất. Giá trị gần 0.5 gợi ý một phân phối gần như đối xứng, trong khi giá trị lớn hơn đáng kể so với 0.5 gợi ý độ xiên âm (nhiều mức lợi suất nằm dưới mức trung bình hơn).

Chúng ta đang nhận được khoảng 52.6% điểm dữ liệu lớn hơn mức trung bình, điều này cho thấy chúng ta có độ xiên hơi âm đối với tập dữ liệu này. Chúng ta không thể loại trừ lợi


suất đối xứng dựa trên điều này vì nó chỉ là một mẫu dữ liệu và khá gần với mức 50%. Điều này gây khó khăn để nói chắc chắn liệu lợi suất của S&P 500 có đối xứng hay không, nhưng ở đây vẫn có thể đưa ra một giả định hợp lý.

3.5.2 Biến động có không đối không?

Đoạn code sau tính toán và vẽ biểu đồ độ lệch chuẩn trượt (rolling standard deviation) 50 ngày của lợi suất log S&P 500, cung cấp một hình ảnh trực quan về sự biến động theo thời gian.

```
# Tính độ lệch chuẩn trượt
vols = pd.DataFrame(df.SP500.rolling(50).std()).rename(columns={"SP500": "S&P 500 STD"})

# đặt kích thước hình và vẽ các độ lệch chuẩn trượt
plt.figure(figsize=(12, 5))
sns.lineplot(
    x="Date",
    y="S&P 500 STD",
    data=vols,
    label="S&P 500 50 day standard deviation rolling avg",
)
plt.show()
```



Hình 5: Độ lệch chuẩn trượt 50 ngày của lợi suất S&P 500

Từ biểu đồ trên, có thể thấy rõ rằng biến động hoàn toàn không phải là không đổi. Điều này thêm một lớp phức tạp khác vào việc lập mô hình lợi suất cổ phiếu, đặc biệt là trong nhiều mô hình giả định mức biến động không đổi.

3.6 LỢI SUẤT CỔ PHIẾU CÓ PHÂN PHỐI CHUẨN KHÔNG?


Phân phối chuẩn là một trong những phân phối phổ biến nhất được sử dụng trong việc lập mô hình các biến ngẫu nhiên. Quả thực, nhiều hiện tượng trong khoa học tự nhiên và xã hội có thể được lập mô hình bằng phân phối chuẩn. Một trong những lợi thế lớn của phân phối chuẩn là sự đơn giản của nó. Chúng ta có thể mô tả hoàn toàn một phân phối chuẩn thông

qua hai con số: một cho tâm của phân phối và một cho độ bất định (uncertainty) xung quanh tâm đó. Con số đầu tiên đề cập đến mức trung bình, và con số thứ hai đề cập đến độ lệch chuẩn.

Khi chúng ta có hai con số này, chúng ta có thể đưa ra các suy luận, ước lượng các phân vị, tính toán xác suất để một điểm rơi vào một vùng, v.v. Nếu dữ liệu của chúng ta được biểu diễn tốt bằng phân phối chuẩn, thì chúng ta có thể tự tin sử dụng mức trung bình và độ lệch chuẩn để báo cáo mức lợi suất kỳ vọng và biến động của danh mục đầu tư. Nếu dữ liệu của chúng ta không được biểu diễn tốt bằng phân phối chuẩn, thì chúng ta cần tìm các phân phối khác phù hợp hơn. Do đó, ví dụ, khi chúng ta có một phân phối lợi suất cổ phiếu, chúng ta sẽ muốn bắt đầu đánh giá này bằng cách trực quan hóa lợi suất để xem chúng có vẻ chuẩn hay không. Tất nhiên, chúng ta có thể tiếp tục điều này bằng các đánh giá định lượng hơn thông qua việc chạy các kiểm định thống kê.

Chúng ta có thể trực quan hóa dữ liệu bằng phương thức `hist()`. Chúng ta truyền vào `bins = 100` dưới dạng tham số để xác định số lượng các nhóm (buckets) để đặt dữ liệu vào. Bạn càng có nhiều bins, dữ liệu sẽ trông càng chi tiết trong một biểu đồ tần suất (histogram). Việc tăng bins quá nhiều có thể dẫn đến dữ liệu hơi nhiễu, điều này sẽ khiến việc xác định phân phối chuẩn trở nên khó khăn hơn.

```
df.hist(bins=100);
```



Hình 6: Biểu đồ tần suất (histogram) lợi suất của S&P 500, NASDAQ và Bitcoin

Biểu đồ trên trông có vẻ như nó có thể có phân phối chuẩn, nhưng chúng ta cần khoa học hơn một chút để xác định xem điều đó có thực sự đúng hay không.

3.6.1 Tiến hành kiểm định tính chuẩn

Chúng ta có thể sử dụng phương thức `normaltest()` để xác định xem dữ liệu mẫu có thể phù hợp với một phân phối chuẩn hay không. Phương thức này sử dụng kiểm định tính chuẩn của D'Agostino và Pearson, kết hợp độ xiên (skew) và độ nhọn (kurtosis) để tạo ra một kiểm định tổng thể (omnibus test) về tính chuẩn.

```
stats.normaltest((np.array(df.SP500)))
```

```
NormaltestResult(statistic=np.float64(1234.7310969195069), pvalue=np.float64(7.61288004534643e-269))
```

Đầu ra của đoạn code này bao gồm hai giá trị:

- **Thống kê (Statistic):** Một thống kê kiểm định đo lường sự sai lệch so với tính chuẩn. Các giá trị cao hơn chỉ ra sự sai lệch lớn hơn.
- **p-value:** Xác suất quan sát được dữ liệu nếu nó thực sự có phân phối chuẩn. Một p-value nhỏ (thường nhỏ hơn 0.05) gợi ý rằng dữ liệu không có phân phối chuẩn.

Đầu ra ở trên cho thấy kết quả của kiểm định tính chuẩn D'Agostino và Pearson trên dữ liệu lợi suất log S&P 500 của chúng ta. Thống kê 1234.73 là rất cao, chỉ ra một sự sai lệch đáng kể so với một phân phối chuẩn. P-value cực kỳ nhỏ (7.61e-269) cung cấp bằng chứng mạnh mẽ để bác bỏ giả thuyết không (null hypothesis) rằng dữ liệu có phân phối chuẩn. Nói một cách đơn giản hơn, kiểm định này gợi ý mạnh mẽ rằng lợi suất log hàng ngày của S&P 500 trong tập dữ liệu của chúng ta không tuân theo một phân phối chuẩn.

3.6.2 Kiểm định độ xiên và độ nhọn

Như một bước kiểm định bổ sung, chúng ta có thể kiểm định độ xiên và độ nhọn của phân phối bằng kiểm định Jarque-Bera. Thống kê kiểm định sẽ luôn lớn hơn không. Thống kê kiểm định càng xa không, thì dữ liệu mẫu càng có nhiều khả năng không khớp với phân phối chuẩn.

May mắn cho chúng ta, Python có một thư viện khác để chúng ta sử dụng ở đây, điều này thực sự đơn giản hóa phân tích. Từ thư viện `scipy.stats`, chúng ta có thể áp dụng trực tiếp phương thức `jarque_bera()` vào dữ liệu của mình để nhận được thống kê kiểm định.

```
stats.jarque_bera((np.array(df.SP500))).pvalue
```

```
np.float64(0.0)
```

Một p-value nhỏ (thường nhỏ hơn 0.05) chỉ ra rằng dữ liệu có khả năng không được phân phối chuẩn. Đầu ra này chỉ ra rằng p-value từ kiểm định Jarque-Bera là 0.0 (hoặc cực kỳ gần bằng không). Điều này gợi ý mạnh mẽ rằng lợi suất log hàng ngày của S&P 500 trong tập dữ liệu của bạn không có phân phối chuẩn.

3.6.3 Phân phối Gaussian của chúng ta đổ vỡ ở đâu?

Theo kiểm định tính chuẩn, dữ liệu của chúng ta không có phân phối chuẩn mặc dù biểu đồ tần suất trông có vẻ như vậy. Vậy tại sao dữ liệu lại trượt kiểm định tính chuẩn? Câu trả lời có thể là do đuôi béo (fat tails). Đuôi béo về cơ bản có nghĩa là các sự kiện cực đoan (cách mức trung bình ± 3 độ lệch chuẩn) có nhiều khả năng xảy ra hơn so với những gì phân phối chuẩn ngụ ý.

Để xác định xem một con số cụ thể cách mức trung bình bao nhiêu độ lệch chuẩn, chúng ta cần sử dụng

$$\frac{X - \bar{X}}{\text{Sample standard deviation}}$$

Hãy thực hiện điều này cho mức tối thiểu (min) và tối đa (max) của dữ liệu mẫu:

```
# lợi suất log hàng ngày nhỏ nhất và lớn nhất
dfMax = df.SP500.max()
dfMin = df.SP500.min()

# In lợi suất log hàng ngày lớn nhất và nhỏ nhất
print("Maximum return of sample data is: ", round(dfMax, 5))
print("Minimum return of sample data is: ", round(dfMin, 5))
print(' -----')

# Tính số độ lệch chuẩn so với lợi suất trung bình
num_dev_max = (df.SP500.max() - df.SP500.mean()) / df.SP500.std()
num_dev_min = (df.SP500.min() - df.SP500.mean()) / df.SP500.std()

# In num_dev_max và num_dev_min
print("Number of standard deviations from the mean for the maximum return: ", round(num_dev_max, 5))
print("Number of standard deviations from the mean for the minimum return: ", round(num_dev_min, 5))
```

```
Maximum return of sample data is: 0.10957
Minimum return of sample data is: -0.12765
-----
Number of standard deviations from the mean for the maximum return: 9.0497
Number of standard deviations from the mean for the minimum return: -10.60025
```

Đầu ra này cung cấp những hiểu biết có giá trị về phân phối lợi suất log hàng ngày của S&P 500, đặc biệt làm nổi bật sự hiện diện của các giá trị ngoại lệ (outliers) hoặc đuôi béo:

- Lợi suất Tối đa và Tối thiểu: Mức lợi suất hàng ngày tối đa xấp xỉ 10.957% và mức lợi suất hàng ngày tối thiểu xấp xỉ -12.765% cho thấy phạm vi lợi suất được quan sát trong dữ liệu của chúng ta.
- Điểm Z (Z-scores): Điểm Z cho mức lợi suất tối đa và tối thiểu lần lượt là 9.05 và -10.6. Đây là những điểm Z cực kỳ cao, chỉ ra rằng cả mức lợi suất tối đa và tối thiểu đều là những giá trị ngoại lệ đáng kể, cách rất xa mức trung bình xét về độ lệch chuẩn.

Trong một phân phối chuẩn, bạn sẽ hiếm khi quan sát thấy các điểm dữ liệu cách mức trung bình hơn 3 độ lệch chuẩn. Những điểm Z cao này gợi ý rằng lợi suất hàng ngày của S&P 500 có phần đuôi béo hơn so với một phân phối chuẩn, nghĩa là các sự kiện cực đoan (lợi suất

dương hoặc âm lớn) có nhiều khả năng xảy ra hơn so với những gì được kỳ vọng theo tính chuẩn.

Thông tin này rất quan trọng đối với việc lập mô hình và quản trị rủi ro, vì việc dựa vào giả định về tính chuẩn có thể dẫn đến việc đánh giá thấp xác suất của các sự kiện cực đoan và các khoản lỗ tiềm ẩn.

Những độ lệch chuẩn này là khổng lồ khi so sánh với phân phối chuẩn. Chúng ta có thể thấy điều này một cách phân tích (analytically) khi chúng ta điền điểm z vào phương thức `norm.cdf()` để xác định xác suất giá trị này có thể xuất hiện trong một phân phối chuẩn:

```
stats.norm.cdf(-10.60)
```

```
np.float64(1.4899011272964664e-26)
```

Điều này ngụ ý rằng cơ hội chúng ta có thể có một biến động thấp đến mức -12.77% là $1.49e-26$. Xác suất này thấp đến mức chúng ta sẽ không bao giờ kỳ vọng một sự kiện như thế này xảy ra trong đời mình. Chúng ta có nhiều sự kiện như thế này, như được minh họa bằng mức tối thiểu và tối đa.

Tiến xa hơn với ý tưởng này, dựa trên bảng phân phối chuẩn z, chúng ta sẽ kỳ vọng 99.7% các điểm dữ liệu của chúng ta nằm trong phạm vi ± 3 độ lệch chuẩn tính từ mức trung bình. Hãy xác định điều này cho dữ liệu mẫu của chúng ta. Trước tiên, chúng ta cần tìm các giá trị giới hạn ở mức ± 3 độ lệch chuẩn:

```
# Tính các cận trên và cận dưới
upper = (3 * df.SP500.std()) + df.SP500.mean()
lower = (-3 * df.SP500.std()) + df.SP500.mean()

# In kết quả
print("Upper bound: ", round(upper, 5))
print("Lower bound: ", round(lower, 5))
```

```
Upper bound: 0.03654
Lower bound: -0.0359
```

Hai tính toán trên sẽ ngụ ý rằng 99.7% tất cả các điểm dữ liệu của chúng ta nên nằm giữa -0.0359 và 0.03654.

Vì chúng ta có 5,031 điểm dữ liệu, chúng ta sẽ kỳ vọng khoảng 15 điểm (tức là .03% của 5,031) trong số đó nằm ngoài phạm vi đó nếu giả định về tính chuẩn được giữ vững. Bây giờ hãy xem thực tế chúng ta có bao nhiêu điểm. Hãy lọc DataFrame `df` để chọn các hàng mà lợi suất log hàng ngày của S&P 500 nằm ngoài phạm vi của giới hạn trên (upper bound) và giới hạn dưới (lower bound). Sau đó, chúng ta sẽ đếm số lượng các điểm dữ liệu rơi vào phạm vi này:

```
# Tính số điểm dữ liệu
len(df[(df["SP500"] < lower) | (df["SP500"] > upper)])
```

Đó là một số lượng giá trị ngoại lệ (outliers) đáng kể nếu xem xét rằng trong một phân phối chuẩn, bạn sẽ kỳ vọng chỉ khoảng 0.3% các điểm dữ liệu rơi ra ngoài phạm vi được xác định bởi 3 độ lệch chuẩn từ mức trung bình.

Phát hiện này tiếp tục hỗ trợ kết luận từ các kiểm định tính chuẩn rằng lợi suất log hàng ngày của S&P 500 không có phân phối chuẩn và có biểu hiện đuôi béo (fat tails). Sự hiện diện của các giá trị ngoại lệ này làm nổi bật tầm quan trọng của việc xem xét các phân phối thay thế và các thước đo rủi ro thay thế khi lập mô hình và phân tích dữ liệu tài chính.

3.7 CÁC PHÂN PHỐI PHI GAUSSIAN (NON-GAUSSIAN DISTRIBUTIONS)


Một phân phối thay thế tiềm năng mà chúng ta có thể sử dụng để dự báo lợi suất cổ phiếu là phân phối t của Student (Student's t-distribution). Phân phối này rất giống với phân phối chuẩn ngoại trừ việc nó có đuôi nặng hơn (heavier tails). Về mặt lý thuyết, điều này có vẻ hoàn hảo cho lợi suất hàng ngày dựa trên những gì chúng ta đã thấy cho đến thời điểm này.

Hãy tiến hành kiểm tra trực quan phân phối dữ liệu của chúng ta bằng cách xếp chồng phân phối chuẩn lên ước lượng mật độ hạt nhân (kernel density estimation - KDE) của lợi suất S&P 500:

```
# Lấy mẫu từ phân phối chuẩn
np.random.seed(222)
normal_dist = stats.norm.rvs(size=len(df["SP500"]), loc = df["SP500"].mean(), scale = df["SP500"].std())

# Tạo thêm một cột trong df để dùng chức năng vẽ KDE của pandas
df['Normal Sample'] = normal_dist

# Vẽ các biểu đồ KDE
df[['SP500', 'Normal Sample']].plot(kind = 'kde', xlim = (-0.1, 0.1), figsize = (12,4));
```



Hình 7: So sánh KDE của lợi suất S&P 500 với mẫu rút từ phân phối chuẩn

Lợi suất của S&P 500 có vẻ có đỉnh nhọn hơn nhiều (leptokurtic). Một phân phối leptokurtic (đỉnh nhọn) có đuôi béo hơn và đỉnh nhọn hơn so với phân phối chuẩn. Theo định nghĩa, các phân phối leptokurtic có độ nhọn (kurtosis) lớn hơn 3.


```
df.SP500.kurt()
```

```
np.float64(13.18083916908493)
```

Thật vậy, độ nhọn của S&P 500 lớn hơn đáng kể so với 3, xác nhận rằng phân phối lợi suất log hàng ngày của S&P 500 là rất nhọn (highly leptokurtic).

Bây giờ, hãy kiểm tra xem phần đuôi của S&P 500 có béo hơn phần đuôi của một phân phối chuẩn hay không. Đoạn code sau tạo ra một biểu đồ ước lượng mật độ hạt nhân (KDE) để so sánh các đuôi của lợi suất log hàng ngày thực tế của S&P 500 với các đuôi của mẫu phân phối chuẩn được tạo ra. Nó tập trung vào đuôi bên trái (lợi suất âm) bằng cách thiết lập các giới hạn trục x thành $(-0.075, -0.04)$.

```
# Quan sát phần đuôi
df[['SP500', 'Normal Sample']].plot(kind = 'kde', xlim = (-0.075, -0.04), ylim = (-1, 2), figsize = (12,4));
```




Hình 8: KDE lợi suất S&P 500 và mẫu chuẩn, phóng to vào đuôi trái

Biểu đồ thu được cho thấy trực quan sự khác biệt ở phần đuôi của hai phân phối. Chúng ta quan sát thấy lợi suất thực tế của S&P 500 có đuôi trái béo hơn phân phối chuẩn, cho thấy xác suất xảy ra các mức lợi suất âm lớn cao hơn. Hình ảnh này cung cấp thêm bằng chứng về tính không chuẩn của lợi suất S&P 500 và sự hiện diện của các đuôi béo.

Ở giai đoạn này, chúng ta sẽ hiệu chỉnh các tham số của phân phối t của Student (Student's t-distribution) bằng phương pháp ước lượng hợp lý cực đại (Maximum Likelihood Estimation, MLE) để phân phối khớp sát với dữ liệu quan sát được. Đoạn code sau khớp một phân phối t của Student vào lợi suất log hàng ngày của S&P 500 bằng **ước lượng hợp lý cực đại (MLE)**, sau đó tạo biểu đồ KDE để so sánh phân phối t đã khớp với dữ liệu thực tế.

```
# Khớp phân phối t bằng MLE
params = stats.t.fit(df.SP500)

# Chúng ta vẽ phân phối đã khớp cùng với KDE của dữ liệu
df['t-Sample *Fitted*'] = stats.t.rvs(*params, size = len(df))
df[['SP500', 't-Sample *Fitted*']].plot(kind = 'kde', figsize = (12,4), xlim = (-0.1, 0.1));
```




Hình 9: KDE lợi suất S&P 500 và mẫu phân phối t đã khớp

Qua quan sát trực quan, có thể thấy rõ rằng dữ liệu tổng hợp được sinh ra từ phân phối t của Student đã khớp cho ra một mức xấp xỉ dữ liệu thực tế chính xác hơn so với những gì chúng ta có từ phân phối chuẩn.

Hãy kiểm tra lại phần đuôi một lần nữa. Chúng ta sẽ lại phóng to để quan sát mức độ gần nhau giữa đuôi trái của lợi suất log hàng ngày thực tế của S&P 500 và đuôi trái của phân phối t của Student đã khớp:

```
# Vẽ vùng đuôi trái
df[['SP500', 't-Sample *Fitted*']].plot(kind = 'kde', figsize = (12,4), xlim = (-0.075, -0.04), ylim = (-1, 2));
```



Hình 10: KDE lợi suất S&P 500 và mẫu phân phối t đã khớp, phóng to vào đuôi trái

Lần này, phần đuôi dường như được phân phối t giải thích tốt hơn. Ở đây, chúng ta có thể quan sát thấy phân phối t đã khớp nắm bắt đuôi béo của lợi suất S&P 500 chính xác hơn phân phối chuẩn. Điều này càng cho thấy sự phù hợp của phân phối t khi mô hình hóa dữ liệu tài chính có đuôi béo và khả năng xảy ra các sự kiện cực đoan.

3.8 KẾT LUẬN

Bài học này đã đề cập đến các chỉ số lợi suất và biến động ở mức bề mặt để so sánh các cổ phiếu. Chúng ta cũng đã thảo luận về các thước đo rủi ro giảm giá và những cách để so sánh đồng thời các tài sản tài chính khác nhau. Sau đó, chúng ta đi sâu vào các chỉ số nâng cao hơn được mô hình hóa bằng các phân phối thống kê khác nhau. Lần đầu tiên, chúng ta tập trung

vào việc so sánh dữ liệu lợi suất cổ phiếu hàng ngày với các phân phối chuẩn. Chúng ta cũng đã đề cập đến những phân phối tiềm năng khác có thể dùng để mô hình hóa dữ liệu này.

Tài liệu tham khảo

- D'Agostino, Ralph B. "An Omnibus Test of Normality for Moderate and Large Size Samples." *Biometrika*, vol. 58, no. 2, 1971, pp. 341–348, <https://doi.org/10.1093/biomet/58.2.341>.

Copyright 2024 WorldQuant University. This content is licensed solely for personal use. Redistribution or publication of this material is strictly prohibited.

ĐỌC THÊM 2: THINK STATS – PHÂN TÍCH DỮ LIỆU KHÁM PHÁ BẰNG PYTHON (MỤC 5.2–5.4)

4.1 THÔNG TIN NGUỒN

- **Nguồn:** Downey, Allen B. *Think Stats: Exploratory Data Analysis in Python*. Version 2.2.0, Green Tea Press, 2014. <https://greenteapress.com/thinkstats2/thinkstats2.pdf>
- **Phần cần đọc:** Mục 5.2–5.4 (tr. 60–66, 15 phút)

> Nguồn: thinkstats2.pdf (Downey) > Phạm vi: Mục 5.2 - 5.4


5.2 Phân phối chuẩn

Phân phối chuẩn (normal distribution), còn được gọi là phân phối Gaussian (Gaussian), thường được sử dụng vì nó mô tả nhiều hiện tượng, ít nhất là ở mức xấp xỉ. Hóa ra có một lý do chính đáng cho sự phổ biến của nó, điều mà chúng ta sẽ tìm hiểu ở Mục 14.4.

Phân phối chuẩn được đặc trưng bởi hai tham số: giá trị trung bình (mean), μ , và độ lệch chuẩn (standard deviation) σ . Phân phối chuẩn với $\mu = 0$ và $\sigma = 1$ được gọi là phân phối chuẩn tắc (standard normal distribution). Hàm phân phối tích lũy (CDF) của nó được định nghĩa bởi một tích phân không có dạng đóng, nhưng có các thuật toán để tính toán nó một cách hiệu quả. Một trong số đó được cung cấp bởi SciPy: `scipy.stats.norm` là một đối tượng đại diện cho một phân phối chuẩn; nó cung cấp một phương thức, `cdf`, để tính toán CDF của phân phối chuẩn tắc:

```
>>> import scipy.stats
>>> scipy.stats.norm.cdf(0)
0.5
```

Kết quả này là chính xác: trung vị (median) của phân phối chuẩn tắc là 0 (giống với giá trị trung bình), và một nửa các giá trị nằm dưới trung vị, vì vậy `CDF(0)` là 0.5.



Hình 5.3: CDF của các phân phối chuẩn với một loạt các tham số.

`norm.cdf` nhận các tham số tùy chọn: `loc`, tham số xác định giá trị trung bình, và `scale`, tham số xác định độ lệch chuẩn.

`thinkstats2` làm cho hàm này dễ sử dụng hơn một chút bằng cách cung cấp `EvalNormalCdf`, hàm này nhận các tham số `mu` và `sigma` và tính toán CDF tại `x`:


```
def EvalNormalCdf(x, mu=0, sigma=1):
    return scipy.stats.norm.cdf(x, loc=mu, scale=sigma)
```

Hình 5.3 cho thấy các CDF đối với các phân phối chuẩn với một loạt các tham số. Hình dạng sigmoid của các đường cong này là một đặc điểm dễ nhận biết của phân phối chuẩn.

Trong chương trước, chúng ta đã xem xét phân phối của cân nặng sơ sinh trong NSFG. Hình 5.4 cho thấy CDF thực nghiệm của cân nặng đối với tất cả trẻ sinh sống (live births) và CDF của một phân phối chuẩn có cùng giá trị trung bình và phương sai.

Phân phối chuẩn là một mô hình tốt cho tập dữ liệu này, vì vậy nếu chúng ta tóm tắt phân phối bằng các tham số $\mu = 7.28$ và $\sigma = 1.24$, sai số thu được (sự khác biệt giữa mô hình và dữ liệu) là nhỏ.

Dưới bách phân vị (percentile) thứ 10 có sự sai lệch giữa dữ liệu và mô hình; có nhiều em bé nhẹ cân hơn so với những gì chúng ta kỳ vọng ở một phân phối chuẩn. Nếu chúng ta đặc biệt quan tâm đến trẻ sinh non (preterm babies), điều quan trọng là...



Hình 5.4: CDF của cân nặng sơ sinh với mô hình chuẩn.


...phải hiểu đúng phần này của phân phối, vì vậy có thể sẽ không phù hợp nếu sử dụng mô hình chuẩn.

5.3 Biểu đồ xác suất chuẩn

Đối với phân phối mũ, và một vài phân phối khác, có những phép biến đổi đơn giản mà chúng ta có thể sử dụng để kiểm tra xem một phân phối giải tích (analytic distribution) có phải là một mô hình tốt cho một tập dữ liệu hay không.

Đối với phân phối chuẩn, không có phép biến đổi nào như vậy, nhưng có một giải pháp thay thế được gọi là biểu đồ xác suất chuẩn (normal probability plot). Có hai cách để tạo một biểu đồ xác suất chuẩn: cách khó và cách dễ. Nếu bạn quan tâm đến cách khó, bạn có thể đọc về nó tại https://en.wikipedia.org/wiki/Normal_probability_plot. Đây là cách dễ:

1. Sắp xếp các giá trị trong mẫu.
2. Từ một phân phối chuẩn tắc ($\mu = 0$ và $\sigma = 1$), tạo một mẫu ngẫu nhiên có cùng kích thước với mẫu, và sắp xếp nó.
3. Vẽ đồ thị các giá trị đã sắp xếp từ mẫu so với các giá trị ngẫu nhiên.



Hình 5.5: Biểu đồ xác suất chuẩn cho các mẫu ngẫu nhiên từ các phân phối chuẩn.

Nếu phân phối của mẫu gần với phân phối chuẩn, kết quả là một đường thẳng với điểm giao cắt (intercept) là μ và độ dốc (slope) là σ .

`thinkstats2` cung cấp `NormalProbability`, hàm này nhận một mẫu và trả về hai mảng NumPy:


```
xs, ys = thinkstats2.NormalProbability(sample)
```

`ys` chứa các giá trị đã sắp xếp từ `sample`; `xs` chứa các giá trị ngẫu nhiên từ phân phối chuẩn tắc.

Để kiểm tra `NormalProbability`, tôi đã tạo một số mẫu giả thực chất được rút ra từ các phân phối chuẩn với nhiều tham số khác nhau. Hình 5.5 cho thấy kết quả. Các đường xấp xỉ thẳng, với các giá trị ở các phần đuôi lệch nhiều hơn so với các giá trị gần giá trị trung bình.

Bây giờ hãy thử với dữ liệu thực. Dưới đây là đoạn mã để tạo một biểu đồ xác suất chuẩn cho dữ liệu cân nặng sơ sinh từ phần trước. Nó vẽ một đường màu xám đại diện cho mô hình và một đường màu xanh lam đại diện cho dữ liệu.

```
def MakeNormalPlot(weights):
    mean = weights.mean()
    std = weights.std()
    xs = [-4, 4]
    fxs, fys = thinkstats2.FitLine(xs, inter=mean, slope=std)
```



Hình 5.6: Biểu đồ xác suất chuẩn của cân nặng sơ sinh.

```
thinkplot.Plot(fxs, fys, color='gray', label='model')
xs, ys = thinkstats2.NormalProbability(weights)
thinkplot.Plot(xs, ys, label='birth weights')
```

`weights` là một Series pandas chứa cân nặng sơ sinh; `mean` và `std` là giá trị trung bình và độ lệch chuẩn.


`FitLine` nhận một chuỗi `xs`, một điểm giao cắt và một độ dốc; nó trả về `xs` và `ys` đại diện cho một đường thẳng với các tham số đã cho, được tính toán tại các giá trị trong `xs`.

`NormalProbability` trả về `xs` và `ys` chứa các giá trị từ phân phối chuẩn tắc và các giá trị từ `weights`. Nếu phân phối của `weights` là phân phối chuẩn, dữ liệu sẽ khớp với mô hình.

Hình 5.6 cho thấy kết quả đối với tất cả trẻ sinh sống, và cả đối với trẻ sinh đủ tháng (thời gian mang thai (`pregnancy length`) lớn hơn 36 tuần). Cả hai đường cong đều khớp với mô hình ở gần giá trị trung bình và lệch ở các phần đuôi. Những em bé nặng nhất thì nặng hơn so với những gì mô hình kỳ vọng, và những em bé nhẹ nhất thì nhẹ hơn.

Khi chúng ta chỉ chọn các ca sinh đủ tháng, chúng ta loại bỏ một số mức cân nặng nhẹ nhất, điều này làm giảm sự sai lệch ở phần đuôi dưới của phân phối.

Biểu đồ này gợi ý rằng mô hình chuẩn mô tả tốt phân phối...



Hình 5.7: CDF của cân nặng người lớn trên thang tuyến tính (trái) và thang log (phải).

...trong phạm vi một vài độ lệch chuẩn từ giá trị trung bình, nhưng không phải ở các phần đuôi. Liệu nó có đủ tốt cho các mục đích thực tế hay không phụ thuộc vào những mục đích đó.


5.4 Phân phối log-chuẩn

Nếu logarit của một tập hợp các giá trị có phân phối chuẩn, thì các giá trị đó có phân phối log-chuẩn (lognormal distribution). CDF của phân phối log-chuẩn giống với CDF của phân phối chuẩn, với $\log x$ được thay thế cho x .

$$CDF_{\lognormal}(x) = CDF_{\text{normal}}(\log x)$$

Các tham số của phân phối log-chuẩn thường được ký hiệu là μ và σ . Nhưng hãy nhớ rằng các tham số này không phải là giá trị trung bình và độ lệch chuẩn; giá trị trung bình của một phân phối log-chuẩn là $\exp(\mu + \sigma^2/2)$ và độ lệch chuẩn của nó rất phức tạp (xem http://wikipedia.org/wiki/Log-normal_distribution).

Nếu một mẫu có phân phối xấp xỉ log-chuẩn và bạn vẽ CDF của nó trên thang đo $\log -x$, nó sẽ có hình dạng đặc trưng của một phân phối chuẩn. Để kiểm tra xem mẫu đó khớp với mô hình log-chuẩn tốt đến mức nào, bạn có thể tạo một biểu đồ xác suất chuẩn bằng cách sử dụng logarit của các giá trị trong mẫu.



Hình 5.8: Biểu đồ xác suất chuẩn cho cân nặng người lớn trên thang tuyến tính (trái) và thang log (phải).

Như một ví dụ, hãy xem xét phân phối cân nặng người lớn, có phân phối xấp xỉ log-chuẩn.²

Trung tâm Ngăn ngừa Bệnh Mạn tính và Nâng cao Sức khỏe (National Center for Chronic Disease Prevention and Health Promotion) thực hiện một cuộc khảo sát hàng năm như một phần của Hệ thống Giám sát Yếu tố Nguy cơ Hành vi (Behavioral Risk Factor Surveillance System - BRFSS).³ Năm 2008, họ đã phỏng vấn 414.509 người trả lời và hỏi về nhân khẩu học, sức khỏe và rủi ro sức khỏe của họ. Trong số dữ liệu họ thu thập được có cân nặng tính bằng kilogram của 398.484 người trả lời.

Kho lưu trữ cho cuốn sách này có chứa CDBRFS08.ASC.gz, một tệp ASCII có độ rộng cố định chứa dữ liệu từ BRFSS, và brfss.py, dùng để đọc tệp và phân tích dữ liệu.

Hình 5.7 (trái) cho thấy phân phối của cân nặng người lớn trên thang tuyến tính...

...với một mô hình chuẩn. Hình 5.7 (phải) cho thấy cùng một phân phối đó trên thang log với một mô hình log-chuẩn. Mô hình log-chuẩn phù hợp hơn, nhưng cách biểu diễn dữ liệu này không làm cho sự khác biệt trở nên quá rõ rệt.

Hình 5.8 cho thấy các biểu đồ xác suất chuẩn đối với cân nặng người lớn, w , và đối với logarit của chúng, $\log_{10} w$. Bây giờ có thể thấy rõ rằng dữ liệu sai lệch đáng kể so với mô hình chuẩn. Mặt khác, mô hình log-chuẩn là phù hợp tốt với dữ liệu.

² Tôi đã được mách nước về khả năng này bởi một bình luận (không có trích dẫn) tại <http://mathworld.wolfram.com/LogNormalDistribution.html>. Sau đó, tôi tìm thấy một bài báo đề xuất phép biến đổi logarit và gợi ý một nguyên nhân: Penman and Johnson, "The Changing Shape of the Body Mass Index Distribution Curve in the Population," Preventing Chronic Disease, 2006 July; 3(3): A74. Trực tuyến tại <http://www.ncbi.nlm.nih.gov/pmc/articles/PMC1636707>.

³ Centers for Disease Control and Prevention (CDC). Behavioral Risk Factor Surveillance System Survey Data. Atlanta, Georgia: U.S. Department of Health and Human Services, Centers for Disease Control and Prevention, 2008.

CÁC MA TRẬN ĐẶC BIỆT CHO PHÂN TÍCH CỔ PHIẾU

LESSON NOTES

Thời gian đọc (Reading Time)	60 phút
Kiến thức trước (Prior Knowledge)	Các phép toán ma trận cơ bản, Đại số tuyến tính, Python cơ bản
Từ khóa (Keywords)	Tương quan lợi suất cổ phiếu, Ma trận đối xứng, Chéo hóa ma trận, Ma trận tam giác, Ma trận xác định dương, Phân tích Cholesky

Trong bài học này, chúng ta sẽ giới thiệu các loại ma trận khác nhau. Những ma trận này đóng vai trò quan trọng trong phân tích tài chính. Với việc hiểu rõ về các đặc điểm và phép toán của những ma trận này, bạn sẽ có một khởi đầu tốt để học nhiều kỹ thuật phân tích tài chính. Trong suốt bài học, chúng ta cũng sẽ sử dụng giá cổ phiếu và lợi suất làm ví dụ để minh họa việc sử dụng các ma trận này. Chúng ta sẽ sử dụng lợi suất cổ phiếu của Apple, Ford Motor và Walmart để giải thích các ứng dụng của các ma trận này.

5.1 1. MA TRẬN ĐỐI XỨNG (SYMMETRIC MATRICES)

5.1.1 Định nghĩa về Ma trận Đối xứng

Một **ma trận đối xứng** là một ma trận vuông mà chuyển vị (transpose) của nó giống hệt như chính ma trận đó. Một ma trận vuông là một ma trận có số hàng bằng với số cột. Ví dụ sau đây minh họa khái niệm về một ma trận đối xứng.

$$A = \begin{pmatrix} m & a & b \\ a & n & c \\ b & c & p \end{pmatrix}$$

$$A^T = \begin{pmatrix} m & a & b \\ a & n & c \\ b & c & p \end{pmatrix}$$

Trong ví dụ trên, ma trận thứ hai là chuyển vị của ma trận A . Các phần tử của ma trận gốc và chuyển vị của nó là giống nhau. Theo ký hiệu toán học, đối với ma trận A , nếu $A = A^T$,

thì A là ma trận đối xứng. Cụ thể hơn, phần tử ở vị trí (i,j) bằng với phần tử ở vị trí (j,i) đối với mọi i và j .

Dưới đây là một số tính chất chính của một ma trận đối xứng:

1. Các trị riêng (eigenvalues) của ma trận là các số thực.
2. Các vectơ riêng (eigenvectors) của ma trận trực giao (orthogonal) với nhau.
3. Ma trận có thể chéo hóa được (diagonalizable).
4. Hạng (rank) của ma trận bằng với số lượng trị riêng khác không.

Khi hai vectơ là **trực giao**, điều đó có nghĩa là các vectơ vuông góc với nhau. Nó cũng có nghĩa là tích vô hướng (inner product) của hai vectơ bằng 0. Hai vectơ này độc lập tuyến tính. Tiếp theo, chúng ta sẽ nói về khả năng chéo hóa của một ma trận đối xứng.

5.1.2 Chéo hóa Ma trận Đối xứng

Ma trận A có thể chéo hóa được nếu tồn tại một ma trận đường chéo (diagonal matrix) Λ sao cho

$$A = B\Lambda B^{-1}$$

Nếu A là một ma trận đối xứng, các giá trị trên đường chéo chính của Λ là các trị riêng của A . B là một ma trận mà các cột là các vectơ riêng của A .

Hãy xem một ví dụ về chéo hóa của một ma trận đối xứng.

Chúng ta có một ma trận đối xứng M như sau:

$$M = \begin{pmatrix} 6 & -2 & -1 \\ -2 & 6 & -1 \\ -1 & -1 & 5 \end{pmatrix}$$

Để lấy được các trị riêng, chúng ta cần đặt đa thức đặc trưng (characteristic polynomial) bằng 0, hoặc giải phương trình đặc trưng như sau:

$$|M - \lambda I| = \begin{vmatrix} 6 - \lambda & -2 & -1 \\ -2 & 6 - \lambda & -1 \\ -1 & -1 & 5 - \lambda \end{vmatrix}$$

⇓

$$(6 - \lambda)(6 - \lambda)(5 - \lambda) + (-2)(-1)(-1) + (-2)(-1)(-1) - (-1)(-1)(6 - \lambda) - (-2)(-2)(5 - \lambda) - (-1)(-1)(6 - \lambda) = 0$$

↓

$$-\lambda^3 + 17\lambda^2 - 90\lambda + 144 = -(\lambda - 8)(\lambda - 6)(\lambda - 3) = 0$$

Do đó, các trị riêng là $\lambda_1 = 8$, $\lambda_2 = 6$ và $\lambda_3 = 3$. Các vectơ riêng tương ứng như sau:

$$\nu_1 = \begin{bmatrix} -1 \\ 1 \\ 0 \end{bmatrix}, \quad \nu_2 = \begin{bmatrix} -1 \\ -1 \\ 2 \end{bmatrix}, \quad \nu_3 = \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}$$

Một điều cần chú ý là các tích vô hướng của từng cặp vectơ riêng đều bằng 0 ($\nu_1^T \nu_2 = 0$, $\nu_2^T \nu_3 = 0$, $\nu_1^T \nu_3 = 0$). Điều này có nghĩa là chúng trực giao với nhau.

Chúng ta có thể tiếp tục chuẩn hóa (normalize) các vectơ riêng thành các vectơ đơn vị như sau:

$$\omega_1 = \begin{bmatrix} -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \\ 0 \end{bmatrix}, \quad \omega_2 = \begin{bmatrix} -\frac{1}{\sqrt{6}} \\ -\frac{1}{\sqrt{6}} \\ \frac{2}{\sqrt{6}} \end{bmatrix}, \quad \omega_3 = \begin{bmatrix} \frac{1}{\sqrt{3}} \\ \frac{1}{\sqrt{3}} \\ \frac{1}{\sqrt{3}} \end{bmatrix}$$

Bây giờ chúng ta có thể viết ra ma trận đối xứng đã được chéo hóa M .

$$M = B\Lambda B^{-1}$$

trong đó

$$\Lambda = \begin{pmatrix} 8 & 0 & 0 \\ 0 & 6 & 0 \\ 0 & 0 & 3 \end{pmatrix}$$

$$B = \begin{pmatrix} -\frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{6}} & \frac{1}{\sqrt{3}} \\ \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{6}} & \frac{1}{\sqrt{3}} \\ 0 & \frac{2}{\sqrt{6}} & \frac{1}{\sqrt{3}} \end{pmatrix}$$

Bởi vì B là một ma trận trực giao, $B^T = B^{-1}$. Chúng ta cũng có thể viết ma trận đối xứng đã được chéo hóa như sau:

$$M = B\Lambda B^T$$

Việc biến đổi một ma trận đối xứng về dạng chéo hóa sẽ làm cho việc tính toán các ma trận trở nên hiệu quả hơn. Nó cũng giúp phân rã một ma trận thành các dạng đơn giản hơn để phân tích. Việc chéo hóa một ma trận cũng là một công cụ thiết yếu để giúp giải quyết vấn đề biến đổi tuyến tính (linear transformation).

Bây giờ chúng ta đã học được nhiều tính chất của các ma trận đối xứng. Hãy cùng xem xét một số ma trận đối xứng phổ biến, như ma trận hiệp phương sai (covariance matrix) và ma trận tương quan (correlation matrix). Chúng ta sẽ xem xét ma trận hiệp phương sai trước.

5.1.3 Ma trận Hiệp phương sai (Covariance Matrix)

Chúng ta đã giới thiệu ma trận hiệp phương sai trong bài học trước. Một ma trận hiệp phương sai là một ma trận vuông cung cấp các phương sai của các biến số trên đường chéo của ma trận và các hiệp phương sai giữa mỗi cặp biến số ở ngoài đường chéo. Dựa trên cấu trúc của một ma trận hiệp phương sai, nó là một ma trận đối xứng. Hãy tính toán ma trận hiệp phương sai cho lợi suất cổ phiếu của Apple, Ford Motor và Walmart làm ví dụ.

```
import datetime
import matplotlib.pyplot as plt
import numpy as np
import pandas as pd
import yfinance as yfin
import seaborn as sns
```

```
# Tải giá cổ phiếu từ Yahoo Finance và thiết lập khoảng thời gian để tải
start = datetime.date(2018, 1, 2)
end = datetime.date(2023, 12, 31)

# Lấy dữ liệu
# Để chuyển đổi giữa tải dữ liệu trực tiếp và tải dữ liệu cục bộ,
# bỏ ghi chú dòng mong muốn và ghi chú dòng còn lại.
# Lấy dữ liệu Amazon, Ford và Bitcoin
#stocks = yfin.download(["AAPL", "F", "WMT"], start, end, auto_adjust = False)["Adj Close"]
stocks = pd.read_csv('FD_M2_L3_stocks_data.csv', index_col='Date', parse_dates=True)\
    .loc[start:end].reindex(columns=["AAPL", "F", "WMT"])

stocks.head()
```

	AAPL	F	WMT
Date			
2018-01-02	40.341888	8.263115	28.973360
2018-01-03	40.334862	8.328388	29.226095
2018-01-04	40.522221	8.471979	29.252544
2018-01-05	40.983574	8.615570	29.425932
2018-01-08	40.831352	8.582937	29.860863

```
stocks.index = pd.to_datetime(stocks.index).strftime("%Y-%m-%d")
```

```
# Để tính toán lợi suất của các cổ phiếu, chúng ta cần loại bỏ các hàng NA.
stocks_returns = stocks[["AAPL", "F", "WMT"]].dropna().pct_change()
stocks_returns = stocks_returns.dropna()
stocks_returns.head()
```

	AAPL	F	WMT
Date			
2018-01-03	-0.000174	0.007899	0.008723
2018-01-04	0.004645	0.017241	0.000905
2018-01-05	0.011385	0.016949	0.005927
2018-01-08	-0.003714	-0.003788	0.014781
2018-01-09	-0.000115	-0.005323	-0.012006

Với lợi suất cổ phiếu của Apple, Ford Motor và Walmart, chúng ta có thể tính toán ma trận hiệp phương sai cho 3 lợi suất cổ phiếu này.

```
# Tính toán ma trận hiệp phương sai cho Apple, Ford Motor và Walmart
# Sử dụng np.allclose để xác minh xem ma trận có phải là ma trận đối xứng không
stock_returns_covariance_matrix = stocks_returns.cov()
print("Apple, Ford Motor and Walmart Covariance Matrix:")
print(stock_returns_covariance_matrix)
print("\nIs the covariance matrix symmetric?", np.allclose(stock_returns_covariance_matrix,
    stock_returns_covariance_matrix.T))
```

Apple, Ford Motor and Walmart Covariance Matrix:

	AAPL	F	WMT
AAPL	0.000398	0.000194	0.000103
F	0.000194	0.000668	0.000068
WMT	0.000103	0.000068	0.000199

Is the covariance matrix symmetric? True

Như chúng ta có thể thấy từ ma trận hiệp phương sai ở trên cho Apple, Ford Motor và Walmart, các phương sai của ba cổ phiếu nằm trên đường chéo của ma trận. Các hiệp phương sai của bất kỳ cặp cổ phiếu nào nằm ở ngoài đường chéo của ma trận. Ma trận hiệp phương sai này cũng là một ma trận đối xứng dựa trên định nghĩa.

5.1.4 Ma trận Tương quan (Correlation Matrix)

Theo bài học trước, tương quan là một số đo để đo lường sự cùng chuyển động (co-movement) của hai biến số trong khi loại bỏ các thang đo của chúng. Không có sự khác biệt về thang đo, chúng ta có thể so sánh các tương quan từ các cặp biến số khác nhau. Nó cũng là một ma trận đối xứng. Hãy tiếp tục với ví dụ về lợi suất cổ phiếu Apple, Ford Motor và Walmart để tính toán ma trận tương quan của chúng.

```
# Tính toán ma trận tương quan cho Apple, Ford Motor và Walmart
# Xác minh xem một ma trận tương quan có phải là ma trận đối xứng không
stock_returns_correlation_matrix = stocks_returns.corr()
print("Apple, Ford Motor and Walmart Correlation Matrix:")
print(stock_returns_correlation_matrix)
print("\nIs the correlation matrix symmetric?", np.allclose(stock_returns_correlation_matrix,
    stock_returns_correlation_matrix.T))
```

Apple, Ford Motor and Walmart Correlation Matrix:

	AAPL	F	WMT
AAPL	1.000000	0.376461	0.365246
F	0.376461	1.000000	0.185249
WMT	0.365246	0.185249	1.000000

Is the correlation matrix symmetric? True

Chúng ta có thể thấy từ ma trận tương quan ở trên rằng nó cũng là một ma trận đối xứng. Các giá trị trên đường chéo là các tương quan của 3 cổ phiếu với chính chúng. Các giá trị ngoài đường chéo là các tương quan của các cặp lợi suất cổ phiếu khác nhau. Lợi suất cổ phiếu của Apple có tương quan tương tự với cả lợi suất cổ phiếu của Ford Motor và Walmart.

Lợi suất cổ phiếu của Ford Motor và Walmart có tương quan thấp nhất trong số các cặp lợi suất cổ phiếu khác.

5.1.5 Chuyển đổi giữa Ma trận Hiệp phương sai và Ma trận Tương quan

Từ bài học trước, chúng ta đã biết rằng hiệp phương sai và tương quan có mối quan hệ như sau.

$$\text{Corr}(X, Y) = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X)} * \sqrt{\text{Var}(Y)}}$$

trong đó $\text{Cov}(X, Y)$ là hiệp phương sai của X và Y , $\text{Var}(X)$ và $\text{Var}(Y)$ là các phương sai của X và Y .

Chúng ta có thể sử dụng công thức trên để chuyển đổi giữa các ma trận hiệp phương sai và tương quan một cách dễ dàng. Hãy minh họa việc chuyển đổi bằng đoạn code sau.

```
# Chuyển đổi hiệp phương sai thành tương quan
def cov_to_corr(cov_matrix):
    d = np.sqrt(np.diag(cov_matrix))
    corr_matrix = cov_matrix / np.outer(d, d)
    return corr_matrix

# Chuyển đổi tương quan thành hiệp phương sai
def corr_to_cov(corr_matrix, std_devs):
    cov_matrix = corr_matrix * np.outer(std_devs, std_devs)
    return cov_matrix
```

```
# Sử dụng ví dụ lợi suất cổ phiếu Apple, Ford Motor và Walmart của chúng ta để minh họa việc chuyển đổi
# Tính độ lệch chuẩn của các lợi suất cổ phiếu
stocks_returns_std = stocks_returns.std()

# ví dụ chuyển đổi hiệp phương sai thành tương quan
cov_to_corr(stock_returns_covariance_matrix)
```

```
# ví dụ chuyển đổi tương quan thành hiệp phương sai
corr_to_cov(stock_returns_correlation_matrix, stocks_returns_std)
```

	AAPL	F	WMT
AAPL	0.000398	0.000194	0.000103
F	0.000194	0.000668	0.000068
WMT	0.000103	0.000068	0.000199

5.2 2. MA TRẬN TAM GIÁC (TRIANGULAR MATRIX)

Một ma trận được sử dụng phổ biến khác là ma trận tam giác. Một ma trận tam giác là một ma trận vuông mà ở đó tất cả các phần tử ở một phía của đường chéo chính đều bằng không. Có hai loại ma trận tam giác: ma trận tam giác dưới (lower triangular matrix) và ma trận tam giác trên (upper triangular matrix).

5.2.1 Ma trận Tam giác dưới

Một **ma trận tam giác dưới** là một ma trận vuông có các phần tử phía trên đường chéo chính bằng không. Đường chéo chính và các phần tử bên dưới nó có thể mang bất kỳ giá trị nào. Dưới đây là minh họa của một ma trận tam giác dưới.

$$B = \begin{pmatrix} m & 0 & 0 \\ a & n & 0 \\ b & c & p \end{pmatrix}$$

5.2.2 Ma trận Tam giác trên

Một **ma trận tam giác trên** là một ma trận vuông có các phần tử phía dưới đường chéo chính bằng không. Đường chéo chính và các phần tử phía trên nó có thể mang bất kỳ giá trị nào. Dưới đây là minh họa của một ma trận tam giác trên.

$$B = \begin{pmatrix} m & a & b \\ 0 & n & c \\ 0 & 0 & p \end{pmatrix}$$

5.2.3 Các tính chất của một Ma trận Tam giác

Dưới đây là một số tính chất chính của một ma trận tam giác:

1. Định thức là tích của các phần tử trên đường chéo.
2. Nghịch đảo của một ma trận tam giác (nếu tồn tại) cũng là ma trận tam giác.
3. Tích của hai ma trận tam giác trên (hoặc dưới) là ma trận tam giác trên (hoặc dưới).

Các tính chất trên đều rất dễ chứng minh bằng các phép toán ma trận, vì vậy chúng tôi sẽ dành những chứng minh này cho người đọc.

5.3 3. MA TRẬN ĐỐI XỨNG XÁC ĐỊNH DƯƠNG (SYMMETRIC POSITIVE DEFINITE - PD) VÀ MA TRẬN ĐỐI XỨNG BÁN XÁC ĐỊNH DƯƠNG (SYMMETRIC POSITIVE SEMI-DEFINITE - SPD)

Trong phần này, chúng ta sẽ giới thiệu hai loại ma trận quan trọng: ma trận đối xứng xác định dương (PD) và ma trận đối xứng bán xác định dương (SPD).

5.3.1 Ma trận Đối xứng Xác định Dương (PD Matrices)

Một ma trận đối xứng A được gọi là xác định dương nếu $x^T A x > 0$ với mọi vectơ khác không x .

Dưới đây là một số tính chất chính của một ma trận đối xứng xác định dương:

1. Tất cả các trị riêng của ma trận đều dương
2. Định thức của ma trận là số dương
3. Ma trận có hạng tối đa (full rank)
4. Ma trận có thể nghịch đảo được
5. Tổng và tích của hai ma trận đối xứng xác định dương cũng là một ma trận đối xứng xác định dương

Các tính chất này của các ma trận đối xứng xác định dương — hạng tối đa, định thức dương và các trị riêng dương — có liên hệ mật thiết với nhau. Những đặc điểm này làm cho các ma trận đối xứng xác định dương đặc biệt hữu ích trong nhiều bối cảnh toán học và ứng dụng khác nhau, cung cấp sự đảm bảo về tính không suy biến (non-singularity), tính ổn định và sự hội tụ trong nhiều thuật toán và phương pháp. Thông thường, một cách nhanh chóng để xác định xem một ma trận đối xứng có phải là xác định dương hay không là tính định thức của nó và kiểm tra xem định thức có dương hay không. Ví dụ, hãy xem xét ma trận đối xứng sau.

$$\begin{pmatrix} 3 & 4 \\ 4 & 5 \end{pmatrix}$$

Đây là một ma trận đối xứng. Tuy nhiên, định thức là $(3 \times 5) - (4 \times 4) = -1$, ma trận này không phải là xác định dương.

5.3.2 Ma trận Đối xứng Bán xác định Dương (SPD Matrices)

Một ma trận đối xứng A được gọi là bán xác định dương nếu $x^T A x \geq 0$ với mọi vectơ x .

Dưới đây là các tính chất chính của một ma trận đối xứng bán xác định dương:

1. Tất cả các trị riêng của ma trận đều không âm
2. Định thức của ma trận không âm
3. Ma trận có thể không có hạng tối đa
4. Ma trận không phải luôn luôn có thể nghịch đảo được

Chúng ta thường cũng sử dụng định thức của một ma trận đối xứng để nhanh chóng kiểm tra xem nó có đồng thời là một ma trận bán xác định dương hay không. Đối với ví dụ ma trận sau,

$$\begin{pmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 1 \end{pmatrix}$$

chúng ta có thể kiểm tra rằng định thức bằng 0. Do đó, ma trận này là một ma trận bán xác định dương.

Quay trở lại với các ma trận hiệp phương sai và ma trận tương quan, cả hai đều là đối xứng bán xác định dương nhưng không nhất thiết phải là đối xứng xác định dương. Đoạn code Python sau có thể được sử dụng để kiểm tra xem một ma trận là đối xứng xác định dương hay đối xứng bán xác định dương.

```
def is_positive_definite(matrix):
    return np.all(np.linalg.eigvals(matrix) > 0)

A = stock_returns_correlation_matrix

print("Is A positive definite?", is_positive_definite(A))
print("Eigenvalues:", np.linalg.eigvals(A))
print("Determinant:", np.linalg.det(A))
print("Rank:", np.linalg.matrix_rank(A))
```

```
Is A positive definite? True
Eigenvalues: [1.62523847 0.5598973 0.81486423]
Determinant: 0.7414992574989508
Rank: 3
```

```
def is_positive_seminefinite(matrix):
    return np.all(np.linalg.eigvals(matrix) >= 0)

A = stock_returns_correlation_matrix

print("Is A positive semidefinite?", is_positive_seminefinite(A))
print("Eigenvalues:", np.linalg.eigvals(A))
print("Determinant:", np.linalg.det(A))
print("Rank:", np.linalg.matrix_rank(A))
```

```
Is A positive semidefinite? True
Eigenvalues: [1.62523847 0.5598973 0.81486423]
Determinant: 0.7414992574989508
Rank: 3
```

5.4 4. PHÂN TÍCH CHOLESKY (CHOLESKY FACTORIZATION)

5.4.1 Định nghĩa về Phân tích Cholesky

Phân tích Cholesky là một phương pháp để phân rã (decompose) một ma trận đối xứng. Phân tích Cholesky phát biểu rằng một ma trận đối xứng xác định dương S có thể được phân rã như sau:

$$S = LL^T$$

trong đó L là một ma trận tam giác dưới hoặc một nhân tử Cholesky (Cholesky factor).

Hãy xem một ví dụ bằng số. Giả sử chúng ta có ma trận đối xứng xác định dương kích thước 3×3 sau.

$$S = \begin{pmatrix} s_{11} & s_{21} & s_{31} \\ s_{21} & s_{22} & s_{32} \\ s_{31} & s_{23} & s_{33} \end{pmatrix} = \begin{pmatrix} l_{11} & 0 & 0 \\ l_{21} & l_{22} & 0 \\ l_{31} & l_{32} & l_{33} \end{pmatrix} \begin{pmatrix} l_{11} & l_{21} & l_{31} \\ 0 & l_{22} & l_{32} \\ 0 & 0 & l_{33} \end{pmatrix} = LL^T$$

⇓

$$LL^T = \begin{pmatrix} l_{11}^2 & l_{11}l_{21} & l_{11}l_{31} \\ l_{21}l_{11} & l_{21}^2 + l_{22}^2 & l_{21}l_{31} + l_{22}l_{32} \\ l_{31}l_{11} & l_{21}l_{31} + l_{22}l_{32} & l_{31}^2 + l_{32}^2 + l_{33}^2 \end{pmatrix}$$

Từ các ma trận trên, chúng ta có thể lấy được các công thức sau cho ma trận tam giác dưới.

$$\begin{aligned} l_{11} &= \sqrt{s_{11}}, \\ l_{21} &= \frac{s_{21}}{l_{11}}, \quad l_{22} = \sqrt{s_{22} - l_{21}^2}, \\ l_{31} &= \frac{s_{31}}{l_{11}}, \quad l_{32} = \frac{s_{32} - l_{21}l_{31}}{l_{22}}, \quad l_{33} = \sqrt{s_{33} - l_{31}^2 - l_{32}^2} \end{aligned}$$

Để có được đáp án trên, bạn phải bắt đầu giải hàng đầu tiên của LL^T . Sau đó, bạn chuyển sang hàng thứ hai và hàng tiếp theo cho đến khi bạn giải được tất cả các phần tử trong L .

Hãy xem một ví dụ bằng số. Giả sử chúng ta có ma trận đối xứng xác định dương sau (vui lòng tự xác minh),

$$S = \begin{pmatrix} 25 & 15 & -5 \\ 15 & 18 & 0 \\ -5 & 0 & 11 \end{pmatrix}$$

Hãy tìm nhân tử Cholesky bằng cách sử dụng các phương trình trên mà chúng ta đã suy ra.

$$\begin{aligned} l_{11} &= \sqrt{25} = 5, \\ l_{21} &= \frac{15}{5} = 3, \quad l_{22} = \sqrt{18 - 9} = 3 \\ l_{31} &= \frac{-5}{5} = -1, \quad l_{32} = \frac{0 - (3)(-1)}{3} = 1, \quad l_{33} = \sqrt{11 - (-1)^2 - (1)^2} = 3 \end{aligned}$$

Do đó, nhân tử Cholesky của S là

$$L_S = \begin{pmatrix} 5 & 0 & 0 \\ 3 & 3 & 0 \\ -1 & 1 & 3 \end{pmatrix}$$

Thư viện Numpy của Python có một hàm để tính toán nhân tử Cholesky cho một ma trận. Chúng ta có thể sử dụng nó để xác minh phép tính thủ công của mình.

```
S= np.array([[25,15,-5],
             [15,18,0],
             [-5,0,11]])

L_numpy = np.linalg.cholesky(S)
print("\nNumPy Cholesky factor:")
print(L_numpy)
```

NumPy Cholesky factor:

```
[[ 5.  0.  0.]
 [ 3.  3.  0.]
 [-1.  1.  3.]]
```

Thuật toán phân tích Cholesky cải thiện đáng kể hiệu suất máy tính để giải các phương trình tuyến tính. Nó cũng có thể được sử dụng để tính nghịch đảo của một ma trận hiệu quả hơn một số phương pháp khác. Phân tích Cholesky cũng ổn định về mặt số học, làm cho nó hữu ích đối với các tính toán liên quan đến các ma trận có điều kiện kém (ill-conditioned matrices).

5.4.2 Sử dụng Phân tích Cholesky cho Mô phỏng Monte Carlo

Phân tích Cholesky rất hữu ích trong các mô phỏng Monte Carlo hoặc các tác vụ tối ưu hóa khác. Trong phần này, chúng ta sẽ sử dụng phân tích Cholesky trong một mô phỏng Monte Carlo để tạo ra các biến ngẫu nhiên có tương quan. Hãy sử dụng ma trận tương quan lợi suất cổ phiếu của Apple và Ford Motor làm ví dụ. Quá trình này bao gồm các bước sau:

1. Tính toán phân tích Cholesky của ma trận tương quan lợi suất cổ phiếu để lấy nhân tử L.
2. Tạo biến ngẫu nhiên chuẩn tắc độc lập Z.
3. Tính toán $X = LZ$ để lấy các biến ngẫu nhiên có tương quan.

Đầu tiên, hãy tính toán tương quan của lợi suất cổ phiếu Apple và Ford Motor.

```
# Tạo một dataframe mới chỉ với lợi suất cổ phiếu của Apple và Ford Motor từ dataframe ở ví dụ trước
two_stock_returns = stocks_returns[["AAPL", "F"]]
original_correlation = two_stock_returns.corr()
original_correlation
```

```
      AAPL      F
AAPL  1.000000  0.376461
F      0.376461  1.000000
```

Bây giờ, hãy triển khai mô phỏng bằng cách sử dụng phân tích Cholesky như mô tả ở trên.

```
# Tạo một hàm để tạo các mẫu ngẫu nhiên từ các biến có tương quan
def generate_correlated_samples(n_samples, correlation_matrix):
    # Tính toán phân tích Cholesky
    L = np.linalg.cholesky(correlation_matrix)

    # Tạo các mẫu chuẩn tắc độc lập
    Z = np.random.standard_normal((correlation_matrix.shape[0], n_samples))

    # Tạo các mẫu có tương quan
    X = L @ Z

    return X

# Tạo các mẫu
n_samples = 10000
X = generate_correlated_samples(n_samples, original_correlation)
X = pd.DataFrame(generate_correlated_samples(n_samples, original_correlation).T, columns = ["APPL",
        "F"])
# Tính toán tương quan của mẫu
sample_correlation = X.corr()
```

Bước tiếp theo của chúng ta là trực quan hóa kết quả từ dữ liệu gốc và dữ liệu được lấy mẫu bằng cách sử dụng mô phỏng Monte Carlo.


```
# Trực quan hóa kết quả
fig, (ax1, ax2) = plt.subplots(1, 2, figsize=(15, 6))

sns.heatmap(original_correlation, annot=True, cmap='coolwarm', vmin=-1, vmax=1, ax=ax1)
ax1.set_title('Original Correlation Matrix')
ax1.set_xlabel='', ylabel='')


sns.heatmap(sample_correlation, annot=True, cmap='coolwarm', vmin=-1, vmax=1, ax=ax2)
ax2.set_title('Sample Correlation Matrix')
ax2.set_xlabel='', ylabel='')

plt.tight_layout()
plt.show()

# Biểu đồ phân tán của lợi suất cổ phiếu Apple và Ford Motor được mô phỏng
plt.figure(figsize=(8, 6))
plt.scatter(X["APPL"], X["F"], alpha=0.1)
plt.title('Scatter Plot of the Simulated Apple and Ford Motor stock returns')
plt.xlabel('Apple')
plt.ylabel('Ford Motor')
plt.show()
```



Biểu đồ bài 3



Biểu đồ bài 3

Từ ma trận tương quan gốc và ma trận tương quan mẫu ở trên, chúng ta có thể thấy rằng các giá trị tương quan của dữ liệu gốc và dữ liệu được mô phỏng là rất gần nhau.

5.5 5. KẾT LUẬN

Trong bài học này, chúng ta đã giới thiệu một vài ma trận đặc biệt và một số công cụ đại số tuyến tính liên quan đến các ma trận này. Chúng ta đã bắt đầu với định nghĩa và các tính chất của một ma trận đối xứng và sau đó là ứng dụng của nó, đặc biệt là dạng đã chéo hóa của nó. Tiếp đó, chúng ta đã mô tả ma trận tam giác trên và ma trận tam giác dưới là gì. Chúng ta chuyển sang các ma trận đối xứng xác định dương và tiếp theo là các ma trận đối xứng bán xác định dương. Chúng ta đã kết thúc bài học bằng việc giới thiệu phân tích Cholesky. Chúng ta đã cung cấp định nghĩa và đi qua một ví dụ bằng số. Chúng ta đã kết thúc phần này với một ứng dụng của phân tích Cholesky bằng mô phỏng Monte Carlo. Tất cả các ma trận đặc biệt này sẽ đóng những vai trò quan trọng trong các công cụ phân tích tài chính mà chúng ta sẽ học trong các bài học tương lai.

Tài liệu tham khảo (References)

- Axler, Sheldon. *Linear Algebra Done Right*. 4th edition, Springer, 2024.

6

ĐỌC THÊM: MATRIX WORLD (ĐẠI SỐ TUYẾN TÍNH CHO MỌI NGƯỜI)

6.1 THÔNG TIN NGUỒN

- **Nguồn:** Hiranabe, Kenji. "Matrix World." *Linear Algebra for Everyone*. March 2023. <https://github.com/kenjihiranabe/The-Art-of-Linear-Algebra/blob/main/MatrixWorld.pdf>
- **Phần cần đọc:** Trang 2–4 (20 phút)

6.2 THẾ GIỚI MA TRẬN : BỨC TRANH VỀ MỌI MA TRẬN

Tôi rất vui khi được kể lại lịch sử của Thế giới Ma trận (Matrix World) — tác phẩm sáng tạo của Kenji Hiranabe tại Nhật Bản. Vào tháng 4 năm 2020, bạn của ông là Satomi Joba đã hỏi liệu tôi có thể gửi cho ông một tin nhắn chúc mừng sinh nhật như một bất ngờ hay không. Ông ấy đã rất vui (và vô cùng ngạc nhiên). Kenji kết hợp toán học với nghệ thuật và điện toán: ba tài năng trong một con người. Tôi mới là người phải ngạc nhiên khi ông gửi Thế giới Ma trận ở phiên bản đầu tiên — không có tên, không có nhiều mục và ý tưởng như bạn thấy bây giờ, nhưng với ý tưởng cốt lõi là trình bày sự đa dạng tuyệt vời của các ma trận.

Kể từ phiên bản đầu tiên đó, Thế giới Ma trận đã phát triển đều đặn. Nó bao gồm mọi thuộc tính (property) phù hợp và mọi phép phân rã (factorization) thể hiện thuộc tính đó. Thật thú vị khi SVD nằm ở vòng tròn ngoài cùng và ma trận đơn vị (identity matrix) nằm ở trung tâm — nó có tất cả các thuộc tính tốt: ma trận I là ma trận đường chéo (diagonal), đối xứng xác định dương (positive definite symmetric), trực giao (orthogonal), ma trận chiếu (projection), ma trận chuẩn (normal), khả nghịch (invertible) và ma trận vuông (square).

Lek-Heng Lim đã chỉ ra tính hữu dụng của các ma trận M vừa đối xứng vừa trực giao — những vị vua và cũng là những nữ hoàng. Trị riêng (eigenvalue) của chúng là 1 và -1. Chúng có dạng $M = I - 2P$ (P = ma trận chiếu đối xứng). Có một sự khớp nối hoàn hảo (neat match) giữa tất cả các ma trận M đó và tất cả các không gian con (subspace) của $\mathbb{R}^n$. Bạn có thể thấy điều gì đó thú vị (hoặc thiếu sót điều gì đó) trong Thế giới Ma trận. Chúng tôi hy vọng bạn sẽ thấy! Cảm ơn Kenji.

Gilbert Strang

6.3 DẠO BƯỚC QUA “THẾ GIỚI MA TRẬN”

Có rất nhiều loại ma trận: Đối xứng (Symmetric), Trực giao (Orthogonal), Suy biến (Singular), Khả nghịch (Invertible), Vuông (Square), Có thể chéo hóa (Diagonalizable), và nhiều loại khác nữa. Đây là một bản đồ về các phân loại này sử dụng biểu đồ Venn. Từ trên xuống dưới, tôi sẽ dẫn bạn đi qua biểu đồ này. Mọi ma trận ($m \times n$) đều có thể được phân rã thành $A = CR$ và cũng có thể được phân rã thành $A = U\Sigma V^T$.

Các ma trận vuông ($n \times n$) hoặc là Khả nghịch hoặc là Suy biến. Tính khả nghịch, được chỉ thị bằng đường chấm đi qua trung tâm, có thể được kiểm tra bằng việc xem liệu $A = LU$ có đủ các phần tử trục (full pivots) hay không, $\det(A) \neq 0$ hay tất cả các trị riêng đều khác không.

Một ma trận Khả nghịch được phân rã thành $A = QR$ sử dụng ma trận Trục giao Q (phương pháp Gram-Schmidt). Một ma trận vuông là Có thể chéo hóa nếu nó có n vector riêng độc lập.

Một ma trận Có thể chéo hóa được phân rã thành $A = X\Lambda X^{-1}$ với một ma trận trị riêng Đường chéo (Diagonal eigenvalue matrix) Λ và một ma trận vector riêng Khả nghịch X . Một ma trận Không thể chéo hóa (Non-diagonalizable) sẽ có dạng chuẩn Jordan (Jordan normal form) J của nó thay vì ma trận đường chéo Λ .

Có một danh mục quan trọng là ma trận Chuẩn (Normal) bao gồm các ma trận Đối xứng, Trục giao, Phản đối xứng (Anti-Symmetric). Một ma trận Có thể chéo hóa thành $Q\Lambda Q^{-1}$ bởi một ma trận Trục giao Q khi và chỉ khi nó là ma trận Chuẩn ($A^T A = A A^T$).

Các ma trận Đối xứng ($S = S^T$) và ma trận Trục giao ($Q^{-1} = Q^T$) là các ma trận Chuẩn quan trọng. Một số ma trận vừa Đối xứng vừa Trục giao. Chúng bao gồm các ma trận phản xạ (reflection matrices) với các trị riêng là 1 và -1.


Tất cả các trị riêng của một ma trận Trục giao đều có $|\lambda| = 1$. Tất cả các trị riêng của một ma trận Đối xứng đều là số thực. Một ma trận Đối xứng được gọi là Nửa xác định dương (Positive Semidefinite) nếu tất cả các trị riêng $\lambda \geq 0$, và Xác định dương (Positive Definite) nếu tất cả các trị riêng $\lambda > 0$.

Các ma trận Chiếu (Projection matrices) ($P^2 = P = P^T$) là Đối xứng và Nửa xác định dương, với tất cả các trị riêng là 1 hoặc 0.

Ma trận Đơn vị (Identity) là ma trận Chiếu Khả nghịch duy nhất.

$A^T A$ đối với bất kỳ ma trận A nào đều là Nửa xác định dương và là Xác định dương khi và chỉ khi các cột của A độc lập tuyến tính.

Nếu một ma trận là Khả nghịch, ma trận nghịch đảo của nó có thể được biểu diễn dưới dạng $A^{-1} = V\Sigma^{-1}U^T$. Với bất kỳ ma trận nào, ngay cả khi nó không Khả nghịch hoặc thậm chí không Vuông, đều tồn tại một giả nghịch đảo (pseudoinverse) $A^+ = V\Sigma^+U^T$.



Hình 1: Thế giới Ma trận

Các nhãn và chú thích trong biểu đồ Thế giới Ma trận:

- **Matrix World in Linear Algebra for Everyone:** Thế giới Ma trận trong “Linear Algebra for Everyone”
- **Appearing section (Mục xuất hiện):** (in Linear Algebra for Everyone) (trong “Linear Algebra for Everyone”)
- **Matrix Factorization:** Phân rã Ma trận
- **Matrix ($m \times n$):** Ma trận ($m \times n$)
 - $A = CR$ (1.4)
 - $A = U\Sigma V^T$ (7.1)
 - SVD: orthonormal basis U, V (SVD: cơ sở trực chuẩn U, V)
 - row rank = column rank (hạng hàng = hạng cột)
 - pseudoinverse for all A (giả nghịch đảo cho mọi A): $A^+ = V\Sigma^+U^T$ (3.5, 7.4)
- **Square Matrix ($n \times n$):** Ma trận vuông ($n \times n$)
- **Invertible:** Khả nghịch
 - $\det(A) \neq 0, \text{ all } \lambda \neq 0$ ($\det(A) \neq 0, \text{ mọi } \lambda \neq 0$)
 - $A = QR$ (4.4)
 - Gram-Schmidt
 - $A^{-1} = V\Sigma^{-1}U^T$

- **Singular:** Suy biến
 - at least one $\lambda = 0$, $\det(A) = 0$ (ít nhất một $\lambda = 0$, $\det(A) = 0$)
 - Triangularize (Tam giác hóa)
 - $A = LU$ (2.3)
 - U has at least one zero row (U có ít nhất một hàng không)
- **Diagonalizable:** Có thể chéo hóa
 - 6.2 $A = X\Lambda X^{-1}$
 - Diagonalize (Chéo hóa)
 - $A = XJX^{-1}$ (A7), J = Jordan form (J = dạng Jordan)
- **Normal:** Chuẩn (A5)
 - $A^T A = A A^T$
 - diagonalizable by orthogonal matrix (có thể chéo hóa bằng ma trận trực giao)
 - 6.3 $A = Q\Lambda Q^T$
- **Orthogonal:** Trực giao (4.4)
 - $Q^{-1} = Q^T$
 - all $|\lambda| = 1$ (mọi $|\lambda| = 1$)
- **Permutation:** Hoán vị (2.4)
 - permutation of I (hoán vị của I)
 - all λ are roots of 1 (mọi λ là căn của 1)
- **Symmetric:** Đối xứng (2.4)
 - $S = S^T$, all λ are real (mọi λ là số thực)
- **Positive Semidefinite:** Nửa xác định dương
 - all $\lambda \geq 0$, all $A^T A$ (mọi $\lambda \geq 0$, mọi $A^T A$)
 - $S = Q\Lambda Q^T$ (6.3)
- **Projection:** Chiếu (4.2)
 - $P^2 = P = P^T$, $\lambda = 1$ or 0 ($\lambda = 1$ hoặc 0)
- **Positive Definite:** Xác định dương (6.3)
 - all $\lambda > 0$ (mọi $\lambda > 0$)
- **Trung tâm biểu đồ:**
 - I : Identity (Đơn vị)
 - O : ma trận không (zero matrix)
 - Diagonal (Đường chéo) $\Sigma = \dots \Lambda = \dots$
- **Ghi chú góc dưới:**
 - Drawn by Kenji Hiranabe with the help of Prof. Gilbert Strang (v1.5, Mar.2th,2023)
(Vẽ bởi Kenji Hiranabe với sự trợ giúp của GS. Gilbert Strang (v1.5, ngày 2 tháng 3 năm 2023))

THỰC HÀNH ĐẠO ĐỨC VỚI DỮ LIỆU

LESSON NOTES

THỰC HÀNH ĐẠO ĐỨC VỚI DỮ LIỆU

Thời gian đọc (Reading Time)	20 phút
Kiến thức trước (Prior Knowledge)	Mô-đun 1 môn Dữ liệu Tài chính (FD), Các loại Dữ liệu, Thuộc tính của Dữ liệu, Thực hành Tốt với Dữ liệu
Từ khóa (Keywords)	Flash Crash, Trách nhiệm ủy thác (Fiduciary), Làm mượt Dữ liệu (Smoothing Data)

Không phải tất cả dữ liệu đều được tạo ra một cách có đạo đức, thẳng thắn, đầy đủ và minh bạch. Giống như việc chúng ta cần áp dụng tư duy phản biện để đánh giá chất lượng, độ chính xác và tính đầy đủ của dữ liệu, chúng ta cũng nên sử dụng các thực hành đạo đức tốt khi cung cấp dữ liệu cho người khác hoặc sử dụng nó trong các mô hình của riêng mình. Bài học này sẽ xem xét một tá các thực hành phi đạo đức liên quan đến dữ liệu.

Đạo đức là một phần quan trọng của tài chính. Các công ty thích đưa đạo đức vào việc đào tạo nhân viên của họ. Thật vậy, một trong những công ty kế toán lớn nhất thế giới đã tổ chức một bài kiểm tra đạo đức cho nhân viên của mình. Hóa ra là các nhân viên đã gian lận trong bài kiểm tra đạo đức của họ! Bản thân công ty đã không tiết lộ thông tin này cho cơ quan quản lý (regulatory board) (GaNun).

Bài học này đề cập đến các vấn đề đạo đức khi chúng áp dụng vào việc xử lý dữ liệu. Mỗi tiểu mục mô tả một trong những cách phi đạo đức mà mọi người xử lý dữ liệu không phù hợp: đầu tư (investing), phóng đại, bóp méo, thu thập không phù hợp, che giấu, hiểu sai, v.v. Mỗi tiểu mục bao gồm ít nhất một ví dụ thực tế về hành vi được thực hiện bởi một cá nhân, công ty, hoặc thậm chí là một thị trường.

7.1 CỐ Ý TẠO RA DỮ LIỆU GÂY HIỂU LẦM (INTENTIONALLY CREATING MISLEADING DATA)

Một ngày nọ, một nghệ sĩ tên là Simon Weckert đã thu thập 99 chiếc điện thoại thông minh (Barret). Anh ta đặt chúng vào một chiếc xe kéo mà sau đó anh ta tiếp tục kéo đi bộ dọc theo các con phố của Munich, trở trêu thay lại là con phố gần trụ sở Google ở Munich—anh ta đang hack ứng dụng Google Maps! Khoảng một giờ sau khi bắt đầu đi bộ, Google Maps đã hiển thị tình trạng giao thông ùn tắc, kéo dài—mặc dù không có bất kỳ chiếc ô tô nào trong khu vực. Nghệ sĩ này tuyên bố rằng anh ta đang chỉ ra sự đơn giản đằng sau các hệ thống này. Thực sự không có tác hại nào được gây ra trong trò chơi khăm thông minh này. Điều này

khuyến chúng ta đặt câu hỏi về các giả định của mình khi nhận được dữ liệu, chẳng hạn như điều kiện giao thông.

Nếu trò này được thực hiện trên các thị trường tài chính, đó sẽ là một câu chuyện hoàn toàn khác. Việc cố ý tạo ra dữ liệu gây hiểu lầm là phi đạo đức. Giống như việc chúng ta có thể tự động tuân theo các điều kiện trên một ứng dụng giao thông, một cố vấn robot (RoboAdvisor) có thể tự động tuân theo các điều kiện trên thị trường (D'Acunto và Rossi). Chúng có thể phản ứng mà không đặt câu hỏi về dữ liệu vì chúng tập trung vào tốc độ và tính hiệu quả thay vì xác thực kết quả.

Một cách trắng trợn để cố ý gây hiểu lầm cho một thị trường là giả mạo (spoof) nó. Một người như vậy đã làm điều đó vào năm 2010 là Navinder Singh Sarao. Ông ta bị quy trách nhiệm cho việc khơi mào một đợt sụt giảm mạnh của thị trường (market downturn) được gọi là Flash Crash (sụp đổ chớp nhoáng) năm 2010. Sarao đã nhận tội giả mạo thị trường và phải trả giá bằng một bản án tù cùng các khoản tiền phạt.

Giả mạo (Spoofing) là gì? Giả mạo là một kiểu lừa gạt cực đoan. Việc giả mạo xảy ra khi một nhà giao dịch đặt một lệnh lớn mà anh ta không có ý định khớp lệnh. Thay vào đó, ý định là thao túng thị trường có lợi cho mình. Ví dụ, một kẻ giả mạo (spoofers) đặt một lệnh mua lớn sẽ đặt một lệnh chào mua khổng lồ thấp hơn nhiều so với báo giá chào mua hiện tại của thị trường. Khi các nhà tạo lập thị trường và các nhà giao dịch khác, bao gồm cả các nhà giao dịch thuật toán, cảm nhận được một người mua có động lực, họ sẽ rút các giá chào bán của mình và tăng chúng lên. Những đợt tăng giá này kích hoạt các nhà giao dịch khác làm điều tương tự. Tuy nhiên, đây mới là động cơ của kẻ giả mạo từ đầu—một sự thao túng giá theo hướng mong muốn.

Trong trường hợp của ông Sarao, ông ta đã giả mạo thị trường bằng cách đặt một lệnh bán lớn (cao hơn giá chào bán) cho hợp đồng tương lai E-mini S&P. Lệnh của ông ta đã khiến các thuật toán hạ giá của chúng, điều này đến lượt nó lại khiến các nhà giao dịch và thuật toán khác hạ giá của họ, và cứ tiếp tục như vậy. Giá cả lao dốc. Các hành động và phản ứng đã gây ra Flash Crash, một đợt sụp đổ thị trường trong ngày đã quét sạch hơn \$1 nghìn tỷ giá trị thị trường. Các thị trường khác không cho thấy sự sụt giảm, và vì vậy thị trường đã học được rằng đây là một tai nạn xảy ra một lần. Trong vòng một giờ, hầu hết thị trường đã điều chỉnh.

Việc tạo ra dữ liệu gây hiểu lầm là phi đạo đức. Các thị trường giao dịch trong thời gian thực và có thể bị gây hiểu lầm bởi những kẻ giả mạo. May mắn thay, quy định và các kiểm soát lớn hơn tồn tại ở nhiều sàn giao dịch ngày nay giúp giảm thiểu sự tái diễn của việc một nhà giao dịch giả mạo thị trường và gây ra một đợt Flash Crash khác. Việc giả mạo thị trường vẫn là một hành vi phạm tội hình sự.

7.2 LAN TRUYỀN ĐÁNH GIÁ GIẢ (PROPAGATING FAKE REVIEWS)

Lần tới khi bạn ở London, bạn có thể muốn dùng bữa tại nơi từng là nhà hàng được đánh giá cao nhất trên tripadvisor.com: The Shed (Butler). Với hình ảnh các món ăn, một khu vườn bên ngoài, và hàng chục đánh giá, The Shed dường như là một nơi hợp thời trang để ăn uống. Vấn đề duy nhất là nhà hàng này không hề tồn tại. Các đánh giá ban đầu đều là giả mạo. Trớ trêu thay, The Shed lại là nơi mọi người đổ xô đến. Những cuộc gọi điện thoại đến nhà hàng chỉ được kết nối tới máy trả lời tự động. Khi mọi người nhận ra nhà hàng này hợp thời trang đến mức nào, họ đã viết đánh giá mặc dù họ chưa bao giờ thực sự đến đó. Một phần của động lực lan truyền (going viral) là việc thuê những người nổi tiếng tạo dáng với các món ăn (vốn thậm chí không phải từ nhà hàng) để tạo ra bầu không khí uy tín và phong cách.

Đọc các đánh giá không giống như việc thực hiện thẩm định chuyên sâu (due diligence). Khi nhiều chi tiết hơn của vụ bê bối FTX được công khai, một số người nổi tiếng đang đứng

ra thừa nhận rằng họ là nhà đầu tư. Nhiều người quen thuộc với ngôi sao điện ảnh Kevin Bacon. Anh ấy là một nhà đầu tư vào FTX và tuyên bố rằng anh ấy đã mất hàng triệu đô la. Ngay cả những người nổi tiếng cũng có thể trở thành nạn nhân của hiệu ứng hào quang (halo effect) hoặc sự viện dẫn thẩm quyền (appeal to authority). Các nhà tiếp thị biết sức mạnh của sự bảo chứng của người nổi tiếng, đến mức nhiều vận động viên và nhạc sĩ kiếm được từ việc bảo chứng sản phẩm nhiều hơn từ tiền lương hàng triệu đô la.

Bạn có tự hỏi có bao nhiêu đánh giá nhà hàng là giả mạo? Có những bên với lợi ích nhóm bị cám dỗ để đăng hết đánh giá rục rờ này đến đánh giá rục rờ khác. Một cú nhấp chuột nhanh vào người đánh giá đó cho thấy họ không đánh giá điều gì khác. Điều tương tự cũng có thể nói đối với các diễn đàn đánh giá cổ phiếu. Một số người tham gia các diễn đàn phổ biến này để chào mời cổ phiếu (hoặc để vui đập chúng nếu họ có các vị thế bán khống). Đạo đức tốt sẽ tránh sự xuyên tạc.

7.3 KHÔNG TIẾT LỘ PHÍ HOẶC XUNG ĐỘT LỢI ÍCH (FAILING TO DISCLOSE FEES OR CONFLICTS OF INTEREST)

Theo một cuộc khảo sát dữ liệu của công ty nghiên cứu dữ liệu Morning Consult, chỉ 36% người lớn tin tưởng các nhà quản lý đầu tư và quản lý tài sản. Phần còn lại hoặc không tin tưởng họ hoặc không có ý kiến về họ. Một phần của vấn đề là các cố vấn tài chính không tiết lộ các khoản phí hoặc tiết lộ các xung đột lợi ích. Ví dụ, một cố vấn có thể đề xuất quỹ tương hỗ A thay vì quỹ B cho một khách hàng. Mặc dù B có thể phù hợp hơn cho hồ sơ đầu tư và khả năng chịu đựng rủi ro, nhưng cố vấn lại được trả một khoản hoa hồng tốt hơn nhiều cho việc bán quỹ tương hỗ A. Việc không tiết lộ các khoản phí hoặc tiết lộ xung đột lợi ích vi phạm lòng tin ủy thác (fiduciary trust).

Trong thế giới đầu tư, đây là những hành vi phạm tội. Ví dụ, hai cố vấn robot (robo-advisor), một trong số đó có hơn \$11 tỷ tiền của khách hàng, đã đưa ra các tuyên bố sai lệch về một chiến lược liên quan đến việc thu hoạch lỗ tính thuế (tax-loss harvesting) (U.S. Securities and Exchange Commission, “SEC Charges Two Robo-Advisers”). Những tiết lộ sai lệch này đã khiến các nhà đầu tư lầm tưởng rằng các quỹ có hiệu suất vượt trội (lợi nhuận cao hơn, rủi ro ít hơn, phí nhỏ hơn) và tự nhiên khiến chúng có vẻ hấp dẫn hơn so với các quỹ khác. Những lần khác, các nhà quản lý không tiết lộ các khoản phí (U.S. Securities and Exchange Commission, “SEC Charges Investment Adviser”).

Đạo đức tốt là công khai mọi dữ liệu liên quan đến đầu tư: kết quả lịch sử, các khoản phí, và rủi ro. Quy định cũng giúp ích. Một số ngành bảo vệ người tiêu dùng/nhà đầu tư tốt hơn những ngành khác.

7.4 DÙNG DỮ LIỆU MÔ PHÒNG THAY CHO DỮ LIỆU THỰC MÀ KHÔNG CÔNG KHAI RÕ RÀNG (USING SIMULATED DATA INSTEAD OF REAL DATA WITHOUT EXPLICIT DISCLOSURE)

Một cách khác để nói dối với dữ liệu là sử dụng dữ liệu mô phỏng trong khi cố tình đánh lừa rằng đó là dữ liệu thực. Ví dụ, một quỹ phòng hộ đã huy động được hàng triệu đô la bằng cách tuyên bố sai sự thật rằng họ có một thành tích (track record) dài hạn dựa trên các giao dịch thực tế sử dụng tiền thật (U.S. Securities and Exchange Commission, “SEC Charges Father-and-Son Hedge Fund Managers”). Trên thực tế, các kết quả là từ các mô phỏng giả định được kiểm thử ngược (back-tested). Các mô phỏng có những chi tiết có thể làm sai lệch một nghiên cứu theo cách này hay cách khác. Ví dụ, một mô phỏng của một quá trình kiểm

thử ngược có thể bỏ qua khoảng chênh lệch chào mua - chào bán (bid-ask spread) và tác động thị trường (market impact). Việc xuyên tạc loại dữ liệu là bất hợp pháp, và các nhà quản lý đã đồng ý trả hàng triệu đô la để giải quyết vụ án gian lận. Bản thân việc sử dụng lợi nhuận mô phỏng không phải là bất hợp pháp hay phi đạo đức. Khi sử dụng dữ liệu mô phỏng, bạn nên chỉ ra rõ ràng rằng các kết quả không phải là thực, mà chỉ là sản phẩm của các kiểm thử ngược hoặc các kịch bản. Ngay cả khi một quỹ có một thành tích hoạt động kéo dài nhiều năm, một tuyên bố miễn trừ trách nhiệm (disclaimer) được thêm vào rằng hiệu suất trong quá khứ không đảm bảo cho các kết quả trong tương lai. Gây hiểu lầm là nói dối.

7.5 THÊM DỮ LIỆU TỐT VÀO DỮ LIỆU XẤU (ADDING GOOD DATA TO BAD DATA)

Việc học sinh gian lận thì đã được biết đến nhiều, nhưng cũng có một thứ gọi là giáo viên gian lận. Câu chuyện này đã được mô tả trong cuốn sách *Freakonomics: A Rogue Economist Explores the Hidden Side of Everything* của Levitt và Dubner. Để làm cho việc giảng dạy của chính họ có vẻ hiệu quả hơn, một số giáo viên ở Chicago đã gian lận bằng cách thêm điểm vào bài kiểm tra của học sinh. Khi học sinh nộp bài kiểm tra, các giáo viên sẽ điền chính xác vài câu hỏi cuối cùng, vì hầu hết học sinh không cố gắng trả lời các câu hỏi khó do thiếu thời gian hoặc độ khó. Vì vậy, các giáo viên này có thể lấy bài thi của một học sinh và dành vài giây để cải thiện điểm số. Các giáo viên không dành bất kỳ thời gian nào để xóa các câu trả lời, nhưng đã dành thời gian để điền vào một dãy đáp án trắc nghiệm đã thuộc lòng (memorized pattern) cho vài câu hỏi cuối cùng, mà hầu hết học sinh chưa bao giờ cố gắng làm. Nhìn chung, việc giáo viên gian lận dường như đã hiệu quả: điểm số của học sinh đã được cải thiện! Nhưng có một số thống kê không nhất quán về hiệu suất đã gióng lên những hồi chuông cảnh báo. Nhiều học sinh trả lời sai các câu hỏi dễ và trung bình nhưng lại làm đúng một chuỗi các câu hỏi khó. Hơn nữa, gần như tất cả các học sinh trong một lớp học đều làm đúng các câu hỏi khó giống hệt nhau. Những sự trùng hợp thật đáng kinh ngạc. Các cuộc điều tra sâu hơn cho thấy có một động lực cho các giáo viên: điểm kiểm tra được cải thiện đồng nghĩa với việc có nhiều tiền hơn cho giáo viên.

Trong ngành ngân hàng, cái giá phải trả cao hơn, và các phương pháp tinh vi hơn nhiều. Định luật Benford (Benford's Law) được sử dụng để phát hiện sự thao túng dữ liệu kế toán trong ngành ngân hàng. Định luật Benford dự đoán các tần số tương đối của các chữ số. Vui lòng đọc bài báo của Grammatikos và Papanikolaou để tìm hiểu cách Định luật Benford được áp dụng để phát hiện sự thao túng dữ liệu kế toán trong ngành ngân hàng. Người ta có thể nghĩ rằng một tỷ lệ nhỏ dữ liệu tốt sẽ không bị chú ý. Thực hành đạo đức tốt là không can thiệp vào chất lượng dữ liệu.

7.6 CHE GIẤU DỮ LIỆU (HIDING DATA)

Thay vì thêm dữ liệu tốt vào dữ liệu xấu, tại sao không che giấu hoàn toàn một số dữ liệu? Đó là những gì đã được thực hiện trong trường hợp của một số khoản nợ công (public debt). Horn mô tả việc báo cáo dưới mức có hệ thống (systematic underreporting) của nợ công. Nghiên cứu bao gồm dữ liệu từ 50 năm. Trong các nền kinh tế mạnh mẽ, việc che giấu nợ rất dễ dàng. Tuy nhiên, trong những thời điểm kinh tế tồi tệ, các khoản nợ bị che giấu có khả năng bị phơi bày. Việc che giấu nợ có thể làm cho các chính trị gia, các kiểm soát viên, hoặc ngân sách trông có vẻ tốt hơn thực tế, và các chính trị gia có thể đưa ra những lời hứa hẹn có thể giúp họ đắc cử nhưng sẽ không thực hiện được khi các khoản thu và chi thực sự được tính toán.

Những ý định tốt có thể khiến mọi người che giấu dữ liệu. Nếu bạn đang loại bỏ các giá trị ngoại lai (outliers) khỏi một phân phối, điều đó có vẻ như đang giảm nhiễu (noise), cải thiện kết quả tổng thể. Tuy nhiên, những gì một người coi là một giá trị ngoại lai, người khác có thể coi là một trường hợp cực đoan quan trọng. Tương tự, vào một “ngày giao dịch mỏng” (một ngày với rất ít thanh khoản), một người có thể coi chênh lệch giá chào mua - chào bán là không đại diện cho thanh khoản tổng thể. Tuy nhiên, các giai đoạn kém thanh khoản này cần được bao gồm trong các mô hình đo lường thanh khoản và rủi ro tổng thể.

Những lần khác, dữ liệu có thể bị thiên lệch và làm sai lệch kết quả. Giả sử một nhà hàng chỉ cung cấp một biểu mẫu phản hồi cho các khách hàng quay lại. Có lẽ, một khách hàng quay lại đã thích trải nghiệm của họ và quay lại cơ sở kinh doanh đó. Tuy nhiên, còn một khách hàng chỉ đến một lần mà không có trải nghiệm tốt thì sao? Họ bị từ chối cơ hội nhận được một biểu mẫu phản hồi ngay từ đầu. Tất nhiên, nhiều trang web trực tuyến (chẳng hạn như Yelp) cung cấp cơ hội cho những khách hàng không hài lòng bày tỏ quan điểm của họ.

7.7 LÀM MUỘT DỮ LIỆU (SMOOTHING DATA)

Việc làm mượt (smoothing) nghe có vẻ là một điều tốt. Trong Kinh tế lượng, bạn sẽ làm mượt các chuỗi thời gian (time series) để lọc bỏ nhiễu. Tuy nhiên, việc làm mượt lãi và lỗ (P and L) làm cho dữ liệu có vẻ ít rủi ro hơn thực tế. Việc làm mượt báo cáo dưới mức (under-reports) biến động. Báo cáo dưới mức biến động là một hiện tượng phổ biến tại các quỹ thay thế hoặc các quỹ giao dịch các chứng khoán không có định giá theo giá thị trường (mark-to-market) rõ ràng, thanh khoản (Le Marois). Phải thừa nhận rằng, nếu một chứng khoán đã không được giao dịch trong nhiều tháng hoặc khó định giá do thiếu khả năng thay thế được (fungibility), thì rất khó để đưa ra giá đánh dấu (marks) chính xác. Nếu biến động bị khai thấp (understated), thì tỷ lệ Sharpe (Sharpe ratios) bị phóng đại (overstated). Ví dụ, giả sử một chiến lược kiếm được cho người quản lý quỹ các mức lợi nhuận hàng ngày sau: +5, -1, +1, -3. Người quản lý có thể biến mức +5 thành +1, giữ lại một khoản dự trữ là 4. Khoản dự trữ đó có thể làm phẳng hoàn toàn mức -3 và giảm nhẹ mức -2 thành -1, vì vậy thay vì có những biến động tăng 5 và giảm 3, chiến lược báo cáo +1, 0, +1, 0. Điều này trông rất tốt: những chiến thắng nhỏ và không có thua lỗ. Khi được thực hiện ở quy mô lớn, việc giữ lại các khoản lợi nhuận để bù đắp các khoản lỗ sẽ làm giảm biến động của một chiến lược. Đạo đức tốt tránh việc làm mượt dữ liệu.

7.8 NGOẠI SUY DỮ LIỆU (EXTRAPOLATING DATA)

Việc ngoại suy (extrapolating) dữ liệu là một vấn đề. Một số mô hình có các vùng tuyến tính và sau đó nhanh chóng thay đổi thành phi tuyến tính (non-linear). Hãy nghĩ đến tác động thị trường. Trước đó trong khóa học này, chúng ta đã thấy vấn đề liên quan đến thảm họa Tàu con thoi Challenger. Vui lòng tham khảo Hình đã chuyển vị (transposed) cho Số lượng Sự cố trong bài báo của Arliss, biểu đồ biểu thị sự thất bại so với nhiệt độ. Đáng buồn thay, phân tích cho thấy rằng việc giảm 20 độ nhiệt độ (phản ánh các điều kiện nhiệt độ vào ngày phóng) làm tăng tỷ số cược (odds) thất bại lên 15 lần. Thực hành đạo đức tốt là đảm bảo các kết quả dự đoán không nằm ngoài vùng thử nghiệm.

Nguy cơ của việc ngoại suy là giả định rằng xu hướng sẽ tiếp tục bên ngoài vùng của các biến dự báo nơi nó đã được thử nghiệm. Nếu một hệ thống là tuyến tính, thì việc ngoại suy sẽ không tạo ra các vấn đề. Thách thức của tính phi tuyến tính khiến việc giả định các xu hướng tiếp tục bên ngoài vùng kiểm thử trở nên nguy hiểm.

7.9 ĐÁNH CẮP DỮ LIỆU (STEALING DATA)

Các công ty bị đánh cắp dữ liệu. Một số dữ liệu này có thể chứa thông tin khách hàng quan trọng, được sử dụng để hack vào tài khoản của họ, bòn rút tiền của họ hoặc thiết lập danh tính mới dưới tên của họ. Trong các trường hợp khác, nó có bản quyền, được cấp bằng sáng chế, hoặc được đăng ký nhãn hiệu. Trong các bài học trước, chúng ta đã thấy những nhân viên đã lấy dữ liệu (và code) từ các công ty. Hãy đọc Chang và cộng sự để xem tác động của việc trộm cắp dữ liệu đối với giá trị thị trường của một công ty.

7.10 CÁC VẤN ĐỀ VỀ CHẤT LƯỢNG DỮ LIỆU (DATA QUALITY PROBLEMS)

Bạn đã nghe đến từ viết tắt GIGO: Garbage In, Garbage Out (Rác vào, Rác ra). Tuy nhiên, làm thế nào chúng ta biết rằng chúng ta có rác ngay từ đầu? Mặc dù không phải là một vấn đề đạo đức trực tiếp, một số dữ liệu có chất lượng kém. Nếu bạn biết dữ liệu có vấn đề về chất lượng nhưng vẫn mô hình hóa nó một cách sâu rộng và báo cáo về các kết quả, bạn đang nhân rộng (propagate) vấn đề chất lượng đó. Sự chặt chẽ và tính hình thức của một mô hình không cải thiện chất lượng của dữ liệu vốn đã có vấn đề ngay từ đầu (xem Liu để biết thêm thông tin).

Một cách để tránh các vấn đề về chất lượng dữ liệu là yêu cầu các báo cáo tài chính đã được kiểm toán (audited financial statements). Sự giám sát của một công ty kế toán chuyên nghiệp cung cấp độ tin cậy và niềm tin vào các kết quả được báo cáo. Hãy xem xét trường hợp của công ty cho thuê xe lớn nhất thế giới, Hertz. Vài năm trước, SEC đã cáo buộc Hertz về việc báo cáo dữ liệu không chính xác (U.S. Securities and Exchange Commission, “SEC Charges Hertz”). Bản thân Hertz đã phải trả một khoản tiền phạt. Nhưng còn các nhà đầu tư tổ chức, những người đã đưa ra các quyết định đầu tư về Hertz dựa trên thông tin này thì sao? Rõ ràng, tin tức về sự xuyên tạc đã không được biết đến vào thời điểm đó. Những người có trách nhiệm ủy thác nên hết sức cẩn thận để đánh giá chất lượng dữ liệu mà họ có trước khi họ xây dựng các mô hình và đưa ra quyết định.

7.11 THU THẬP DỮ LIỆU KHI CHƯA ĐƯỢC PHÉP (COLLECTING DATA WITHOUT PERMISSION)

Các ứng dụng điện thoại thông minh thích dữ liệu. Nhiều ứng dụng trong số đó thu thập dữ liệu của chúng ta, ngay cả khi không có sự cho phép của chúng ta. Hiện nay có một lĩnh vực tập trung vào luật quyền riêng tư dữ liệu (data privacy laws) bảo vệ người tiêu dùng, người dùng ứng dụng, v.v. khỏi các công ty thu thập và bán lại dữ liệu của họ (Klosowski). Vấn đề là dữ liệu này có thể được sử dụng theo những cách mà người dùng không bao giờ dự định.

Đạo đức tốt đòi hỏi sự cho phép rõ ràng (explicit permission) để lưu trữ dữ liệu người dùng. Sự tiết lộ này thường là một phần của thỏa thuận cấp phép (license agreement) nhưng có thể dễ dàng bị lạc trong các dòng chữ in nhỏ (fine print).

7.12 TIẾT LỘ DỮ LIỆU KHI CHƯA ĐƯỢC PHÉP (DISCLOSING DATA WITHOUT PERMISSION)

Việc tiết lộ dữ liệu mà không có sự cho phép thậm chí còn tồi tệ hơn. Điều này có nghĩa là dữ liệu sử dụng của bạn được gửi cho các công ty và các bên thứ ba mà không có sự cho phép hoặc kiến thức của bạn. Hơn nữa, điều gì sẽ xảy ra nếu có một vụ vi phạm dữ liệu (data

breach)? Đã có những công ty lớn mà các ngân hàng dữ liệu của họ bị hack, khiến thông tin nhạy cảm của mọi người có sẵn cho tội phạm.

Như bạn có thể thấy, dữ liệu có bộ quy tắc đạo đức riêng của nó. Với nhiều loại dữ liệu hơn có sẵn (hãy nghĩ đến tất cả các dữ liệu thay thế (alternative data) được sử dụng trong tài chính), số lượng tài khoản mà mọi người có ngày càng tăng (với ngân hàng, công ty môi giới, sàn giao dịch, cổ vấn, ứng dụng, v.v.), có nhiều dữ liệu hơn bao giờ hết.

7.13 KẾT LUẬN (CONCLUSION)

Giống như việc chúng ta đã kết thúc khóa học FM bằng việc thảo luận về đạo đức, chúng ta kết thúc khóa học FD bằng việc thảo luận về đạo đức xoay quanh dữ liệu. Chúng tôi nhắc lại rằng danh tiếng xây dựng rất chậm ở khía cạnh tích cực nhưng lại sụp đổ nhanh chóng ở khía cạnh tiêu cực. Nhiều thập kỷ thực hành đạo đức, siêng năng có thể bị lấn át bởi một hành động phi đạo đức duy nhất. Thật không may, internet không có khả năng lãng quên. Nhờ vào các bức ảnh trên Instagram, các bài đăng trên Facebook, các blog, các video trên YouTube lan truyền (viral), và các bài báo không bao giờ biến mất, những câu chuyện về hành vi phi đạo đức không có ngày hết hạn.

Những câu chuyện chúng ta đã nghe—giao dịch nội gián (insider trading), bịa đặt email, giả mạo thị trường—đã biến những người tương đối vô danh thành các meme trên internet. Các tìm kiếm trên Google tiết lộ hàng ngàn trang về những người này, những người được thế giới biết đến vì hành động khét tiếng của họ. Chi phí cơ hội (opportunity cost) khá cao. Nhiều người sẽ tránh làm việc với hoặc thuê những người này vì thành tích đã biết là không trung thực và lừa dối. Hãy thực hành đạo đức tốt — trong dữ liệu và trong hành động.

7.14 TÀI LIỆU THAM KHẢO (REFERENCES)

Arliss, Will. "Probability of the Challenger Disaster." Medium, 9 October 2020, <https://towardsdatascience.com/probability-of-the-challenger-disaster-c2a17b7984cc>.

Barret, Brian. "An Artist Used 99 Phones to Fake a Google Maps Traffic Jam." *Wired*, 3 Feb. 2020, <https://www.wired.com/story/99-phones-fake-google-maps-traffic-jam/>.

Butler, Oobah. "I Made My Shed the Top Rated Restaurant On TripAdvisor." *Vice*, 6 December 2017, <https://www.vice.com/en/article/434gqw/i-made-my-shed-the-top-rated-restaurant-on-tripadvisor>.

Chang, Kuo-Chung, et al. "The Effect of Data Theft on a Firm's Short-Term and Long-Term Market Value." *Mathematics*, vol. 8, no. 5, 2020, <https://www.mdpi.com/2227-7390/8/5/808/htm>.

D'Acutto, Francesco, and Alberto Rossi. "Robo-advice: An Effective Tool to Reduce Inequalities?" Brookings, 5 Oct. 2022, <https://www.brookings.edu/research/robo-advice-an-effective-tool-to-reduce-inequalities/>.

GaNun, Jacqueline. "Accounting Giant Ernst Young Admits its Employees Cheated on Ethics Exams." NPR, 28 June 2022, <https://www.npr.org/2022/06/28/1108044858/accounting-giant-ernst-young-admits-its-employees-cheated-on-ethics-exams>.

Grammatikos, Theoharry, and Nikolaos I. Papanikolaou. "Applying Benford's Law to Detect Accounting Data Manipulation in the Banking Industry." *Journal of Financial Services Research*, vol. 59, 2021, pp. 115–142, <https://link.springer.com/article/10.1007/s10693-020-00334-9>.

Horn, Sebastian, et al. "Systematic Underreporting of Public Debt Statistics: 50 Years of Evidence and Recent Progress." *World Bank Blogs*, 3 March 2022, <https://blogs.worldbank.org>

g/developmenttalk/systematic-underreporting-public-debt-statistics-50-years-evidence-and-recent.

Klosowski, Thorin. "The State of Consumer Data Privacy Laws in the US (And Why It Matters)." *The New York Times*, 6 Sept. 2021, <https://www.nytimes.com/wirecutter/blog/state-of-privacy-laws-in-us/>.

Le Marois, Oliver, and Raphael Douady. "Return Smoothing Practices." *The Hedge Fund Journal*, no. 30, 2007, <https://thehedgefundjournal.com/return-smoothing-practices/>.

Levitt, Steven D., and Stephen J. Dubner. *Freakonomics: A Rogue Economist Explores the Hidden Side of Everything*. William Morrow, 2005.

Liu, Grace. "Data Quality Problems Troubling Business and Financial Researchers: A Literature Review and Synthetic Analysis." *Journal of Business & Finance Librarianship*, November 2020, https://digitalcommons.wcupa.edu/lib_facpub/13/.

U.S. Securities and Exchange Commission. "SEC Charges Investment Adviser with Failing to Disclose Conflicts Arising from Mutual Fund and Account Recommendations." March 2022, <https://www.sec.gov/litigation/litreleases/2022/lr25340.htm>.

U.S. Securities and Exchange Commission. "SEC Charges Father-and-Son Hedge Fund Managers Who Agree to Pay \$4.8 Million to Settle Fraud Case." 2012, <https://www.sec.gov/news/press-release/2012-2012-71.htm>.

U.S. Securities and Exchange Commission. "SEC Charges Hertz with Inaccurate Financial Reporting and Other Failures." 1 Feb. 2019, <https://www.sec.gov/enforce/33-10601-s>.

U.S. Securities and Exchange Commission. "SEC Charges Two Robo-Advisers With False Disclosures." 2018, <https://www.sec.gov/news/press-release/2018-300>.

Copyright 2024 WorldQuant University. This content is licensed solely for personal use. Redistribution or publication of this material is strictly prohibited.

ĐỌC THÊM 1: ÁP DỤNG ĐỊNH LUẬT BENFORD ĐỂ PHÁT HIỆN THAO TÚNG DỮ LIỆU KẾ TOÁN

8.1 THÔNG TIN NGUỒN

- **Nguồn:** Grammatikos, Theoharry, và Nikolaos I. Papanikolaou. "Applying Benford's Law to Detect Accounting Data Manipulation in the Banking Industry." *Journal of Financial Services Research*, vol. 59, 2021, tr. 115–142. <https://link.springer.com/article/10.1007/s10693-020-00334-9>
- **Phần cần đọc:** Lướt qua các bảng, biểu đồ và đồ thị (20 phút)


Lưu ý kiểm chứng

Số liệu trong các Bảng 3–8 của chương này đang chờ đối chiếu lại từng ô với bản gốc; các Bảng 1, 2, 9 và Hình 1–3 đã được đối chiếu.

Bảng 1 Tần số kỳ vọng của chữ số theo Benford

Chữ số (Digit)	Vị trí thứ 1 (1st place)	Vị trí thứ 2 (2nd place)	Vị trí thứ 3 (3rd place)	Vị trí thứ 4 (4th place)
0		.1197	.1018	.1002
1	.3010	.1139	.1014	.1001
2	.1761	.1088	.1010	.1001
3	.1249	.1043	.1006	.1001
4	.0969	.1003	.1002	.1000
5	.0792	.0967	.0998	.0999
6	.0670	.0934	.0994	.0999
7	.0580	.0904	.0990	.0999
8	.0512	.0876	.0986	.0999
9	.0458	.0850	.0983	.0998

Bảng này trình bày tần số kỳ vọng cho các chữ số từ 0 đến 9 ở mỗi vị trí trong bốn vị trí đầu tiên của bất kỳ số nào dựa trên phân phối của Benford.



Hình 1: Tần số kỳ vọng của Benford cho chữ số thứ nhất và thứ hai.

Hình 1 Tần số kỳ vọng của Benford cho chữ số thứ nhất và thứ hai. Hình này chứa biểu diễn đồ họa của các tần số kỳ vọng cho chữ số thứ nhất (đường đứt nét) và cho chữ số thứ hai (đường liền nét) dựa trên phân phối của Benford. Các giá trị trên trục dọc là xác suất phân phối của chữ số i như được hiển thị trên trục ngang, với $i = 0, 1, 2, \dots, 9$.

Bảng 2 Các biến kế toán ngân hàng và nguồn dữ liệu

Thành phần CAMEL (CAMEL components)	Các biến số (Variables)	Ký hiệu (Abbreviation)	Nguồn dữ liệu (Data Source)
Mức độ an toàn vốn (Capital adequacy)	Vốn pháp định cốt lõi (Core regulatory capital)	TIER1	Báo cáo Call (Call reports)
	Vốn chủ sở hữu theo sổ sách (Book equity capital)	EQUITY	
Chất lượng tài sản (Asset quality)	Chi phí dự phòng tổn thất cho vay (Loan loss provisions)	LLP	
	Số dư dự phòng tổn thất cho vay (Allowances for loan losses)	ALLOW	
	Nợ xấu (Non-performing loans)	NPL	
Sức mạnh thu nhập (Earnings strength)	Tổng thu nhập lãi (Total interest income)	INTINC	
	Tổng thu nhập ngoài lãi (Total non-interest income)	NINTINC	
	Tổng tài sản sinh lời (Total earning assets)	EARNAS	
Tính thanh khoản (Liquidity)	Tiền mặt và số dư tại các tổ chức nhận tiền gửi (Cash and balances due from depository institutions)	CASH	

Thành phần CAMEL (CAMEL components)	Các biến số (Variables)	Ký hiệu (Abbreviation)	Nguồn dữ liệu (Data Source)
	Tiền mua quỹ liên bang và chứng khoán bán theo hợp đồng mua lại (Federal funds purchased and securities sold under agreements to repurchase)	REPOS	

Bảng này trình bày tất cả các biến số mà chúng tôi sử dụng trong phân tích thực nghiệm của mình. Ký hiệu của mỗi biến số và nguồn mà chúng tôi sử dụng để thu thập dữ liệu kế toán tương ứng cũng được báo cáo ở hai cột cuối cùng.

Bảng 3 Phân tích chữ số ở vị trí thứ hai trong giai đoạn trước khủng hoảng


Chữ số (Digit)	Tần số ký vọng (Exp. freq.)	TIER1 Không kiệt quệ n=118,801	TIER1 Phá sản n=8,036	TIER1 Được cứu trợ n=14,918	LLP Không kiệt quệ n=116,805	LLP Phá sản n=7,633	LLP Được cứu trợ n=14,008	INTINC Không kiệt quệ n=119,382	INTINC Phá sản n=8,439	INTINC Được cứu trợ n=15,402	NINTINC Không kiệt quệ n=119,270	NINTINC Phá sản n=8,421	NINTINC Được cứu trợ n=15,426	CASH Không kiệt quệ n=119,320	CASH Phá sản n=8,296	CASH Được cứu trợ n=15,224
		Sai lệch quan sát (z-statistic)	Sai lệch quan sát (z-statistic)	Sai lệch quan sát (z-statistic)	Sai lệch quan sát (z-statistic)	Sai lệch quan sát (z-statistic)	Sai lệch quan sát (z-statistic)	Sai lệch quan sát (z-statistic)	Sai lệch quan sát (z-statistic)	Sai lệch quan sát (z-statistic)	Sai lệch quan sát (z-statistic)	Sai lệch quan sát (z-statistic)	Sai lệch quan sát (z-statistic)	Sai lệch quan sát (z-statistic)	Sai lệch quan sát (z-statistic)	Sai lệch quan sát (z-statistic)
0	.1197	0.0147 1.33 0.0115	0.0344 1.20 0.0219	0.0272 1.41 0.0238	-0.0414 -1.87* -0.0208	-0.0571 -1.99** -0.0093	-0.0793 -2.09** -0.0094	0.0556 2.30** 0.0395	0.0730 2.41** 0.0476	0.0732 2.69*** 0.0390	0.0181 1.39 0.0116	0.0182 1.51 0.0103	0.0820 2.34** 0.0346	-0.0032 -0.84 0.0029	-0.0096 -1.20 -0.0042	0.0103 0.54 0.0087
1	.1139	0.92 -0.0028	1.43 -0.0226	1.32 0.0170	-1.30 0.0122	-1.28 0.0032	-1.55 -0.0086	1.74* -0.0192	2.18** 0.0202	2.13** 0.0136	1.30 0.0042	0.96 0.0129	1.69* -0.0125	0.41 0.0010	-1.02 0.0053	0.67 -0.0094
2	.1088	-1.10 0.0023	-1.03 -0.0094	1.21 -0.0115	0.95 0.0109	1.17 0.0014	-1.48 0.0051	-1.10 0.0153	1.49 -0.0218	1.22 -0.0067	1.14 -0.0049	1.17 0.0002	-0.85 -0.0062	0.23 0.0004	0.67 0.0039	-1.05 -0.0060
3	.1043	1.17 0.0016	-0.89 0.0048	-0.95 0.0102	0.67 -0.0075	0.91 -0.0010	1.04 0.0019	1.28 0.0042	-1.10 -0.0094	-0.93 -0.0051	-0.95 -0.0051	0.54 0.0035	-0.68 0.0035	0.49 -0.0029	0.78 0.0008	-1.21 0.0039
4	.1003	0.68 0.0014	0.99 0.0037	1.18 -0.0008	-1.26 -0.0053	-0.73 0.0009	0.88 -0.0012	1.13 0.0039	-1.29 0.0048	-1.17 0.0021	-0.99 -0.0004	0.70 0.0032	0.31 0.0028	-0.58 0.0012	0.45 0.0004	0.50 0.0021
5	.0967	0.72 -0.0022	1.06 0.0032	-0.48 0.0014	-1.18 0.0061	1.05 -0.0018	-0.76 -0.0009	1.06 0.0044	0.85 0.0032	0.96 -0.0048	-1.17 0.0013	1.05 0.0003	0.63 0.0022	0.92 0.0020	1.12 -0.0055	0.87 -0.0009
6	.0934	-0.58 -0.0018	0.38 -0.0029	1.07 -0.0114	1.04 0.0116	-0.63 -0.0020	-0.97 0.0044	1.02 0.0098	-1.00 -0.0097	-1.00 -0.0105	0.62 -0.0040	0.64 0.0095	1.17 -0.0173	1.04 -0.0039	-0.53 -0.0126	-1.04 -0.0028
7	.0904	-0.69 -0.0130	-1.15 -0.0174	-1.41 -0.0249	1.17 0.0125	-0.87 0.0082	1.29 0.0084	1.16 -0.0256	-1.39 -0.0425	-1.18 -0.0342	-1.16 -0.0032	1.18 -0.0053	-1.29 -0.0259	-0.62 -0.0040	-1.10 0.0153	-0.63 0.0070
8	.0876	-1.14 -0.0141	-1.38 -0.0351	-1.38 -0.0308	1.04 0.0452	1.38 0.0489	1.40 0.0738	-2.05** -0.0718	-2.28** -0.0816	-1.79* -0.0822	-1.03 -0.0053	-1.02 -0.0128	-1.84* -0.0782	-0.51 -0.0103	0.83 0.0188	1.38 0.0106
9	.0850	-0.93 $\chi^2_{(9)}$	-1.49 5.18	-1.33 10.83	1.98** 15.19*	1.94* 17.19**	2.32** 17.93**	-2.26** 18.19**	-2.49** 19.88**	-2.55** 20.07**	-1.40 9.31	-1.44 6.93	-2.41** 18.05***	-1.02 5.30	0.99 2.76	0.92 3.58

Cột đầu tiên của Bảng liệt kê tất cả mười chữ số có khả năng xuất hiện ở vị trí thứ hai của các biến số được kiểm tra, trong khi tần số xuất hiện kỳ vọng cho mỗi chữ số được xác định bởi Định luật Benford được trình bày ở cột thứ hai. Phần còn lại của các cột báo cáo các sai lệch quan sát được giữa tần số thực tế và kỳ vọng cho từng biến số (TIER1, LLP, INTINC, NINTINC, CASH) đối với các nhóm ngân hàng không bị kiệt quệ, phá sản, và được cứu trợ trong giai đoạn trước khủng hoảng. Giá trị của thống kê z và mức ý nghĩa tương ứng được trình bày bên dưới sai lệch quan sát được cho mỗi chữ số. Các giá trị của kiểm định mức độ phù hợp (goodness-of-fit) chi-bình phương được báo cáo ở hàng cuối cùng của Bảng. Tất cả các biến số và nguồn dữ liệu của chúng được mô tả trong Bảng 2. ***, **, và * chỉ ra ý nghĩa thống kê tương ứng ở mức 1%, 5%, và 10%.

Bảng 4 Phân tích chữ số ở vị trí thứ hai trong giai đoạn khủng hoảng


		TIER1 Không kiệt quệ n=118,801	TIER1 Phá sản n=8,036	TIER1 Được cứu trợ n=14,918	LLP Không kiệt quệ n=116,805	LLP Phá sản n=7,633	LLP Được cứu trợ n=14,008	INTINC Không kiệt quệ n=119,382	INTINC Phá sản n=8,439	INTINC Được cứu trợ n=15,402	NINTINC Không kiệt quệ n=119,270	NINTINC Phá sản n=8,421	NINTINC Được cứu trợ n=15,426
Tần số kỳ vọng (Exp. freq.)	Sai lệch quan sát (z-statistic)	Sai lệch quan sát (z-statistic)	Sai lệch quan sát (z-statistic)	Sai lệch quan sát (z-statistic)	Sai lệch quan sát (z-statistic)	Sai lệch quan sát (z-statistic)	Sai lệch quan sát (z-statistic)	Sai lệch quan sát (z-statistic)	Sai lệch quan sát (z-statistic)	Sai lệch quan sát (z-statistic)	Sai lệch quan sát (z-statistic)	Sai lệch quan sát (z-statistic)	Sai lệch quan sát (z-statistic)
Chữ số (Digit)	freq.)	(z-statistic)	(z-statistic)	(z-statistic)	(z-statistic)	(z-statistic)	(z-statistic)	(z-statistic)	(z-statistic)	(z-statistic)	(z-statistic)	(z-statistic)	(z-statistic)
0	.1197	0.0498 5.89***	0.0582 7.41***	0.0632 8.09***	-0.0582 -3.85***	-0.0692 -4.98***	-0.0882 -7.53***	0.0641 5.12***	0.0788 8.75***	0.0778 6.93***	0.0305 -0.75	0.0274 1.39	0.0873 8.94***
1	.3010	0.0271 2.34**	0.0263 3.03***	0.0305 2.19**	-0.0372 -2.09**	-0.0391 -2.51**	-0.0358 -2.97***	0.0531 4.12***	0.0496 3.63***	0.0484 4.70***	0.0019 0.56	0.0270 0.74	0.0396 2.48**
2	.1761	0.0005 0.51	0.0013 0.64	0.0009 0.50	0.0028 0.53	-0.0037 -0.49	-0.0005 -0.64	0.0103 0.78	0.0087 0.56	0.0112 0.80	0.0007 0.41	0.0012 0.56	0.0052 0.48
3	.1249	-0.0039 -0.88	-0.0028 -0.92	0.0018 0.39	0.0002 0.90	-0.0010 -0.74	0.0015 0.55	0.0032 0.84	0.0028 1.18	-0.0003 -1.05	0.0019 0.72	-0.0009 -0.88	0.0021 0.27
4	.0969	0.0026 1.05	-0.0032 -0.84	-0.0043 -0.95	0.0028 0.49	-0.0004 -0.91	-0.0018 -1.18	0.0006 0.26	0.0012 0.38	-0.0018 -0.49	-0.0002 -1.12	-0.0010 -1.04	0.0002 0.69
5	.0792	0.0009 0.17	-0.0013 -0.28	-0.0020 -0.58	0.0033 0.89	0.0014 1.10	-0.0028 -0.65	-0.0033 -0.12	-0.0030 -0.19	0.0012 0.65	0.0018 0.33	0.0041 0.55	-0.0010 -0.70
6	.0670	-0.0055 -1.26	0.0054 0.98	-0.0041 -1.00	0.0005 0.59	0.0011 0.70	-0.0017 -0.81	0.0003 0.86	0.0010 0.88	0.0015 0.73	0.0028 1.03	-0.0046 -0.78	0.0031 0.98
7	.0580	0.0083 1.30	0.0094 1.29	0.0102 1.36	-0.0037 -0.83	-0.0022 -1.03	0.0030 -1.03	0.0041 0.92	0.0032 1.03	-0.0009 -0.99	0.0002 0.88	0.0021 0.39	-0.0072 -1.34
8	.0512	-0.0088 -2.23**	-0.0104 -3.04***	-0.0086 -1.97**	0.0051 1.45	0.0038 1.20	0.0047 1.51	-0.0196 -4.83***	-0.0185 -2.56**	-0.0163 -2.71***	0.0092 0.67	-0.0018 -0.49	-0.0103 -1.99**
9	.0458	-0.0201 -2.04**	-0.0185 -2.18**	-0.0240 -2.69***	0.0387 2.37**	0.0379 2.27**	0.0354 3.17***	-0.0316 -5.31***	-0.0302 -2.48**	-0.0289 -2.95***	-0.0018 -0.74	-0.0006 -0.99	-0.0304 -3.05***
$\chi^2_{(9)}$		20.05**	24.09***	18.44**	17.38**	19.27**	25.07***	23.21***	18.52**	24.61***	8.12	7.10	19.28**

Cột đầu tiên của Bảng liệt kê tất cả mười chữ số có khả năng xuất hiện ở vị trí thứ hai của các biến số được kiểm tra, trong khi tần số xuất hiện kỳ vọng cho mỗi chữ số được xác định bởi Định luật Benford được trình bày ở cột thứ hai. Phần còn lại của các cột báo cáo các sai lệch quan sát được giữa tần số thực tế và kỳ vọng cho từng biến số (TIER1, LLP, INTINC, NINTINC, CASH) đối với các nhóm ngân hàng không bị kiệt quệ, phá sản, và được cứu trợ trong giai đoạn khủng hoảng. Giá trị của thống kê z và mức ý nghĩa tương ứng được trình bày bên dưới sai lệch quan sát được cho mỗi chữ số. Các giá trị của kiểm định mức độ phù hợp (goodness-of-fit) chi-bình phương được báo cáo ở hàng cuối cùng của Bảng. Tất cả các biến số và nguồn dữ liệu của chúng được mô tả trong Bảng 2. ***, **, và * chỉ ra ý nghĩa thống kê tương ứng ở mức 1%, 5%, và 10%.



Hình 2: Biểu diễn đồ họa kết quả phân tích chữ số trong giai đoạn trước khủng hoảng.

Hình 2 Biểu diễn đồ họa kết quả phân tích chữ số trong giai đoạn trước khủng hoảng. Các Panel A, B, C và D cung cấp biểu diễn đồ họa kết quả phân tích chữ số ở vị trí thứ hai của các biến kế toán bị thao túng (lần lượt là *TIER1*, *LLP*, *INTINC* và *NINTINC*) trong giai đoạn trước khủng hoảng. Các giá trị trên trục dọc là xác suất phân phối của chữ số i ($i = 0, 1, 2, \dots, 9$) như hiển thị trên trục ngang.



Hình 3: Biểu diễn đồ họa kết quả phân tích chữ số trong giai đoạn khủng hoảng.

Hình 3 Biểu diễn đồ họa kết quả phân tích chữ số trong giai đoạn khủng hoảng. Các Panel A, B, C và D cung cấp biểu diễn đồ họa kết quả phân tích chữ số ở vị trí thứ hai của các biến kế toán bị thao túng (lần lượt là *TIER1*, *LLP*, *INTINC* và *NINTINC*) trong giai đoạn khủng hoảng. Các giá trị trên trục dọc là xác suất phân phối của chữ số i ($i = 0, 1, 2, \dots, 9$) như hiển thị trên trục ngang.

Bảng 5 Ý nghĩa thống kê của các sai lệch được báo cáo so với Định luật Benford đối với chữ số không

	Giai đoạn trước khủng hoảng (Pre-crisis period)	Giai đoạn khủng hoảng (Crisis period)	Giai đoạn trước khủng hoảng so với Khủng hoảng (Pre-crisis vs Crisis (z-statistic))
<i>Panel A: TIER1</i>			
Các ngân hàng không bị kiệt quệ (Non-distressed banks)	0.0147	0.0498	1.98**

	Giai đoạn trước khủng hoảng (Pre-crisis period)	Giai đoạn khủng hoảng (Crisis period)	Giai đoạn trước khủng hoảng so với Khủng hoảng (Pre-crisis vs Crisis (z-statistic))
Các ngân hàng phá sản (Failed banks)	0.0344	0.0582	2.60***
Các ngân hàng được cứu trợ (Bailed-out banks)	0.0272	0.0632	2.91***
Các ngân hàng không bị kiệt quệ so với phá sản (Non-distressed vs Failed banks (z-statistic))	1.24	2.02**	
Các ngân hàng không bị kiệt quệ so với được cứu trợ (Non-distressed vs Bailed-out banks (z-statistic))	1.06	2.33**	
Các ngân hàng phá sản so với được cứu trợ (Failed vs Bailed-out banks (z-statistic))	0.87	1.14	
<i>Panel B: LLP</i>			
Các ngân hàng không bị kiệt quệ (Non-distressed banks)	-0.0414	-0.0582	-2.05**
Các ngân hàng phá sản (Failed banks)	-0.0571	-0.0692	-2.31**
Các ngân hàng được cứu trợ (Bailed-out banks)	-0.0793	-0.0882	-2.88***
Các ngân hàng không bị kiệt quệ so với phá sản (Non-distressed vs Failed banks (z-statistic))	-1.99**	-2.10**	
Các ngân hàng không bị kiệt quệ so với được cứu trợ (Non-distressed vs Bailed-out banks (z-statistic))	-2.24**	-2.23**	
Các ngân hàng phá sản so với được cứu trợ (Failed vs Bailed-out banks (z-statistic))	-0.90	-0.82	
<i>Panel C: INTINC</i>			
Các ngân hàng không bị kiệt quệ (Non-distressed banks)	0.0556	0.0641	2.19**
Các ngân hàng phá sản (Failed banks)	0.0730	0.0788	2.02**

	Giai đoạn trước khủng hoảng (Pre-crisis period)	Giai đoạn khủng hoảng (Crisis period)	Giai đoạn trước khủng hoảng so với Khủng hoảng (Pre-crisis vs Crisis (z-statistic))
Các ngân hàng được cứu trợ (Bailed-out banks)	0.0732	0.0778	2.31**
Các ngân hàng không bị kiệt quệ so với phá sản (Non-distressed vs Failed banks (z-statistic))	2.10**	1.99**	
Các ngân hàng không bị kiệt quệ so với được cứu trợ (Non-distressed vs Bailed-out banks (z-statistic))	2.24**	2.06**	
Các ngân hàng phá sản so với được cứu trợ (Failed vs Bailed-out banks (z-statistic))	1.38	1.40	
Panel D: NINTINC			
Các ngân hàng không bị kiệt quệ (Non-distressed banks)	0.0281	0.0305	0.93
Các ngân hàng phá sản (Failed banks)	0.0382	0.0274	1.05
Các ngân hàng được cứu trợ (Bailed-out banks)	0.0820	0.0873	2.09**
Các ngân hàng không bị kiệt quệ so với phá sản (Non-distressed vs Failed banks (z-statistic))	1.14	1.07	
Các ngân hàng không bị kiệt quệ so với được cứu trợ (Non-distressed vs Bailed-out banks (z-statistic))	3.95***	4.11***	
Các ngân hàng phá sản so với được cứu trợ (Failed vs Bailed-out banks (z-statistic))	2.44**	2.70***	

Bảng này trình bày các sai lệch so với Định luật Benford đối với chữ số không giữa ba loại hình ngân hàng (các ngân hàng không bị kiệt quệ, phá sản, và được cứu trợ) và trong hai giai đoạn thời gian đối với bốn biến số (TIER1, LLP, INTINC, NINTINC) được phát hiện là bị thao túng trong phân tích cơ sở của chúng tôi. Các giá trị của các kiểm định ý nghĩa thống kê liên quan dựa trên thống kê z cũng được báo cáo. Tất cả các biến số và nguồn dữ liệu của chúng được mô tả trong Bảng 2. ***, **, và * chỉ ra ý nghĩa thống kê tương ứng ở mức 1%, 5%, và 10%.

Bảng 6 Phân tích chữ số ở vị trí thứ nhất trong giai đoạn trước khủng hoảng

		TIER1 Không kiệt quệ n=130,924	TIER1 Phá sản n=9,093	TIER1 Được cứu trợ n=16,690	LLP Không kiệt quệ n=130,337	LLP Phá sản n=8,792	LLP Được cứu trợ n=15,973	INTINC Không kiệt quệ n=131,527	INTINC Phá sản n=9,361	INTINC Được cứu trợ n=17,190	NINTINC Không kiệt quệ n=131,534	NINTINC Phá sản n=9,340	NINTINC Được cứu trợ n=17,118	CASH Không kiệt quệ n=131,429	CASH Phá sản n=9,305	CASH Được cứu trợ n=12,345
Chữ số (Digit)	Tần số kỳ vọng (Exp. freq.)	Sai lệch quan sát (z-statistic)	Sai lệch quan sát (z-statistic)	Sai lệch quan sát (z-statistic)	Sai lệch quan sát (z-statistic)	Sai lệch quan sát (z-statistic)	Sai lệch quan sát (z-statistic)	Sai lệch quan sát (z-statistic)	Sai lệch quan sát (z-statistic)	Sai lệch quan sát (z-statistic)	Sai lệch quan sát (z-statistic)	Sai lệch quan sát (z-statistic)	Sai lệch quan sát (z-statistic)	Sai lệch quan sát (z-statistic)	Sai lệch quan sát (z-statistic)	Sai lệch quan sát (z-statistic)
1	.3010	0.0498 1.93* 0.0162	0.0582 2.05** 0.0163	0.0652 1.75* 0.0244	-0.0582 -2.12** -0.0164	-0.0692 -2.36** -0.0087	-0.0882 -2.31** -0.0142	0.0641 2.69*** 0.0438	0.0788 3.29*** 0.0502	0.0778 3.15*** 0.0376	0.0205 1.44 0.0192	0.0174 1.39 0.0188	0.0873 2.41** 0.0355	-0.0041 -1.05 0.0037	-0.0082 -0.78 -0.0055	0.0079 1.15 0.0053
2	.1761	1.42 1.51 -0.0034	1.51 1.51 0.0098	1.41 1.41 0.0109	-1.55 -1.55 0.0133	-0.96 -0.96 0.0058	-1.24 -1.24 -0.0100	1.85* 1.85* 0.0203	2.31** 2.31** 0.0173	2.34** 2.34** 0.0083	1.40 1.20 0.0091	1.20 1.20 -0.0044	2.06** 2.06** -0.0089	0.56 0.56 0.0048	-0.89 -0.89 0.0040	1.02 1.02 -0.0067
3	.1249	-1.03 0.0028 0.0028	0.65 -0.0104 -0.0104	0.94 0.0086 0.0086	1.14 0.0117 0.0117	1.14 0.0117 0.0117	0.89 0.0023 0.0023	1.25 0.0102 0.0102	1.30 0.0187 0.0187	1.36 0.0050 0.0050	0.89 -0.0074 -0.0074	-0.96 0.0063 0.0063	-1.04 -0.0058 -0.0058	0.39 0.0009 0.0009	1.04 0.0027 0.0027	-0.38 -0.0050 -0.0050
4	.0969	0.95 0.0014 0.0014	-1.12 0.0059 0.0059	1.23 -0.0097 -0.0097	0.81 -0.0084 -0.0084	1.02 -0.0009 -0.0009	0.78 0.0023 0.0023	0.97 0.0056 0.0056	0.86 0.0112 0.0112	0.86 -0.0057 -0.0057	-1.04 -0.0042 -0.0042	0.69 0.0018 0.0018	-0.96 -0.0033 -0.0033	0.56 -0.0017 -0.0017	1.18 0.0013 0.0013	-0.59 0.0018 0.0018
5	.0792	0.74 0.0010 0.0010	0.75 0.0020 0.0020	-0.82 -0.0021 -0.0021	-1.18 -0.0041 -0.0041	-1.01 0.0012 0.0012	0.59 -0.0009 -0.0009	1.28 0.0024 0.0024	0.68 0.0086 0.0086	-0.71 0.0007 0.0007	-0.73 -0.0019 -0.0019	1.07 0.0049 0.0049	-0.40 0.0004 0.0004	-0.70 0.0008 0.0008	0.64 0.0010 0.0010	0.68 0.0010 0.0010
6	.0670	0.83 -0.0020 -0.0020	0.97 0.0009 0.0009	-0.33 0.0038 0.0038	-0.94 0.0072 0.0072	0.87 -0.0034 -0.0034	-1.03 -0.0014 -0.0014	1.10 0.0052 0.0052	1.03 0.0090 0.0090	1.26 -0.0035 -0.0035	0.67 0.0010 0.0010	0.61 0.0028 0.0028	1.28 0.0035 0.0035	1.02 0.0033 0.0033	0.89 -0.0101 -0.0101	1.05 -0.0006 -0.0006
7	.0580	-0.65 -0.0031 -0.0031	0.59 -0.0055 -0.0055	0.70 -0.0085 -0.0085	1.19 0.0131 0.0131	-1.09 -0.0034 -0.0034	-1.12 0.0068 0.0068	0.79 0.0104 0.0104	0.78 -0.0102 -0.0102	-1.04 -0.0087 -0.0087	0.77 -0.0035 -0.0035	0.99 0.0051 0.0051	0.49 -0.0104 -0.0104	0.87 -0.0028 -0.0028	-1.19 -0.0092 -0.0092	-0.82 -0.0021 -0.0021
8	.0512	-0.88 -0.0114 -0.0114	-1.01 -0.0198 -0.0198	-1.05 -0.0209 -0.0209	0.94 0.0133 0.0133	1.17 0.0073 0.0073	1.17 0.0138 0.0138	0.83 -0.0278 -0.0278	-1.24 -0.0412 -0.0412	-0.96 -0.0382 -0.0382	-0.82 -0.0068 -0.0068	0.52 -0.0104 -0.0104	-1.33 -0.0280 -0.0280	-0.54 -0.0052 -0.0052	-0.85 0.0122 0.0122	-0.78 0.0064 0.0064
9	.0458	-1.29 $\chi^2_{(9)}$	-1.49 14.93*	-1.46 15.11*	1.47 17.56**	1.40 19.25***	1.32 19.81**	-1.76* 19.95**	-2.36** 24.39***	-1.97** 23.17***	-1.16 9.60	-1.21 5.80	-2.24** 22.70***	-0.69 6.18	1.06 4.29	1.20 5.07

Cột đầu tiên của Bảng liệt kê các chữ số có khả năng xuất hiện ở vị trí thứ nhất của các biến số được kiểm tra, trong khi tần số xuất hiện kỳ vọng cho mỗi chữ số được xác định bởi Định luật Benford được trình bày ở cột thứ hai. Phần còn lại của các cột báo cáo các sai lệch quan sát được giữa tần số thực tế và kỳ vọng cho từng biến số (TIER1, LLP, INTINC, NINTINC, CASH) đối với các nhóm ngân hàng không bị kiệt quệ, phá sản, và được cứu trợ trong giai đoạn trước khủng hoảng. Giá trị của thống kê z và mức ý nghĩa tương ứng được trình bày bên dưới sai lệch quan sát được cho mỗi chữ số. Các giá trị của kiểm định mức độ phù hợp (goodness-of-fit) chi-bình phương được báo cáo ở hàng cuối cùng của Bảng. Tất cả các biến số và nguồn dữ liệu của chúng được mô tả trong Bảng 2. ***, **, và * chỉ ra ý nghĩa thống kê tương ứng ở mức 1%, 5%, và 10%.

Bảng 7 Kiểm tra tính vững: Phân tích chữ số ở vị trí thứ hai trong giai đoạn trước khủng hoảng

Chữ số (Digit)	Tần số kỳ vọng (Exp. freq.)	EQUITY Không kiệt quệ n=118,939	EQUITY Phá sản n=8,190	EQUITY Được cứu trợ n=14,830	NPL Không kiệt quệ n=117,592	NPL Phá sản n=7,592	NPL Được cứu trợ n=14,142	ALLOW Không kiệt quệ n=118,671	ALLOW Phá sản n=7,920	ALLOW Được cứu trợ n=14,721	EARNAS Không kiệt quệ n=119,265	EARNAS Phá sản n=8,328	EARNAS Được cứu trợ n=15,275	REPOS Không kiệt quệ n=116,846	REPOS Phá sản n=7,146	REPOS Được cứu trợ n=13,951
		Sai lệch quan sát (z-statistic)	Sai lệch quan sát (z-statistic)	Sai lệch quan sát (z-statistic)	Sai lệch quan sát (z-statistic)	Sai lệch quan sát (z-statistic)	Sai lệch quan sát (z-statistic)	Sai lệch quan sát (z-statistic)	Sai lệch quan sát (z-statistic)	Sai lệch quan sát (z-statistic)	Sai lệch quan sát (z-statistic)	Sai lệch quan sát (z-statistic)	Sai lệch quan sát (z-statistic)	Sai lệch quan sát (z-statistic)	Sai lệch quan sát (z-statistic)	Sai lệch quan sát (z-statistic)
0	.1197	0.0031	0.0163	0.0176	-0.0105	-0.0310	-0.0352	-0.0053	-0.0682	-0.0662	0.0488	0.0632	0.0671	0.0040	0.0184	0.0081
1	.1139	0.44	1.04	1.34	-1.28	-1.33	-1.20	-0.85	-2.31**	-2.14**	2.08**	2.12**	2.39**	0.49	1.03	1.16
		0.0021	0.0103	0.0098	-0.0074	-0.0206	-0.0198	0.0046	-0.0201	-0.0170	0.0374	0.0459	0.0391	-0.0038	0.0128	0.0052
2	.1088	0.49	1.11	1.17	-1.12	-1.42	-1.31	0.94	-1.44	-1.38	1.98**	2.05**	1.73*	-0.62	1.21	1.05
		0.0014	0.0053	0.0072	0.0079	-0.0131	-0.0149	-0.0037	-0.0130	-0.0094	0.0137	0.0208	0.0157	-0.0022	-0.0094	0.0027
3	.1043	0.36	1.16	1.23	1.18	-1.20	-1.28	-1.08	-1.39	-1.56	1.39	1.43	1.31	-0.48	-0.52	0.43
		-0.0052	0.0031	-0.0041	0.0061	0.0127	-0.0102	-0.0044	0.0083	-0.0062	-0.0125	0.0121	-0.0059	0.0020	-0.0048	-0.0034
4	.1003	-0.60	0.94	-0.84	1.05	1.29	-0.95	-1.08	1.32	-0.49	-1.20	1.29	-1.33	0.93	-0.71	-0.87
		-0.0023	-0.0023	-0.0031	0.0053	0.0114	0.0061	-0.0035	0.0057	0.0027	-0.0108	-0.0054	-0.0038	0.0014	0.0016	-0.0028
5	.0967	-0.37	-0.99	-0.99	0.95	0.69	0.86	-1.14	1.20	0.83	-1.19	-1.38	-0.61	0.61	0.34	-1.16
		0.0019	-0.0014	-0.0022	-0.0054	0.0086	0.0048	-0.0023	-0.0021	-0.0017	0.0095	-0.0032	-0.0021	0.0008	0.0003	0.0032
6	.0934	0.43	-1.18	-1.05	-1.02	0.43	0.22	-0.85	-0.95	-1.14	0.98	-0.76	-0.83	0.42	1.10	1.37
		0.0030	0.0020	0.0084	-0.0069	0.0140	0.0031	0.0057	0.0019	-0.0011	0.0084	0.0048	0.0015	0.0004	-0.0011	0.0039
7	.0904	0.61	0.43	0.59	-0.93	-0.53	1.05	1.11	1.36	-1.23	0.69	1.02	1.25	0.67	-0.74	1.41
		-0.0039	0.0038	0.0096	0.0089	0.0101	-0.0101	0.0096	0.0203	0.0119	-0.0083	-0.0105	-0.0116	-0.0014	0.0040	0.0047
8	.0876	-0.28	0.75	1.14	1.05	1.18	-0.74	1.08	1.16	1.30	-1.15	-1.38	-1.30	-1.02	1.32	0.78
		-0.0045	0.0096	0.0101	0.0094	0.0232	0.0160	0.0129	0.0241	0.0284	-0.0264	-0.0319	-0.0261	-0.0027	0.0111	-0.0109
9	.0850	-0.44	1.09	0.78	1.07	1.39	1.41	0.64	1.54	1.27	-1.76*	-1.84*	-1.78*	-0.94	1.29	-1.11
		0.0059	-0.0149	0.0126	0.0101	0.0288	0.0387	0.0148	0.0574	0.0620	-0.0608	-0.0841	-0.0858	-0.0049	0.0173	-0.0125
$\chi^2(9)$		0.33	-0.85	1.30	1.18	1.51	1.44	1.22	2.43**	2.49**	-2.31**	-2.34**	-2.36**	-0.88	0.42	-0.94
		2.49	4.62	3.19	4.93	10.74	9.17	6.09	18.34**	17.55**	17.48**	18.94**	17.27**	2.90	2.62	4.01

Cột đầu tiên của Bảng liệt kê tất cả mười chữ số có khả năng xuất hiện ở vị trí thứ hai của các biến số được kiểm tra, trong khi tần số xuất hiện kỳ vọng cho mỗi chữ số được xác định bởi Định luật Benford được trình bày ở cột thứ hai. Phần còn lại của các cột báo cáo các sai lệch quan sát được giữa tần số thực tế và kỳ vọng cho từng biến số (EQUITY, NPL, ALLOW, EARNAS, REPOS) đối với các nhóm ngân hàng không bị kiệt quệ, phá sản, và được cứu trợ trong giai đoạn trước khủng hoảng. Giá trị của thống kê z và mức ý nghĩa tương ứng được trình bày bên dưới sai lệch quan sát được cho mỗi chữ số. Các giá trị của kiểm định mức độ phù hợp (goodness-of-fit) chi-bình phương được báo cáo ở hàng cuối cùng của Bảng. Tất cả các biến số và nguồn dữ liệu của chúng được mô tả trong Bảng 2. ***, **, và * chỉ ra ý nghĩa thống kê tương ứng ở mức 1%, 5%, và 10%.

Bảng 8 Kiểm tra tính vững: Phân tích chữ số ở vị trí thứ hai trong giai đoạn khủng hoảng

Chữ số (Digit)	Tần số kỳ vọng (Exp. freq.)	EQUITY Không kiệt quệ n=130,948	EQUITY Phá sản n=9,115	EQUITY Được cứu trợ n=16,782	NPL Không kiệt quệ n=130,271	NPL Phá sản n=8,830	NPL Được cứu trợ n=15,984	ALLOW Không kiệt quệ n=130,751	ALLOW Phá sản n=9,064	ALLOW Được cứu trợ n=16,572	EARNAS Không kiệt quệ n=131,208	EARNAS Phá sản n=9,293	EARNAS Được cứu trợ n=17,025	REPOS Không kiệt quệ n=129,892	REPOS Phá sản n=8,603	REPOS Được cứu trợ n=15,648
		Sai lệch quan sát (z-statistic)	Sai lệch quan sát (z-statistic)	Sai lệch quan sát (z-statistic)	Sai lệch quan sát (z-statistic)	Sai lệch quan sát (z-statistic)	Sai lệch quan sát (z-statistic)	Sai lệch quan sát (z-statistic)	Sai lệch quan sát (z-statistic)	Sai lệch quan sát (z-statistic)	Sai lệch quan sát (z-statistic)	Sai lệch quan sát (z-statistic)	Sai lệch quan sát (z-statistic)	Sai lệch quan sát (z-statistic)	Sai lệch quan sát (z-statistic)	Sai lệch quan sát (z-statistic)
0	.1197	0.0053	0.0178	0.0196	-0.0096	-0.0704	-0.0744	-0.0067	-0.0894	-0.0803	0.0592	0.0829	0.0794	0.0053	-0.0143	0.0102
1	.1139	0.49	1.21	1.22	-1.13	-2.16**	-2.17**	-1.04	-2.71***	-2.37**	2.32**	2.42**	3.19***	0.61	-0.64	0.99
		0.0034	0.0096	0.0102	-0.0083	-0.0140	-0.0261	-0.0052	-0.0242	-0.0194	0.0457	0.0461	0.0305	-0.0059	0.0111	0.0065
2	.1088	0.40	0.87	1.08	-1.07	-1.36	-1.48	0.81	-1.59	-1.50	2.01**	2.08**	1.99**	-0.77	0.96	1.37
		0.0022	0.0099	0.0051	0.0068	-0.0084	-0.0108	0.0037	-0.0096	-0.0105	0.0170	0.0163	0.0104	-0.0041	-0.0060	0.0014
3	.1043	0.31	1.10	1.06	0.94	-1.12	-0.96	0.93	-1.27	-1.26	1.22	1.31	1.20	-0.55	-0.78	0.38
		-0.0062	0.0048	-0.0064	0.0032	-0.0102	-0.0082	-0.0024	0.0080	-0.0093	-0.0103	0.0100	-0.0063	0.0018	-0.0031	-0.0026
4	.1003	-0.78	1.23	-1.11	0.94	-0.47	-1.01	-0.92	0.97	-1.02	-1.12	0.99	-0.85	1.15	-1.04	-1.02
		-0.0037	-0.0056	-0.0048	0.0021	0.0021	0.0096	-0.0025	0.0063	0.0009	-0.0089	-0.0067	-0.0048	0.0007	0.0019	-0.0017
5	.0967	-0.45	-1.04	-0.82	1.10	0.77	0.72	-1.03	0.81	0.33	-0.93	-1.20	-0.79	0.59	0.69	-0.48
		0.0028	-0.0028	-0.0019	-0.0034	0.0038	0.0037	-0.0010	-0.0080	-0.0008	0.0063	-0.0019	-0.0013	0.0004	0.0012	0.0006
6	.0934	0.46	-0.89	-0.70	-0.89	1.13	1.17	-1.01	-1.03	-0.84	1.16	-0.80	-1.01	0.69	0.98	1.40
		0.0021	0.0035	0.0059	-0.0047	-0.0059	0.0064	0.0038	0.0028	-0.0042	0.0042	0.0058	0.0029	0.0012	0.0008	0.0034
7	.0904	0.74	0.62	0.64	-1.05	-1.00	1.26	0.89	1.08	-0.92	1.04	0.81	0.97	0.84	-1.26	0.87
		-0.0052	0.0049	0.0108	0.0078	0.0104	-0.0108	0.0076	0.0163	0.0126	0.0067	-0.0096	-0.0090	-0.0011	0.0031	0.0040
8	.0876	-0.21	1.13	1.30	1.16	1.27	-0.99	1.17	0.86	1.12	0.91	-1.12	-1.22	-0.93	0.86	0.61
		-0.0046	0.0111	0.0119	0.0107	0.0188	0.0192	0.0104	0.0199	0.0205	-0.0305	-0.0350	-0.0278	-0.0020	0.0076	-0.0094
9	.0850	-0.35	0.92	0.82	0.88	1.50	1.51	0.52	1.50	1.48	-1.84*	-1.75*	-2.15**	-1.03	0.64	-0.78
		0.0060	-0.0158	0.0132	0.0136	0.0673	0.0787	0.0125	0.0914	0.0762	-0.0737	-0.0918	-0.0924	-0.0056	0.0103	-0.0103
$\chi^2_{(9)}$		0.32	-1.20	1.41	1.24	2.02**	2.11**	1.33	2.49**	3.04***	-2.47**	-2.27**	-3.38***	-0.71	1.29	-1.11
		3.16	5.17	4.34	5.27	17.20**	17.16**	5.82	23.78***	23.71***	19.04**	18.03***	24.96***	3.37	3.38	4.55

Cột đầu tiên của Bảng liệt kê tất cả mười chữ số có khả năng xuất hiện ở vị trí thứ hai của các biến số được kiểm tra, trong khi tần số xuất hiện kỳ vọng cho mỗi chữ số được xác định bởi Định luật Benford được trình bày ở cột thứ hai. Phần còn lại của các cột báo cáo các sai lệch quan sát được giữa tần số thực tế và kỳ vọng cho từng biến số (EQUITY, NPL, ALLOW, EARNAS, REPOS) đối với các nhóm ngân hàng không bị kiệt quệ, phá sản, và được cứu trợ trong giai đoạn khủng hoảng. Giá trị của thống kê z và mức ý nghĩa tương ứng được trình bày bên dưới sai lệch quan sát được cho mỗi chữ số. Các giá trị của kiểm định mức độ phù hợp (goodness-of-fit) chi-bình phương được báo cáo ở hàng cuối cùng của Bảng. Tất cả các biến số và nguồn dữ liệu của chúng được mô tả trong Bảng 2. ***, **, và * chỉ ra ý nghĩa thống kê tương ứng ở mức 1%, 5%, và 10%.

Bảng 9 Mô hình hệ số bóp méo (Distortion factor model)

	EQUITY DF (z-statistic)	TIER1 DF (z-statistic)	NPL DF (z-statistic)	ALLOW DF (z-statistic)	LLP DF (z-statistic)	EARNAS DF (z-statistic)	INTINC DF (z-statistic)	NINTINC DF (z-statistic)	CASH DF (z-statistic)	REPOS DF (z-statistic)
Panel A: Giai đoạn trước khủng hoảng (Pre-crisis period)										
Các ngân hàng không kiệt quệ (Non-distressed banks)	1.61	1.33	-0.78	-2.38	-3.19	7.41	5.31	-1.01	0.75	0.89
(số quan sát, obs = 6,302)	0.49	1.06	-0.50	-1.46	-1.72*	1.78*	2.14**	-0.47	1.27	0.55
Các ngân hàng phá sản (Failed banks)	-1.05	2.11	-2.95	-5.94	-3.51	6.93	7.89	1.18	-1.08	1.64
(số quan sát, obs = 448)	-0.67	1.18	-1.80*	-2.27**	-1.96**	2.40**	2.35**	1.50	-0.79	1.30
Các ngân hàng được cứu trợ (Bailed-out banks)	1.89	1.97	-3.76	-6.20	-6.63	6.53	6.21	7.42	-1.33	0.82
(số quan sát, obs = 815)	1.04	0.85	-1.93*	-1.91*	-2.38**	2.68***	2.14**	1.86*	-1.10	1.25
Panel B: Giai đoạn khủng hoảng (Crisis period)										
Các ngân hàng không kiệt quệ (Non-distressed banks)	1.90	5.89	-1.38	-3.58	-3.85	7.82	5.12	-0.75	0.38	1.38
(số quan sát, obs = 6,302)	0.52	1.74*	-0.72	-1.60	-1.94*	1.97**	2.08**	-0.50	1.45	1.06
Các ngân hàng phá sản (Failed banks)	-2.19	7.41	-6.44	-8.53	-4.98	9.30	8.75	1.39	-0.96	2.16
(số quan sát, obs = 448)	-0.58	1.85*	-1.91*	-2.42**	-2.31**	3.17***	2.48**	1.28	-0.59	1.48
Các ngân hàng được cứu trợ (Bailed-out banks)	2.30	8.09	-6.79	-7.64	-7.53	8.81	6.93	8.94	-2.00	0.77
(số quan sát, obs = 815)	1.21	2.27**	-2.04**	-2.10**	-2.17**	2.80***	3.61***	2.31**	-1.29	1.14

Bảng này hiển thị các giá trị DF tính theo phần trăm cho từng biến được xem xét, đối với các ngân hàng không kiệt quệ, phá sản và được cứu trợ. Giá trị của thống kê z và các mức ý nghĩa tương ứng được trình bày bên dưới các giá trị DF. Kết quả ở Panel A thuộc thời kỳ trước khủng hoảng. Kết quả ở Panel B thuộc thời kỳ khủng hoảng. Để tính đến khả năng thiên lệch chọn mẫu trong dữ liệu của chúng tôi, chúng tôi loại bỏ mọi giá trị ngoại lai khỏi các tập ngân hàng phá sản và được cứu trợ. Tất cả các biến và nguồn dữ liệu của chúng được mô tả trong Bảng 2.

***, ** và * chỉ ra ý nghĩa thống kê tương ứng ở mức 1%, 5% và 10%.

ĐỌC THÊM 2: TÁC ĐỘNG CỦA VIỆC ĐÁNH CẤP DỮ LIỆU LÊN GIÁ TRỊ THỊ TRƯỜNG CỦA DOANH NGHIỆP

9.1 THÔNG TIN NGUỒN

- **Nguồn:** Chang, Kuo-Chung. "The Effect of Data Theft on a Firm's Short-Term and Long-Term Market Value." *Mathematics*, vol. 8, no. 5, 2020. <https://www.mdpi.com/2227-7390/8/5/808/htm>
- **Phần cần đọc:** tr. 6–7 (10 phút)

9.2 PHÁT TRIỂN CÁC GIẢ THUYẾT

Các vụ vi phạm dữ liệu (data breaches) khiến tổ chức phải chịu thêm chi phí nhân công để khắc phục sự cố và sửa chữa các dữ liệu và hệ thống bị hỏng. Chúng cũng có thể dẫn đến việc giảm năng suất và giảm doanh thu do thời gian ngừng hoạt động (downtime) ngoài dự kiến. Các chi phí bổ sung khác bao gồm thiết lập đường dây nóng cho khách hàng, cung cấp dịch vụ giám sát tín dụng cho nạn nhân cũng như các khoản phí kiện tụng. Những chi phí này có thể tác động tạm thời đến hoạt động kinh doanh hoặc dẫn đến những khoản phí tức thì đối với khả năng sinh lời dự kiến của công ty. Do đó, một công ty bị vi phạm dữ liệu dự kiến sẽ gặp phải sự sụt giảm trong dòng tiền thuần tương lai của mình. Kết quả là, các nhà đầu tư sẽ đánh giá lại định giá của họ đối với công ty. Vì vụ vi phạm dự kiến sẽ có tác động tiêu cực đến dòng tiền thuần, các mức định giá cũng dự kiến sẽ giảm xuống. Như vậy, chúng tôi đưa ra giả thuyết:

Giả thuyết 1 (H1). *Việc công bố một vụ vi phạm dữ liệu có tác động tiêu cực đến giá trị thị trường ngắn hạn của công ty bị vi phạm.*

Ngoài những hậu quả mang tính nhất thời đối với hiệu quả tài chính, tác động của các vụ vi phạm dữ liệu là rất sâu rộng và có thể gây tổn hại cho các công ty ở bất kỳ quy mô nào. Những hệ lụy của các sự cố vi phạm có thể tiếp diễn trong nhiều năm tới. Bên cạnh các chi phí trả trước cho việc thông báo tới các chủ thể dữ liệu cùng với việc điều tra và kiểm soát vụ vi phạm, các tập đoàn cũng phải đối mặt với nguy cơ bị kiện tụng và nộp phạt, cũng như các chi phí vô hình khác liên quan đến thiệt hại về thương hiệu và uy tín doanh nghiệp. Sự sụt giảm uy tín này có thể đồng nghĩa với việc mất khách hàng cũng như sự sụt giảm trong việc thu hút khách hàng mới, bởi vì mối quan hệ giữa an ninh dữ liệu và định giá thị trường của công ty có thể được quy cho niềm tin của khách hàng. Các nghiên cứu đã chỉ ra rằng an ninh dữ liệu là thiết yếu đối với niềm tin của khách hàng do những lo ngại liên quan đến quyền riêng tư thông tin [38–40]. Những khách hàng hiện tại có thể không sẵn lòng giao dịch với công ty bị vi phạm vì những lo ngại về quyền riêng tư. Hậu quả là, công ty bị vi phạm phải chịu sự sụt giảm lòng trung thành của khách hàng cũng như tốc độ thu hút khách hàng mới bị thu hẹp. Hơn nữa, các vụ vi phạm an ninh cũng có thể dẫn đến chi phí kinh doanh trong

tương lai cao hơn do sự e ngại của các đối tác hoặc nhà cung cấp khi tiếp tục quan hệ hợp tác với các công ty bị vi phạm. Từ đó, tác động tiêu cực đến khả năng sinh lời dài hạn của công ty. Thêm vào đó, các hành động pháp lý phát sinh do vụ vi phạm cũng sẽ gây ra nghĩa vụ tài chính liên tục đáng kể, đặc biệt là nếu các vụ kiện thành công hoặc tiếp tục kéo dài. Do vậy, chúng tôi đưa ra giả thuyết:

Giả thuyết 2 (H2). *Việc công bố vụ vi phạm dữ liệu có tác động tiêu cực đến giá trị thị trường dài hạn của công ty bị vi phạm.*

Mức độ nghiêm trọng tiềm tàng của vụ vi phạm có khả năng tương quan với số lượng hồ sơ bị lộ. Tài liệu tham khảo [7] đã phát hiện một mối quan hệ thuận chiều giữa số lượng thẻ tín dụng bị lộ và độ lớn của các tỷ suất sinh lợi bất thường âm trong một mẫu rất nhỏ gồm bốn trường hợp. Các phát hiện từ một cuộc khảo sát do [41] thực hiện cũng cho thấy có một mối tương quan thuận giữa số lượng hồ sơ bị lộ và chi phí của vụ vi phạm dữ liệu. Vì vậy, chúng tôi đưa ra giả thuyết:

Giả thuyết 3.1 (H3.1). *Quy mô của vụ vi phạm dữ liệu có tương quan thuận với tỷ suất sinh lợi âm cao hơn đối với giá trị thị trường ngắn hạn của công ty bị vi phạm.*

Khi một sự kiện vi phạm dữ liệu xảy ra, chúng ta không thể ngay lập tức biết được quy mô chính xác về tác động của sự cố nếu chỉ dựa vào kích thước của vụ rò rỉ. Ví dụ, trong sự cố vi phạm dữ liệu của SONY, sau thông báo đầu tiên về vụ vi phạm, quy mô của các vụ vi phạm tiếp tục mở rộng theo thời gian ngay cả sau khi được phát hiện, do sự tiến hóa trong loại hình xâm nhập của kẻ tấn công và hành vi đánh cắp cơ hội của những kẻ xâm nhập bằng cách ẩn nấp trong các chương trình hoặc các bộ phận khác thuộc hệ thống thông tin của tổ chức. Vì thế, nếu chỉ điều tra mối quan hệ giữa quy mô vụ vi phạm dữ liệu mà một công ty phải gánh chịu và các hiệu ứng ngắn hạn của nó thì không thể là một thước đo hoàn chỉnh về tác động của sự cố. Hơn nữa, các vụ vi phạm dữ liệu lớn hơn sẽ dẫn đến việc mất nhiều khách hàng hơn và các trách nhiệm pháp lý theo sau tương đối nặng nề hơn, và do đó tác động của sự cố cũng sẽ được duy trì trong dài hạn. Vì vậy, không những quy mô của các sự cố không thể được đo lường đầy đủ trong ngắn hạn, mà các thiệt hại pháp lý bồi thường theo sau cũng không thể được đo lường đầy đủ trong giai đoạn ngắn hạn ngay sau sự cố. Ví dụ, trong vụ vi phạm dữ liệu của Target năm 2013, trong đó khối lượng dữ liệu trị giá 70 triệu bảng Anh (pounds) [?] đã bị đánh cắp, một khoản tiền 39 triệu đô la

đã được chi trả vào năm 2015 cho vụ kiện tập thể [42]. Như chúng ta đã thấy ở đây, mặc dù sự cố vi phạm xảy ra vào năm 2013, khoản tiền bồi thường pháp lý đã không được quyết định cho đến năm 2015. Đã mất ít nhất hai năm để tác động từ sự cố vi phạm của Target được hiện thực hóa đầy đủ. Do đó, chúng tôi đưa ra giả thuyết:

Giả thuyết 3.2 (H3.2). *Quy mô của vụ vi phạm dữ liệu có tương quan thuận với tỷ suất sinh lợi âm cao hơn đối với giá trị thị trường dài hạn của công ty bị vi phạm.*

ĐỌC THÊM 3: CÁC VẤN ĐỀ CHẤT LƯỢNG DỮ LIỆU ĐỐI VỚI NHÀ NGHIÊN CỨU KINH DOANH VÀ TÀI CHÍNH

10.1 THÔNG TIN NGUỒN

- **Nguồn:** Liu, Grace. "Data Quality Problems Troubling Business and Financial Researchers: A Literature Review and Synthetic Analysis." *Journal of Business & Finance Librarianship*, 2020. https://digitalcommons.wcupa.edu/lib_facpub/13/
- **Phần cần đọc:** tr. 29–36 (25 phút)

câu hỏi nghiên cứu, cung cấp cho các nhà nghiên cứu kinh doanh và thủ thư thông tin về các vấn đề dữ liệu phổ biến và thảo luận về hàm ý của chúng đối với tham khảo kinh doanh và tư vấn nghiên cứu.

10.2 CÁC VẤN ĐỀ CHẤT LƯỢNG DỮ LIỆU (DATA QUALITY PROBLEMS) PHỔ BIẾN

10.3 GIÁ TRỊ BỊ THIẾU (MISSING VALUES)

Giá trị bị thiếu là một trong những vấn đề chất lượng dữ liệu phổ biến nhất. Các tệp dữ liệu CRSP được phát hiện bị thiếu lợi suất hủy niêm yết (delisting returns), lợi suất quỹ tương hỗ (mutual fund returns) và các danh mục quỹ tương hỗ bắt buộc (Shumway, 1997; Elton et al., 2001; Wisen, 2002; Schwarz & Potter, 2016). Một lượng lớn dữ liệu bị bỏ sót đã được xác định trong Compustat (Boritz & No, 2013; Casey et al., 2016; Heitzman & Lester, 2020). Sự bỏ sót dữ liệu về “chủ sở hữu cuối cùng toàn cầu” (global ultimate owner) đã được báo cáo trong Orbis (Jaraitė et al., 2013). Dữ liệu hạn mức tín dụng (credit line) và dữ liệu nợ chưa thanh toán (outstanding debt) trong Capital IQ được quan sát thấy có một lượng lớn các giá trị bị thiếu (Mathers & Giacomini, 2016; Lee, 2017). Dữ liệu bảng cân đối kế toán, dữ liệu số lượng nhân viên được báo cáo và dữ liệu lợi suất thực tế trên tài sản chương trình hưu trí (actual return on plan assets) được phát hiện bị thiếu trong Worldscope (Weiß & Mühlhnickel, 2014; McGuire et al., 2016; Nobes & Stadler, 2018). Thông tin cho những người dự thầu, điều khoản chấm dứt (termination provisions), thông báo mua lại cổ phần (share repurchase announcements), thông báo tiếp quản (takeover announcements) và các sự kiện liên quan đến sáp nhập được phát hiện bị thiếu trong SDC (Faccio & Masulis, 2005; Boone & Mulherin, 2007; Banyan et al., 2008; Mulherin & Aziz Simsir, 2015). Dữ liệu phát hành trái phiếu, dữ liệu tài chính cổ phiếu, dữ liệu đối thủ cạnh tranh và dữ liệu cây sản phẩm trong Mergent Online được phát hiện không đầy đủ (Tallapally, 2009; Ma et al., 2011; Berrios, 2013; Lu & Shang, 2017).

Các nhà nghiên cứu thường xác định các giá trị bị thiếu bằng cách so sánh trực tiếp dữ liệu với dữ liệu gốc trong các hồ sơ gửi lên SEC và gần đây hơn là với dữ liệu tương tác được

gắn thẻ XBRL (XBRL-tagged) từ hệ thống EDGAR của SEC (Tallapally et al., 2011; Boritz & No, 2013; Chychyla & Kogan, 2015; Schwarz & Potter, 2016). Giá trị bị thiếu xảy ra phổ biến hơn đối với các khái niệm kế toán phức tạp như “lỗ hoạt động ròng” (net operating loss), “hạn mức tín dụng”, “nợ chưa thanh toán”, “lợi suất thực tế trên tài sản chương trình hưu trí” (Mathers & Giacomini, 2016; Lee, 2017; Nobes & Stadler, 2018; Heitzman & Lester, 2020). Giá trị bị thiếu cũng thường xuyên xảy ra hơn đối với các giao dịch phức tạp cần nhiều nỗ lực để theo dõi các thay đổi như mua lại cổ phần và sáp nhập và mua lại (M&A) (Banyi et al., 2008; Chapman & Klein, 2009; Netter et al., 2011). Giá trị bị thiếu thường được quan sát thấy nhiều hơn đối với dữ liệu trong các phần chú thích hoặc dữ liệu không xuất hiện trực tiếp trên báo cáo tài chính, chẳng hạn như “lợi suất thực tế trên tài sản chương trình hưu trí” hoặc “tín dụng tuần hoàn chưa rút” (undrawn revolving credit) (Mathers & Giacomini, 2016; Nobes & Stadler, 2018). Trong Orbis, giá trị bị thiếu cũng có thể xảy ra do giới hạn về lượng dữ liệu được phép tải xuống (Kalemli-Ozcan et al., 2019).

Các nhà nghiên cứu đôi khi áp dụng các quy trình hoặc bộ lọc đặc biệt để loại trừ các giá trị bị thiếu khỏi mẫu nghiên cứu. Tuy nhiên, thực tiễn này chắc chắn có thể tạo ra thiên lệch bỏ sót (omission bias) hoặc thiên lệch chọn mẫu (selection biases) (Elton et al., 2001; Weiß & Mühlhnickel, 2014). Việc loại bỏ tất cả các quan sát chứa giá trị bị thiếu là một chiến lược ngây thơ và có thể có tác động rõ rệt đến sức mạnh thống kê của các phép kiểm định (Hribar, 2016, tr. 63). Loại trừ các giá trị bị thiếu có thể tạo ra các kết quả sai lệch và số lượng lớn các giá trị bị thiếu có thể làm cho một cơ sở dữ liệu không thể sử dụng được cho nghiên cứu cụ thể (Francis et al., 2016; Lee, 2017). Việc thiếu lợi suất hủy niêm yết có thể dẫn đến thiên lệch hủy niêm yết (delisting bias) và các thiên lệch dữ liệu chưa biết khác làm nhiễu kết quả thực nghiệm (Shumway, 1997; Shumway & Warther, 1999). Các giá trị bị thiếu có thể được giảm bớt bằng cách so sánh các tập dữ liệu với hồ sơ SEC hoặc các nguồn dữ liệu khác. Casey et al. (2016) đã đề xuất một

Mô hình Cân bằng Báo cáo Tài chính được Điều chỉnh (Modified Financial Statement Balancing Model) để giải quyết một phần các vấn đề về giá trị bị thiếu hoặc các mục nhập sai sót và khôi phục chúng thành các điểm dữ liệu có thể sử dụng được như số 0 hoặc các khoản tổng hợp.

10.4 LỖI DỮ LIỆU (DATA ERRORS)

Lỗi dữ liệu là một vấn đề chất lượng dữ liệu phổ biến khác. Nhiều lỗi số học, lỗi mã hóa, lỗi ngày sáp nhập, lỗi vị thế danh mục đầu tư đã được tìm thấy trong CRSP (Courtenay & Keller, 1994; Elton et al., 2001; Schwarz & Potter, 2016). Các lỗi đánh máy hoặc lỗi làm tròn, lỗi phân loại, lỗi tính toán, các biến số kiểm toán viên bị mã hóa sai đã được tìm thấy trong Compustat (San Miguel, 1977; Chychyla & Kogan, 2015); sự phân loại sai các thực thể và cổ đông đã được tìm thấy trong Orbis (Monasterolo et al., 2017). Sự chênh lệch (disparity) giữa dữ liệu hạn mức tín dụng Capital IQ và dữ liệu trong hồ sơ 10-K được phát hiện là đáng kể (Mathers & Giacomini, 2016). Mã nhà phân tích và ngày công bố thu nhập trong I/B/E/S được quan sát thấy bị lỗi báo cáo (Acker & Duck, 2009; Roger, 2017). Các lỗi dữ liệu về khối lượng (volume), giá cả, cổ phiếu, chỉ số lợi suất và tổng lợi suất, phân loại, ngày tháng và thông tin hủy niêm yết đã được tìm thấy trong Datastream (Bloom et al., 2004; Rossi, 2011; Brückner, 2013). Các lỗi trong đơn vị chào bán (unit offers), phân loại ngành, doanh số, tài sản, giá chào bán, giá thị trường hoặc giá trị thương vụ đã được báo cáo trong SDC. Tỷ lệ lỗi cao đối với số cổ phiếu đang lưu hành sau khi phát hành (post-issue shares outstanding), số lượng cổ phiếu phân bổ vượt mức (overallotment shares) được thực thi và số lượng nhà bảo lãnh phát hành quản lý (managing underwriters) cũng được báo cáo trong SDC (Ritter, 2019).

Nhiều nhà nghiên cứu xác định lỗi dữ liệu bằng cách so sánh các cơ sở dữ liệu khác nhau hoặc bằng cách so sánh cơ sở dữ liệu với dữ liệu thu thập thủ công của họ (Beedles & Simkowitz, 1978; Courtenay & Keller, 1994). Lỗi dữ liệu có thể xảy ra ở các dạng đơn giản như lỗi đánh máy hoặc lỗi làm tròn. Nhưng thường xuyên hơn, lỗi dữ liệu xảy ra ở các dạng phức tạp hơn. Lỗi dữ liệu có thể là kết quả của việc bao gồm hoặc loại trừ không đúng một số khoản mục kế toán trong các phép tính toán, chẳng hạn như gộp cả nghiên cứu theo hợp đồng (contract research) vào chi phí R&D, xử lý sai các hoạt động kinh doanh và đầu tư, loại trừ các khoản chênh lệch dồn tích phải trả (accrued imbalances payable) [?] khỏi các khoản phải trả (San Miguel, 1977; Shi & Zhang, 2011). Các lỗi có nhiều khả năng xảy ra đối với các khái niệm tài chính phức tạp như “giá vốn hàng bán” (cost of goods sold), “lợi nhuận gộp” (gross profit) hoặc “lỗ hoạt động ròng” hơn là đối với các khái niệm đơn giản như “tổng tài sản”, “tổng nợ phải trả” hoặc “thu nhập ròng” (Chychyla & Kogan, 2015; Heitzman & Lester, 2020). Lỗi thường xuyên xảy ra hơn đối với các giao dịch phức tạp như sáp nhập và mua lại, thay đổi sàn giao dịch, hủy niêm yết hoặc chia tách cổ phiếu (Andrikopoulos et al., 2007; Rossi, 2011; Nobes & Stadler, 2018; Ritter, 2019). Lỗi mã hóa sai trong các biến số kiểm toán viên xảy ra thường xuyên hơn khi có sự thay đổi kiểm toán viên (Utke, 2018). Tỷ lệ lỗi nói chung cao hơn đối với các khoản mục được báo cáo trong phần chú thích so với các khoản mục được báo cáo trên báo cáo kết quả hoạt động kinh doanh hoặc bảng cân đối kế toán (Kinney & Swanson, 1993; Bratten et al., 2016). Lỗi phân loại (classification errors) có thể xảy ra do sự hiểu nhầm các khái niệm kinh doanh và tài chính như cổ phiếu phổ thông hoặc phân loại ngành (Ince & Porter, 2006; Ritter, 2019). Về các công ty nước ngoài hoặc giao dịch nước ngoài, lỗi có thể phát sinh từ việc dịch hoặc diễn giải không đúng các thuật ngữ kế toán nước ngoài hoặc các điều kiện của công ty nước ngoài (Brückner, 2013; Nobes & Stadler, 2018). Các lỗi cũng phát sinh khi cơ sở dữ liệu không cập nhật dữ liệu kịp thời khi có những thay đổi về sàn giao dịch, phân loại ngành, kiểm toán viên, sự trình bày lại (restatement), v.v. (Rossi, 2011; Chychyla & Kogan, 2015; Utke, 2018).

Lỗi dữ liệu có thể làm bóp méo kết quả của các nghiên cứu liên quan theo nhiều cách (Acker & Duck, 2009). Việc làm tròn giá đến đồng xu (penny) gần nhất có thể không phải là một lỗi nghiêm trọng (hard error), nhưng nó có thể gây ra những khác biệt không hề nhỏ trong lợi suất tính toán khi giá ở mức nhỏ (Ince & Porter, 2006). Các lỗi báo cáo trong mã nhà phân tích có thể tác động đến việc đánh giá

đặc điểm của các nhà phân tích và có thể làm thiên lệch các nghiên cứu thực nghiệm dựa vào việc theo dõi các nhà phân tích (Roger, 2017). Những lỗi lớn có thể ảnh hưởng đến một số thuộc tính của mẫu ở một mức độ không tương xứng với số lượng nhỏ của chúng, đưa vào các thiên lệch và làm nhiễu loạn các phân tích thống kê (Rosenberg & Houglet, 1974). Một lượng lớn thông tin không chính xác sẽ khiến các nhà nghiên cứu cần xác minh dữ liệu một cách độc lập, điều này làm suy yếu giá trị của việc sử dụng các cơ sở dữ liệu thương mại (Elton et al., 2001). Lỗi dữ liệu có thể được phát hiện và giảm bớt bằng cách kiểm tra chéo (cross-checking) với các nguồn khác. Mô hình Cân bằng Báo cáo Tài chính được Điều chỉnh có thể được sử dụng để tìm các mục nhập sai sót (Casey et al., 2016). Các phương pháp lấy mẫu thống kê thường được sử dụng để xác định lỗi dữ liệu và các giá trị ngoại lai (CRSP LLC, 2020c).

10.5 SỰ CHÊNH LỆCH (DISCREPANCIES)

Nhiều nhà nghiên cứu đã tìm thấy các sự chênh lệch khi so sánh các cơ sở dữ liệu hoặc tập dữ liệu khác nhau (Grinblatt et al., 1984; Sarig & Warga, 1989; Guenther & Rosman, 1994; Courtenay & Keller, 1994; Kern & Morris, 1994; Kahle & Walkling, 1996; Elton et al., 2001;

Yang et al., 2003; Ulbricht & Weiner, 2005; Daske et al., 2013; Bollaert & Delanghe, 2015; McGuire et al., 2016; Tobek & Hronec, 2018). Sự chênh lệch có thể là do sự khác biệt về độ bao phủ cơ sở dữ liệu, định nghĩa, chính sách mã hóa, mã định danh, phân loại, mô hình tính toán, thiên lệch chọn mẫu, hoặc lỗi dữ liệu (Sarig & Warga, 1989; Courtenay & Keller, 1994; Kern & Morris, 1994; Yang et al., 2003; Tallapally, 2009; Dreyer & Hines, 2014; Nam, et al., 2017).

Thường xuyên nhất, sự chênh lệch được phát hiện bằng cách so sánh hai cơ sở dữ liệu hoặc tập dữ liệu khác nhau. Tuy nhiên, sự chênh lệch cũng có thể xảy ra trong phạm vi một cơ sở dữ liệu, đặc biệt là trong các cơ sở dữ liệu tập hợp (aggregator databases) mà thu thập dữ liệu từ các nguồn khác nhau. Ví dụ, các nhà nghiên cứu đã phát hiện ra rằng EPS thực tế trong I/B/E/S khác với EPS thực tế được nhà phân tích suy ra ở 39% số lần (Brown & Larocque, 2011, 2013). Sự chênh lệch phổ biến hơn đối với các giao dịch phức tạp như chia tách cổ phiếu, cổ tức bằng cổ phiếu, sáp nhập và mua lại, những thay đổi kế toán hoặc các hoạt động bị ngừng lại (Grinblatt et al., 1984; Courtenay & Keller, 1994; Kern & Morris, 1994). Sự chênh lệch là phổ biến hơn đối với các khoản mục dữ liệu dựa trên sự gán chủ quan như mã SIC (Guenther & Rosman, 1994; Kahle & Walkling, 1996; Stasch, 2014); Sự chênh lệch có thể xảy ra do các quy trình chuẩn hóa trong cơ sở dữ liệu có thể không nhất thiết mang lại lợi ích cho nghiên cứu thực nghiệm (Tallapally et al., 2012; Chychyla & Kogan, 2014). Mức độ chênh lệch cao hơn giữa các cơ sở dữ liệu được xác định đối với dữ liệu quốc tế, đặc biệt là dữ liệu về các quốc gia đang phát triển (Lara et al., 2006; Daske et al., 2013; McGuire et al., 2016; Hines & Sharma, 2018). Sự chênh lệch lớn về tính khả dụng của dữ liệu giữa các quốc gia khác nhau phần lớn là do các thông lệ kế toán và quy tắc nộp hồ sơ khác nhau dựa trên các tập quán lịch sử và văn hóa khác nhau (Green, 2007). Firat (2002) đã xác định ít nhất ba loại tính không đồng nhất (heterogeneities) (tính không đồng nhất ở cấp độ dữ liệu, về mặt bản thể học và thời gian) giữa các cơ sở dữ liệu. Sự khác biệt phát sinh khi các cơ sở dữ liệu chọn các đơn vị, tỷ lệ hoặc định dạng khác nhau để trình bày dữ liệu của cùng một công ty; hoặc khi chúng áp dụng các định nghĩa kế toán, chính sách chuyển đổi tiền tệ khác nhau; hoặc khi các giá trị hay định nghĩa thực thể thuộc về các thời điểm, hoặc khoảng thời gian khác nhau (Firat, 2002).

Sự chênh lệch trên các cơ sở dữ liệu hàm ý rằng sẽ có rủi ro khi dựa vào bất kỳ cơ sở dữ liệu đơn lẻ nào (McGuire, 2016). Sự chênh lệch có thể dẫn đến “hiệu ứng cơ sở dữ liệu” (database effect), có nghĩa là các nhà nghiên cứu sẽ đi đến các kết luận khác nhau dựa trên các cơ sở dữ liệu khác nhau. Những khác biệt trong cơ sở dữ liệu có thể ảnh hưởng đến các lựa chọn mẫu, các suy diễn

về tổng thể, và có thể ảnh hưởng sâu hơn tới kết quả của nghiên cứu thực nghiệm (Kern & Morris, 1994; Kahle & Walkling, 1996; Lara et al., 2006; McGuire et al., 2016). Nhiều nhà nghiên cứu chọn sử dụng nhiều nguồn dữ liệu cho nghiên cứu của họ; tuy nhiên, cần phải nỗ lực lớn để so sánh các chính sách mã hóa, đối chiếu (matching), lọc, và làm sạch dữ liệu (Chakrabarty & Trzcinka, 2006).

10.6 CÁC THIÊN LỆCH (BIASES)

Những lo ngại về các thiên lệch trong cơ sở dữ liệu được thảo luận rộng rãi. Thiên lệch phóng đại (upward bias), thiên lệch hủy niêm yết, thiên lệch bỏ sót, thiên lệch sống sót (survivorship bias), thiên lệch ươm tạo (incubation bias), thiên lệch điền lùi (backfill bias) (hoặc thiên lệch ‘lịch sử tức thời’ - ‘instant-history’ bias), và thiên lệch trùng lặp (duplication bias) đã được phát hiện trong CRSP (Loughran & Ritter, 1995; Shumway, 1997; Canina et al., 1998; Shumway & Warther, 1999; Elton et al., 2001; Wisen, 2002; Yan, 2007; Evans, 2010; Jorion and Schwarz,

2017; CRSP, 2020). Thiên lệch sống sót, thiên lệch chọn lọc sau sự kiện (ex-post-selection bias), và thiên lệch nhìn trước (look-ahead bias) đã được tìm thấy trong Compustat (Ball, 1979; Banz & Breen, 1986). Thiên lệch sống sót và thiên lệch chọn mẫu đã được báo cáo trong Datastream và Orbis (Ince & Porter, 2006; Andrikopoulos et al., 2007; Kalemli-Ozcan et al., 2019).

Thiên lệch có thể xảy ra vì nhiều lý do. Việc phóng đại bởi một thước đo hoặc chỉ số thống kê có thể dẫn đến thiên lệch phóng đại (Rosenberg & Houglet, 1974; Loughran & Ritter, 1995). Khi các quan sát bị loại trừ khỏi mẫu do một quy tắc chọn lọc khác với việc lấy mẫu ngẫu nhiên, nó có thể tạo ra thiên lệch chọn mẫu. Thiên lệch sống sót là một ví dụ về thiên lệch chọn mẫu được thúc đẩy bởi sự loại trừ không tương xứng đối với các cổ phiếu đã bị hủy niêm yết theo thời gian (Waszczuk, 2014). Thiên lệch ươm tạo là một ví dụ về thiên lệch chọn mẫu do các quỹ mới có hiệu suất kém bị loại khỏi cơ sở dữ liệu hoặc không được đưa vào kịp thời (Wisen, 2002). Thiên lệch điều lùi phát sinh khi hiệu suất của quỹ không được công khai trong một khoảng thời gian ươm tạo nhưng sau đó được thêm vào cơ sở dữ liệu, có lẽ là sau một hiệu suất tốt (Jorion & Schwarz, 2017). Thiên lệch nhìn trước xảy ra khi dữ liệu được sử dụng trong nghiên cứu được giả định là có sẵn cho công chúng tại một thời điểm cụ thể trong khi trên thực tế, dữ liệu đó chỉ có sẵn vào một thời điểm muộn hơn (Andrikopoulos et al., 2007). Việc bỏ qua lợi suất hủy niêm yết đối với một lượng lớn các công ty có thể dẫn đến thiên lệch hủy niêm yết (Shumway & Warther, 1999; Waszczuk, 2014). Các thiên lệch có nhiều khả năng xảy ra đối với các công ty mới, công ty nhỏ, công ty nước ngoài, các công ty hủy niêm yết và các công ty có hiệu suất kém (Andrikopoulos et al., 2007; Landis & Skouras, 2018). Thiên lệch có thể làm sai lệch kết quả nghiên cứu thực nghiệm và tạo ra các kết luận không đáng tin cậy. Một số nhà nghiên cứu cố gắng khắc phục thiên lệch sống sót bằng cách thêm các công ty đã hủy niêm yết trở lại vào mẫu của họ. Tuy nhiên, việc giảm thiểu các thiên lệch phụ thuộc rất nhiều vào những nỗ lực của các nhà cung cấp cơ sở dữ liệu trong việc cải thiện chất lượng dữ liệu và tính toàn vẹn của dữ liệu (data integrity).

10.7 SỰ KHÔNG NHẤT QUÁN (INCONSISTENCIES)

Sự không nhất quán mô tả một tình huống mà dữ liệu không được xử lý một cách nhất quán với cùng một quy tắc, đặc biệt là trong cùng một cơ sở dữ liệu. Sự không nhất quán cần được điều tra thêm về các lỗi dữ liệu tiềm ẩn. Các vấn đề không nhất quán đã được báo cáo trong các cơ sở dữ liệu Compustat, Orbis và SDC (McElreath & Wiggins, 1984; Faccio & Masulis, 2005; Shi & Zhang, 2011; Kalemli-Ozcan et al., 2019). Một ví dụ về sự không nhất quán là việc các khoản mục kế toán giống nhau được định nghĩa khác nhau trong các báo cáo tài chính khác nhau. Người ta đã báo cáo rằng trong Compustat “chi phí khấu hao và phân bổ” (depreciation and amortization expenses) được báo cáo trên báo cáo kết quả hoạt động kinh doanh và báo cáo lưu chuyển tiền tệ bao gồm các khoản mục khác nhau. Các sự kiện đặc biệt chẳng hạn như “bán tài sản” và “ghi giảm hàng tồn kho” (inventory write-offs) đã được điều chỉnh trong báo cáo lưu chuyển tiền tệ nhưng không phải trong bảng cân đối kế toán. Số tiền trình bày lại (restated amount) được phản ánh trong báo cáo lưu chuyển tiền tệ đã không được điều chỉnh trong bảng cân đối kế toán. Sự thay đổi về phân loại được phản ánh trong

bảng cân đối kế toán đã không được cập nhật trong báo cáo lưu chuyển tiền tệ (Shi & Zhang, 2011). Hơn nữa, sự không nhất quán có thể xảy ra đối với các khoảng thời gian khác nhau, ví dụ, định nghĩa của Compustat về các khoản phải trả trong năm 2002 và 2003 là khác nhau (Shi & Zhang, 2011). Các vấn đề không nhất quán cũng có thể xảy ra với các mã định danh độc quyền (proprietary identifiers). Một mã định danh độc quyền thường được nhận dạng là ID duy nhất để theo dõi một công ty; tuy nhiên, nó có thể không được sử dụng một cách nhất quán theo cách này. Các nhà nghiên cứu đã tiết lộ rằng mã BvD ID của một công ty

có thể thay đổi do thay đổi địa chỉ, hình thức pháp lý (legal form), hoặc các hoạt động M&A, điều này có thể gây ra vấn đề trong việc theo dõi các thay đổi của một công ty (Kalemli-Ozcan et al., 2019).

Các nhà nghiên cứu có thể giả định rằng các cơ sở dữ liệu từ cùng một nhà cung cấp có cùng một chính sách báo cáo. Nhưng Mathers and Giacomini (2016) đã nhắc nhở các nhà nghiên cứu rằng Compustat và Capital IQ đều từ S&P Global Market Intelligence có chính sách mã hóa khác nhau về năm tài chính (Mathers & Giacomini, 2016). I/B/E/S và Worldscope đều từ Thomson Reuters, trong khi 22% sự chênh lệch giữa ngày công bố đã được báo cáo trong hai cơ sở dữ liệu này (Acker & Duck, 2009). Thông tin từ các phần khác nhau của một cơ sở dữ liệu cũng có thể không nhất quán. Các nhà nghiên cứu đã báo cáo rằng trong SDC, dữ liệu “phương thức thanh toán” thu được từ phần mô tả và trường biến “phương thức thanh toán” có sự khác biệt thường xuyên (Faccio & Masulis, 2005). Dữ liệu không nhất quán có thể tạo ra các vấn đề về khả năng so sánh (McElreath & Wiggins, 1984). Nó có thể gây ra các vấn đề tương tự như lỗi dữ liệu và đôi khi đánh lừa các nhà nghiên cứu. Do các nhà nghiên cứu phải mất nhiều công sức để nhận thấy và giải quyết các điểm không nhất quán trong các cơ sở dữ liệu, vấn đề này làm suy yếu giá trị của các cơ sở dữ liệu thương mại.

10.8 DỮ LIỆU PHẦN ĐẦU TÍNH (STATIC HEADER DATA)

Vấn đề dữ liệu phần đầu tính (hoặc vấn đề về niên đại - vintage issue) xảy ra khi cơ sở dữ liệu chỉ cung cấp thông tin mới nhất có sẵn và thiếu các bản ghi chuỗi thời gian (Kalemli-Ozcan et al., 2019). Vấn đề dữ liệu phần đầu tính xảy ra chủ yếu trong trường dữ liệu bao gồm “tên công ty”, “mã chứng khoán” (ticker), “địa chỉ”, “trụ sở chính”, “quyền sở hữu” (ownership), “sàn giao dịch chứng khoán”, và “mã ngành” (Ince & Porter, 2006; Hines, 2016; Landis & Skouras, 2018; Nobes & Stadler, 2018; Kalemli-Ozcan et al., 2019). Các vấn đề như vậy đã được quan sát thấy trong Compustat, Orbis, Worldscope, và Datastream (Ince & Porter, 2006; Hines, 2016; Landis & Skouras, 2018; Nobes & Stadler, 2018; Kalemli-Ozcan et al., 2019). Dữ liệu phần đầu tính xóa đi hồ sơ theo dõi (track record) về các thay đổi trước đó, do đó nó hạn chế các nhà nghiên cứu đưa các biến dữ liệu này vào phân tích chuỗi thời gian. Vì dữ liệu có thể không đại diện chính xác cho thời điểm đó, khi sử dụng các trường dữ liệu phần đầu tính để tạo mẫu, nó có thể dẫn đến mẫu không chính xác, thiếu sót, hoặc thiên lệch chọn mẫu (Landis & Skouras, 2018).

10.9 SỰ CHUẨN HÓA (STANDARDIZATION)

Sự chuẩn hóa và điều chỉnh làm cho dữ liệu có thể so sánh tốt hơn giữa các công ty, theo thời gian, và đặc biệt làm cho nó khả thi để so sánh các công ty từ các quốc gia khác nhau. Lợi ích rõ ràng của sự chuẩn hóa khiến nó trở thành điểm nhấn bán hàng của một số cơ sở dữ liệu như Compustat, Worldscope, và Orbis. Tuy nhiên, sự chuẩn hóa cũng gây ra các vấn đề về dữ liệu. Sự chuẩn hóa và điều chỉnh dữ liệu về “khấu hao, cạn kiệt, và phân bổ” (depreciation, depletion, and amortization) trong Compustat đã được phát hiện là “báo cáo thấp đi 7.5% so với giá vốn hàng bán trong hồ sơ 10-K” và “phóng đại tỷ suất lợi nhuận gộp trong hồ sơ 10-K thêm 14.3%” (Bostwick et al., 2016). Các nhà nghiên cứu cũng phát hiện ra sự chuẩn hóa trong Compustat “không mang lại sự cải thiện nào cho các mô hình dự đoán phá sản và tác động tiêu cực đáng kể đến độ chính xác dự báo của mô hình Altman” (Chychyla & Kogan, 2014, tr. 1). Việc chuẩn hóa đối với

dữ liệu I/B/E/S được điều chỉnh theo chia tách cổ phiếu và làm tròn đến đồng xu gần nhất làm mất đi thông tin (Payne & Thomas, 2003). Vì vậy, các nhà nghiên cứu nên cân nhắc kỹ hơn khi lựa chọn giữa tập dữ liệu đã chuẩn hóa và chưa chuẩn hóa. Cần phải nỗ lực hơn để hiểu quá trình chuẩn hóa và những thay đổi được tạo ra đối với các tập dữ liệu gốc do một quá trình như vậy.

10.10 NHỮNG THAY ĐỔI TRONG DỮ LIỆU LỊCH SỬ (CHANGES IN HISTORICAL DATA)

Dữ liệu lịch sử có thể được sửa đổi do việc sửa lỗi hoặc cập nhật từ sự trình bày lại. Nhưng những thay đổi có hệ thống trong dữ liệu lịch sử có thể là một vấn đề. Các nhà nghiên cứu sử dụng các đề xuất cổ phiếu của nhà phân tích I/B/E/S phát hiện ra các tệp dữ liệu trong cùng một khoảng thời gian được tải xuống tại các thời điểm khác nhau có những khác biệt đáng kể. Những khác biệt này bao gồm các mức đề xuất, việc bổ sung và xóa các bản ghi, xóa tên nhà phân tích, và các thay đổi trong các thuộc tính của dự báo thu nhập có sẵn trong mỗi phiên bản (Ljungqvist et al., 2008; Call et al., 2020). Những thay đổi tưởng chừng như không ngẫu nhiên này đã làm dấy lên những lo ngại về tính toàn vẹn của dữ liệu (Brown-Humes, 2006). Những thay đổi trong dữ liệu lịch sử có thể rất phổ biến do tính chất hay thay đổi của các cơ sở dữ liệu thương mại, đặc biệt đối với các nhà tổng hợp dữ liệu lấy dữ liệu từ các nguồn dữ liệu sơ cấp khác. Những thay đổi về các nhà cung cấp dữ liệu sơ cấp, những người đóng góp (contributors), và các điều khoản hợp đồng đều có thể dẫn đến những thay đổi trong cơ sở dữ liệu. Trong những trường hợp mà cơ sở dữ liệu trao cho những người đóng góp dữ liệu quyền kiểm soát trực tiếp đối với cơ sở dữ liệu, những thay đổi có nhiều khả năng xảy ra hơn và khó quản lý hơn.

10.11 THIẾU TÍNH MINH BẠCH (LACK OF TRANSPARENCY)

Thiếu tính minh bạch là một vấn đề cơ bản đối với nhiều vấn đề dữ liệu khác. Nói chung, các nhà cung cấp cơ sở dữ liệu không minh bạch về quy trình quản lý và thu thập dữ liệu của họ, chứ chưa nói đến việc cảnh báo các nhà nghiên cứu về các vấn đề và thiên lệch dữ liệu tiềm ẩn (Annaert, et al., 2016). Các nhà nghiên cứu bày tỏ sự quan ngại về tính minh bạch của dữ liệu SDC về cách thức thu thập dữ liệu hoặc cách xác định các biến (Netter et al., 2011). Mặc dù các vấn đề dữ liệu thường không được giải thích công khai, đôi khi chúng được tiết lộ thông qua các cuộc trò chuyện riêng giữa các nhà nghiên cứu và các nhà cung cấp cơ sở dữ liệu. Khi bị đặt câu hỏi về những thay đổi trong dữ liệu lịch sử của các nhà phân tích cá nhân, I/B/E/S phản hồi rằng tên của các nhà phân tích cá nhân vẫn còn trong cơ sở dữ liệu, nhưng chúng không hiển thị trên các tệp mà giới học thuật nhìn thấy do nguồn cấp dữ liệu (data feed) không đầy đủ (Brown-Humes, 2006). Khi được hỏi về những thay đổi trong các dự báo thu nhập lịch sử, I/B/E/S giải thích rằng những điều chỉnh hồi tố có thể xảy ra do chia tách cổ phiếu, cổ tức bằng cổ phiếu, những điều chỉnh tiền tệ mặc định hoặc sửa lỗi và tiết lộ thêm rằng một số khác biệt xảy ra là do công ty môi giới duy trì quyền kiểm soát đối với việc phân phối những dự báo này và những người đăng ký (subscribers) học thuật thường chỉ có quyền truy cập vào một tập hợp con của tất cả các dự báo thu nhập được đóng góp vào cơ sở dữ liệu (Call et al., 2020). Bất chấp những lời giải thích từ các nhà cung cấp, việc thiếu tính minh bạch khiến các nhà nghiên cứu lo ngại và ảnh hưởng lớn đến niềm tin của các nhà nghiên cứu đối với các cơ sở dữ liệu thương mại (Call et al., 2020).

10.12 CÁC VẤN ĐỀ VỀ THỜI GIAN BÁO CÁO (REPORTING TIME ISSUES)

Thời gian báo cáo dữ liệu có thể là một vấn đề khi các nhà cung cấp cơ sở dữ liệu không minh bạch về thời gian báo cáo dữ liệu và lịch cập nhật của họ. Nó có thể ảnh hưởng đến nghiên cứu khi thời điểm mà dữ liệu có sẵn cho công chúng khác với thời điểm mà một nghiên cứu giả định nó là (McElreath & Wiggins, 1984). Việc ghi nhận không đúng thời gian báo cáo có thể gây ra thiên lệch nhìn trước (Andrikopoulos, et al., 2007). Sự trễ báo cáo (reporting lag) hoặc sự chậm trễ là một vấn đề khác đôi khi là không thể tránh khỏi. Trong trường hợp dữ liệu được tổng hợp từ các nhà cung cấp khác nhau, sự

trễ báo cáo có thể gây ra bởi các điều khoản hợp đồng cấm tiết lộ (embargo) cụ thể. Trong trường hợp dữ liệu có nguồn gốc từ các quốc gia khác nhau, sự trễ báo cáo cũng có thể do các thực tiễn tuân thủ báo cáo khác nhau ở các quốc gia khác nhau (Green, 2003). Độ trễ báo cáo trong Orbis được phát hiện là khoảng 2 năm tính trung bình và thay đổi theo từng quốc gia và từng sản phẩm dữ liệu (Kalemli-Ozcan et al. 2019). Độ trễ báo cáo do sự ươm tạo (khi các quỹ mới có hiệu suất kém không được đưa vào cơ sở dữ liệu nhanh chóng như các quỹ mới có hiệu suất vượt trội) có thể dẫn đến thiên lệch chọn mẫu (Wisen, 2002).

10.13 SỰ LẠM DỤNG DỮ LIỆU (MISUSE OF DATA)

Các vấn đề dữ liệu không chỉ giới hạn ở bản thân dữ liệu, đôi khi các nhà nghiên cứu có thể sử dụng dữ liệu một cách không đúng đắn như là các biến đại diện (proxies) hoặc các thước đo. Ví dụ, việc ghép (nhân gộp) lợi suất hàng ngày (compounding) của chỉ số tỷ trọng đều (equal-weighted index) CRSP để tính lợi suất hàng tháng có thể dẫn đến những thiên lệch lớn (Canina et al., 1998). Các hệ số điều chỉnh (adjustment factors) đối với giá cổ phiếu của CRSP đã bao gồm các hiệu ứng từ các sự kiện cổ tức bằng tài sản, chia tách công ty (spin-off), và chào bán quyền mua cổ phần (rights offering), do đó các nhà nghiên cứu chỉ được sử dụng các hệ số điều chỉnh của CRSP để xử lý (accommodate) các sự kiện thiếu tính thực chất kinh tế như vậy, nếu không, nó có thể tạo ra các quan sát mẫu sai sót và các kết quả sai lệch (Francis et al., 2016). Mills et al. (2003) cảnh báo các nhà nghiên cứu cần đặc biệt thận trọng khi sử dụng dữ liệu lỗi hoạt động rỗng của Compustat làm chỉ báo cho các vị thế lỗ thuế ở Hoa Kỳ của một công ty, đặc biệt là khi bối cảnh nghiên cứu liên quan đến các công ty có hoạt động ở nước ngoài hoặc hoạt động mua lại của công ty. Hơn nữa, vì Compustat chỉ bao phủ các công ty đại chúng trong một ngành, nó là một đại diện kém cho mức độ tập trung ngành thực tế. Việc xây dựng các thước đo tập trung ngành bằng cách sử dụng dữ liệu Compustat có thể dẫn đến kết luận không chính xác (Ali et al., 2008; Keil, 2017). Những thông báo mua lại cổ phần trong SDC là những công cụ dự báo kém đối với số lượng cổ phiếu sẽ được công ty mua lại, bởi vì dữ liệu không đầy đủ (Banyi et al., 2008).

Thông qua nghiên cứu, chúng tôi thấy rằng một số vấn đề chất lượng dữ liệu có thể được giảm nhẹ thông qua sự cải thiện trong các phương pháp kiểm định thống kê, các kỹ thuật lập hồ sơ và khai phá dữ liệu (data profiling and mining), cùng với việc áp dụng các chính sách và hệ thống báo cáo dữ liệu mới. Tuy nhiên, sự cải thiện chất lượng dữ liệu tổng thể phần lớn phụ thuộc vào các hoạt động kiểm soát chất lượng minh bạch của các nhà cung cấp dữ liệu và sự tham gia cởi mở của họ với cộng đồng nghiên cứu.

10.14 HÀM Ý ĐỐI VỚI THAM KHẢO KINH DOANH VÀ TƯ VẤN NGHIÊN CỨU

Giúp người dùng thư viện và các nhà nghiên cứu hiểu chất lượng thông tin là một phần thiết yếu của các dịch vụ tham khảo thư viện. Các thủ thư đã đặc biệt chú ý đến các khía cạnh chất lượng thông tin như độ tin cậy, tính hợp lệ (validity), độ chính xác, tính thẩm quyền, tính kịp thời, và các thiên lệch (ACRL, 2000). Chúng tôi cũng đã phát triển các phương pháp thực tiễn như bộ tiêu chí CRAAP (Tính cập nhật - Currency, Tính phù hợp - Relevance, Thẩm quyền - Authority, Độ chính xác - Accuracy, và Mục đích - Purpose) để tạo điều kiện cho giáo dục về hiểu biết thông tin (Blakeslee, 2004). Tuy nhiên, nghiên cứu này nhận thấy các vấn đề chất lượng dữ liệu có thể phức tạp và đáng lo ngại hơn nhiều. Những thủ thư kinh doanh cần phải nhận thức được các vấn đề chất lượng dữ liệu này và nâng cao nhận thức của các nhà nghiên cứu về các vấn đề này thông qua tham khảo kinh doanh và tư vấn. Dưới đây là một số lời khuyên thực tế mà chúng ta có thể cung cấp cho các nhà nghiên cứu.

- Các nhà nghiên cứu không nên coi chất lượng của các cơ sở dữ liệu thương mại danh tiếng là điều hiển nhiên. Họ luôn nên đánh giá chất lượng dữ liệu và kiểm tra độ chính xác và tính đầy đủ của nó. Họ cần cẩn trọng với các dự án nghiên cứu những khái niệm kế toán hoặc các giao dịch kinh doanh phức tạp, hoặc các dự án liên quan đến các công ty mới, công ty nhỏ, công ty nước ngoài, hoặc công ty hủy niêm yết.
- Các nhà nghiên cứu không nên chỉ dựa vào một nguồn dữ liệu duy nhất. Nếu có thể, họ nên tham khảo nhiều nguồn, đặc biệt là các nguồn dữ liệu gốc. Họ nên chú ý đến các định nghĩa và chính sách mã hóa khác nhau của các cơ sở dữ liệu khác nhau và coi sự chênh lệch giữa các cơ sở dữ liệu như một cơ hội để xác định các giá trị bị thiếu hoặc lỗi dữ liệu. Họ nên cẩn trọng vì “hiệu ứng cơ sở dữ liệu” và kiểm chứng các lý thuyết của họ thông qua nhiều nguồn dữ liệu.
- Các nhà nghiên cứu nên đọc cẩn thận các cảnh nang dữ liệu và hiểu cách dữ liệu được định nghĩa hoặc tính toán, đặc biệt đối với dữ liệu đã được chuẩn hóa hoặc điều chỉnh. Họ nên nhận thức được sự không nhất quán của cơ sở dữ liệu trong việc xử lý các định nghĩa và những điều chỉnh như vậy trên các báo cáo tài chính, các khoảng thời gian lịch sử, và xuyên suốt cơ sở dữ liệu.
- Các nhà nghiên cứu nên thận trọng trong việc sử dụng cơ sở dữ liệu làm công cụ sàng lọc để xác định các mẫu dữ liệu, đặc biệt là sử dụng trường dữ liệu phần đầu tính như một biến để sàng lọc các mẫu dữ liệu. Họ cần đánh giá xem liệu dữ liệu mẫu có phải là các biến đại diện hoặc thước đo thích hợp hay không. Dữ liệu không đầy đủ và các phân loại không chính xác trong cơ sở dữ liệu có thể gây ra các bản ghi bị thiếu hoặc không chính xác trong các mẫu dữ liệu hoặc thậm chí tạo ra thiên lệch chọn mẫu và kết quả sai lệch.
- Các nhà nghiên cứu không nên bỏ qua các thiên lệch trong cơ sở dữ liệu. Thay vào đó, họ cần tìm kiếm các thủ tục thích hợp để giảm thiểu các thiên lệch và giải thích rõ ràng về tác động của các thiên lệch tiềm ẩn cũng như những hạn chế của nghiên cứu của họ.
- Các nhà nghiên cứu không nên coi việc thu thập dữ liệu là giao dịch một lần (one-time transaction). Thay vào đó, họ cần hiểu tính chất hay thay đổi của một cơ sở dữ liệu nghiên cứu, bảo tồn dữ liệu ở các thời điểm khác nhau, và để lại một bằng chứng bằng văn bản (paper trail) về truy cập và sử dụng dữ liệu.

- Các nhà nghiên cứu cần nhận thức được thời gian báo cáo, độ trễ báo cáo, lịch cập nhật, hoặc khoảng thời gian cấm tiết lộ (embargo) của các nguồn dữ liệu. Họ có thể cần điều chỉnh cách thu thập dữ liệu hoặc các thông lệ cập nhật của họ cho phù hợp.
- Các nhà nghiên cứu nên giữ liên lạc cởi mở với các nhà cung cấp về các vấn đề dữ liệu. Việc trao đổi của họ sẽ cho phép các nhà cung cấp xác định những vấn đề tương tự hoặc khởi xướng các dự án để tạo ra những thay đổi ở quy mô lớn.

10.15 KẾT LUẬN

Bài viết này cung cấp một bài tổng quan tài liệu về các tài liệu kinh doanh và tài chính đề cập đến các vấn đề về chất lượng dữ liệu và bao gồm các cơ sở dữ liệu như CRSP, Compustat, Capital IQ, I/B/E/S, Datastream, Worldscope, SDC, và BvD Orbis. Sự phân tích tổng hợp (synthetic analysis) trên các tài liệu kinh doanh đã xác định được 11 loại vấn đề chất lượng dữ liệu phổ biến, bao gồm giá trị bị thiếu, lỗi dữ liệu, sự chênh lệch, các thiên lệch, sự không nhất quán, dữ liệu phần đầu tính, sự chuẩn hóa, những thay đổi trong dữ liệu lịch sử, thiếu tính minh bạch, các vấn đề về thời gian báo cáo và sự lạm dụng dữ liệu. Các vấn đề dữ liệu này có thể đưa vào các lỗi và thiên lệch vào trong nghiên cứu thực nghiệm bằng nhiều cách, làm nhiều phân tích thống kê, và bóp méo kết quả nghiên cứu. Nhiều nhà nghiên cứu đã bác bỏ

các kết quả nghiên cứu trước đó sau khi sửa chữa các vấn đề dữ liệu cụ thể. Bất chấp sự phổ biến của các vấn đề về chất lượng dữ liệu, các cơ sở dữ liệu này được các nhà nghiên cứu học thuật sử dụng rộng rãi để thực hiện các nghiên cứu thực nghiệm trong các lĩnh vực kế toán, tài chính, kinh tế, toán học và thống kê, bởi thị trường thương mại cho mục đích kiểm thử ngược (backtesting) và tính toán mô hình, và bởi các cơ quan chính phủ phục vụ phân tích tài chính và kinh tế. Nghiên cứu học thuật từ lâu đã được tin cậy như một cách thức đáng tin cậy để tạo ra tri thức và đạt được những tiến bộ về mặt khoa học và lý thuyết trong các lĩnh vực liên quan. Việc ra quyết định dựa trên bằng chứng và dựa trên dữ liệu đã được hoan nghênh rộng rãi như một thực tiễn ra quyết định đáng tin cậy hơn. Các vấn đề chất lượng dữ liệu không chỉ làm suy yếu giá trị của nghiên cứu học thuật, đánh lừa các quyết định kinh doanh, gây nhiễu (confound) các chính sách của chính phủ mà còn làm tổn hại đến niềm tin của công chúng vào tri thức. Các thủ thư đã đóng một vai trò quan trọng trong việc hỗ trợ cộng đồng nghiên cứu truy cập các nguồn dữ liệu và giáo dục cho các nhà nghiên cứu. Hy vọng rằng, bài viết này sẽ giúp tạo điều kiện thuận lợi cho sự giao tiếp của thủ thư với các nhà nghiên cứu về các vấn đề chất lượng dữ liệu và sẽ nâng cao nhận thức của cộng đồng nghiên cứu về vấn đề này.

10.16 PHỤ LỤC I DANH SÁCH CÁC BÀI BÁO ĐƯỢC ĐÁNH GIÁ (LIST OF REVIEWED ARTICLES)

Bài báo (Tác giả-Năm)	Tên Tạp chí	Tóm tắt (cung cấp cho cơ sở dữ liệu có trên 5 bài báo được trích dẫn)
Center for Research in Security Prices (CRSP)		

Bài báo (Tác giả-Năm)	Tên Tạp chí	Tóm tắt (cung cấp cho cơ sở dữ liệu có trên 5 bài báo được trích dẫn)
Rosenberg and Houglet (1974)	The Journal of Finance	Phạm vi Thời gian: Số lượng Bài báo 1970-1999: 12 2000-2009: 4 2010-2019: 5 Phạm vi Tạp chí: Số lượng Bài báo The Journal of Finance: 9 Social Science Research Network (SSRN): 4 Journal of Financial and Quantitative Analysis: 2 Journal of Financial Economics: 1 The Accounting Review: 1 The Review of Financial Studies: 1 Journal of Accounting and Economics: 1 Working Paper: 1 Manuscript: 1 Tổng cộng: 21
Beedles and Simkowitz (1978)	The Journal of Finance	
Bennin (1980)	The Journal of Finance	
Grinblatt et al. (1984)	Journal of Financial Economics	
Sarig and Warga (1989)	Journal of Financial and Quantitative Analysis	
Guenther and Rosman (1994)	Journal of Accounting and Economics	
Courtenay and Keller (1994)	The Accounting Review	
Loughran and Ritter (1995)	The Journal of Finance	
Kahle and Walkling (1996)	Journal of Financial and Quantitative Analysis	
Shumway (1997)	The Journal of Finance	
Canina (1998)	The Journal of Finance	
Shumway and Warther (1999)	The Journal of Finance	
Elton et al. (2001)	The Journal of Finance	
Wisen (2002)	SSRN	
Evans (2007)	Manuscript	
Yan (2007)	SSRN	
Evans (2010)	The Journal of Finance	
Schwarz and Potter (2016)	The Review of Financial Studies	
Francis et al. (2016)	SSRN	

Bài báo (Tác giả-Năm)	Tên Tạp chí	Tóm tắt (cung cấp cho cơ sở dữ liệu có trên 5 bài báo được trích dẫn)
Jorion and Schwarz (2017)	SSRN	
Tobek and Hronec (2018)	IES Working Paper	
Compustat		
San Miguel (1977)	The Accounting Review	Phạm vi Thời gian: Số lượng Bài báo 1970-1999: 6 2000-2009: 6
Ball (1979)	The Journal of Finance	
McElreath and Wiggins (1984)	Financial Analysts Journal	

(Bảng Phụ lục I tiếp tục ở trang in 37, ngoài phạm vi đọc của WQU; ô tóm tắt của Compustat cũng tiếp tục ở đó nên số liệu trong ô này chưa phải tổng cuối cùng.)